Einführung in die Statistik

Kennenlernen und Organisation

Dr. Jakob Hoffmann

Economic Geography Group, Department für Geographie

Ludwig-Maximilians-Universität, München

Kennenlernen durch Statistik

Warum Statistik?

Statistik als fundierte Argumentation

Wissenschaft ist Überzeugungsarbeit. Überzeugt werden müssen z.B. andere Wissenschaftler, Entscheidungsträger (Policy und Strategie), die breite Öffentlichkeit (Wissenschaftskommunikation), man selbst.

Ziele dieser Veranstaltung

- *Primärziel*: Statistische Methoden verstehen, Umgang mit Daten üben
- *Metaziel*: Grundwerkzeuge wissenschaftlicher Überzeugungsarbeit erlernen (Aufbau von Bewertungs- und Kritikfähigkeit statistischer Argumente)

Abelson, Robert P (1995) *Statistics as Principled Argument*. Lawrcence Erlbaum Associates, Hillsdale.

Leben Dirigenten von Top-Orchestern länger?

Science Times

The New York Times

Frontiers: Physics
The Search For Zero

Manic-Depressive Cycle Tied to 'Clock' Defect

Music's Charms May Lengthen Life

How Ancients Navigated

Standards Stir Debate In Colleges

„Music's charms may lengthen life"

(NYT, 1978)

https://www.nytimes.com/1978/12/05/archives/musics-charms-may-lengthen-life-several-factors-involved.html

Leben Dirigenten von Top-Orchestern länger?

- Befund: Dirigenten berühmter Orchester werden im Schnitt 73.4 Jahre alt (Mittelwert amerikanischer Männer 68.5) → „Music's charms may lengthen life" (NYT 1978, in Abelson 1995).
- Sind alle amerikanischen Männer die richtige Vergleichsgruppe? Alternative: Männer, die das 30te Lebensjahr erreicht haben

Leben Dirigenten von Top-Orchestern länger?

- Befund: Dirigenten berühmter Orchester werden im Schnitt 73.4 Jahre alt (Mittelwert amerikanischer Männer 68.5) → „Music's charms may lengthen life" (NYT 1978, in Abelson 1995).
- Sind alle amerikanischen Männer die richtige Vergleichsgruppe? Alternative: Männer, die das 30te Lebensjahr erreicht haben

Statistik betreiben bedeutet **vergleichen**, und die Auswahl der Referenzgruppe entscheidet, wie überzeugend ein statistisches Argument ist.

Abelson, Robert P (1995) *Statistics as Principled Argument*. Lawrcence Erlbaum Associates, Hillsdale.
https://www.nytimes.com/1978/12/05/archives/musics-charms-may-lengthen-life-several-factors-involved.html

Lernen Schüler*innen auf Privatschulen effektiver?

Lernen Schüler*innen auf Privatschulen effektiver?

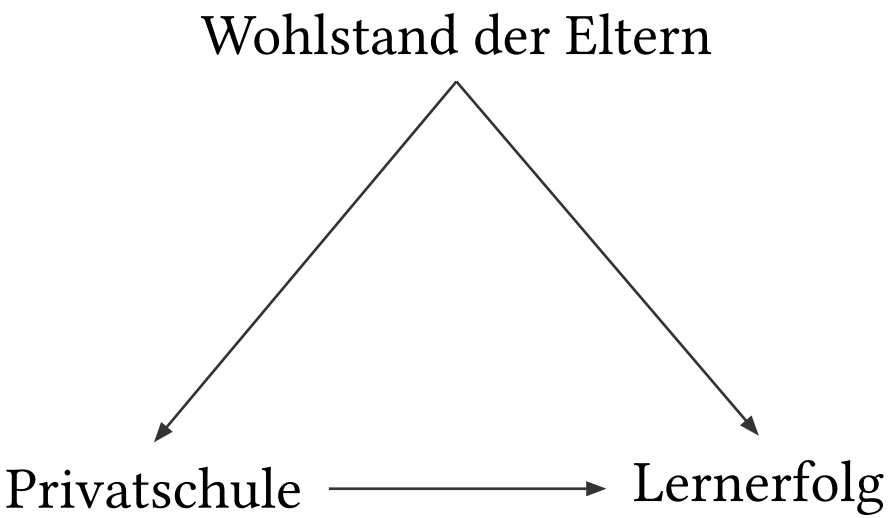

- Ein naiver Ansatz wäre, die Noten von Kindern auf Privatschulen mit denen von Kindern auf öffentlichen Schulen zu vergleichen.
- Dieser Vergleich ignoriert, dass sowohl der Besuch einer Privatschule als auch der Lernerfolg von weiteren Faktoren (wie z.B. Wohlstand) beeinflusst wird.

Llaudet, E., & Imai, K. (2025). Data Analysis for Social Science: A Friendly and Practical Introduction. Princeton University Press.

Lernen Schüler*innen auf Privatschulen effektiver?

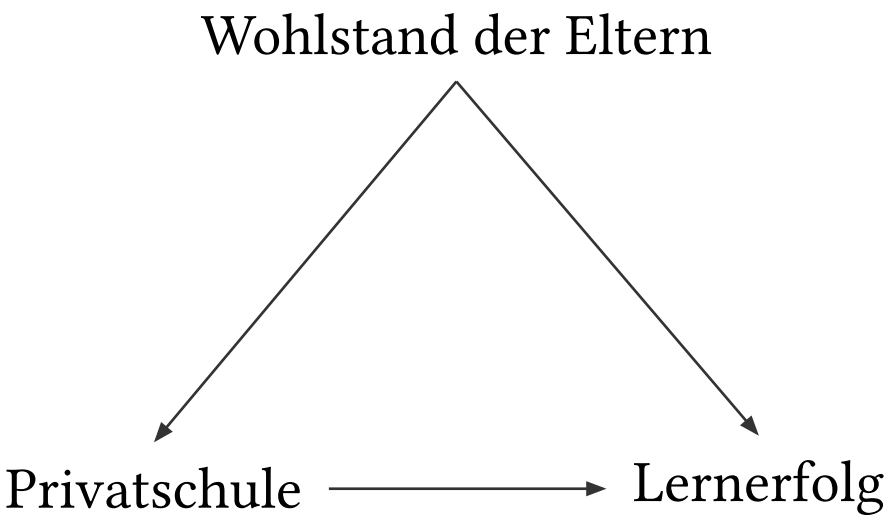

- Ein naiver Ansatz wäre, die Noten von Kindern auf Privatschulen mit denen von Kindern auf öffentlichen Schulen zu vergleichen.
- Dieser Vergleich ignoriert, dass sowohl der Besuch einer Privatschule als auch der Lernerfolg von weiteren Faktoren (wie z.B. Wohlstand) beeinflusst wird.

Ein statistisches Argument, das einen **kausalen Zusammenhang** unterstützen soll, braucht besondere Vorsicht und Werkzeuge.

Llaudet, E., & Imai, K. (2025). Data Analysis for Social Science: A Friendly and Practical Introduction. Princeton University Press.

Beispiel: Hat der Brexit der Wirtschaft geschadet?

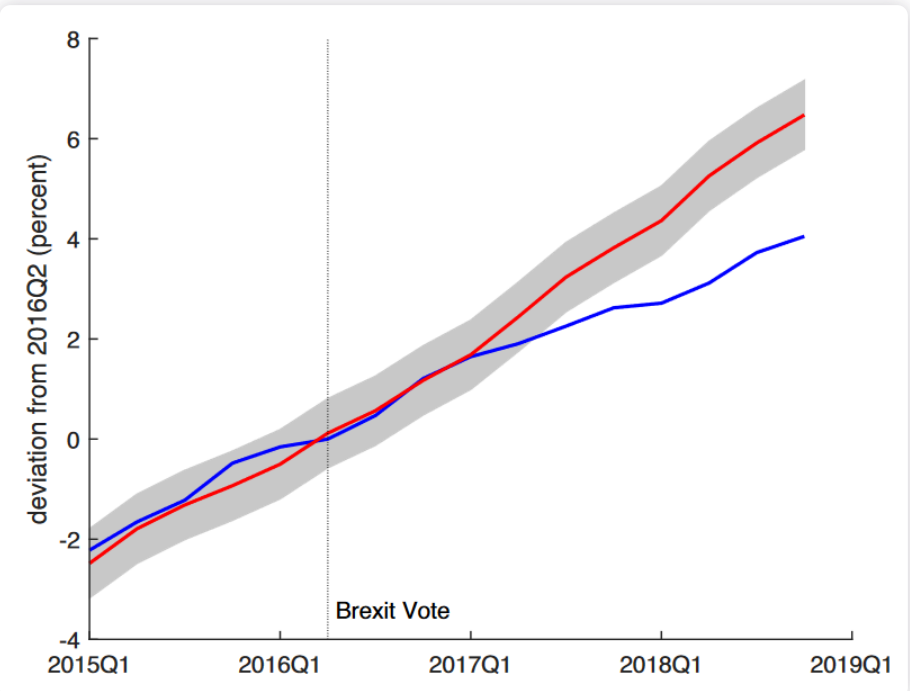

Quelle: Born et al. 2019

- Aussage über ein kontrafaktisches, hypothetisches Szenario.
- Synthetic control: Tatsächliche Entwicklung der Wirtschaft in blau vs. hypothetische Entwicklung ohne Brexit in rot (grau = Konfidenzintervall).
- Bis Ende 2018 ist ein geschätzter Outputverlust von 1.7 pp bis 2.5 pp entstanden.

Born, B., Müller, G. J., Schularick, M., & Sedláček, P. (2019). The costs of economic nationalism: Evidence from the Brexit experiment. The Economic Journal, 129(623), 2722–2744.

Leben Menschen in ‚Blue Zones' länger?

Quelle: https://www.health.harvard.edu/healthy-aging-and-longevity/living-in-the-blue-zone

Leben Menschen in ‚Blue Zones' länger?

Quelle: https://www.health.harvard.edu/healthy-aging-and-longevity/living-in-the-blue-zone

- ‚Blue Zones' sind Regionen, in denen Menschen vermeintlich besonders lange leben (hohe Rate über 100-Jähriger).
- Begründet wird die Langlebigkeit von Verfechtern mit guter Ernährung (s. *greek diet*) und gesundem Lebensstil.
- Kritiker widersprechen mit verweisen auf fehlende oder fehlerhafte Geburtsurkunden oder Pensionsbetrug.

Newman, S. J. (2019). Supercentenarians and the oldest-old are concentrated into regions with no birth certificates and short lifespans. bioRxiv.

Leben Menschen in ‚Blue Zones' länger?

Quelle: https://www.health.harvard.edu/healthy-aging-and-longevity/living-in-the-blue-zone

- ‚Blue Zones' sind Regionen, in denen Menschen vermeintlich besonders lange leben (hohe Rate über 100-Jähriger).
- Begründet wird die Langlebigkeit von Verfechtern mit guter Ernährung (s. *greek diet*) und gesundem Lebensstil.
- Kritiker widersprechen mit verweisen auf fehlende oder fehlerhafte Geburts-

Ein statistisches Argument ist nur so gut wie die **Daten**, die es unterstützen (GIGO-Prinzip: Garbage-In, Garbage-Out).

Newman, S. J. (2019). Supercentenarians and the oldest-old are concentrated into regions with no birth certificates and short lifespans. bioRxiv.

Wer wird der nächste Präsident?

Literary Digest (unrememberedhistory.com)

- Wählerbefragung zur US-Wahl 1936 (Roosevelt vs. Landon) mit **10 mio.** Befragten (ausgewählt aus Leserschaft, Telefonbuch und Automobilregister) und **2.4 mio.** Antworten
- Vorhersage: **43%** Roosevelt vs. **57%** Landon Ergebnis: **62%** Roosevelt vs. **38%** Landon
- Woran könnte der Fehler von 38pp gelegen haben?

Wer wird der nächste Präsident?

Literary Digest (unrememberedhistory.com)

- Wählerbefragung zur US-Wahl 1936 (Roosevelt vs. Landon) mit **10 mio.** Befragten (ausgewählt aus Leserschaft, Telefonbuch und Automobilregister) und **2.4 mio.** Antworten
- Vorhersage: **43%** Roosevelt vs. **57%** Landon Ergebnis: **62%** Roosevelt vs. **38%** Landon
- Woran könnte der Fehler von 38pp gelegen haben?

Die verfügbaren Daten müssen die Grundgesamtheit **repräsentieren**, über die eine Aussage getroffen werden soll.

Wie gut sind Wahlvorhersagen?

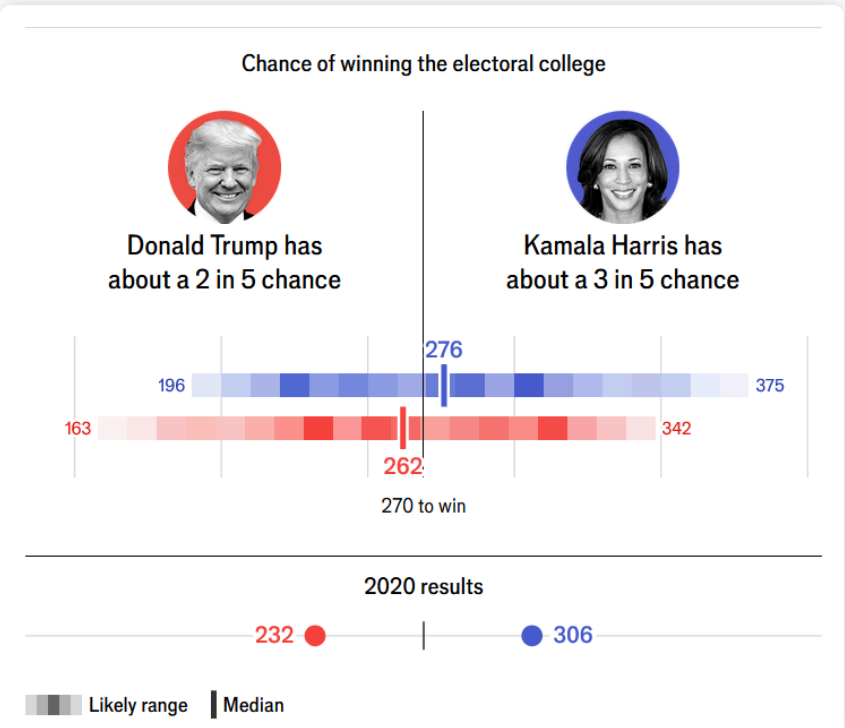

Die US-Wahlvorhersage des Economist

- Der Economist nutzt ein statistisches Modell, welches Wählerbefragungen und andere Prädiktoren (sog. *fundamentals*) kombiniert.
- Kurz vor der Wahl bestand große Unsicherheit: Ergebnisse von 196 Sitzen (verheerende Niederlage) bis 375 Sitzen (überwältigender Erfolg) für Kamala Harris waren statistisch glaubhaft.

Quantifizierung von Unsicherheit kalibriert das Vertrauen in die Aussagekraft statistischer Evidenz.

Wie sicher sind bestimmte Folgen des Klimawandels?

Table 1. Likelihood Scale	
Term*	**Likelihood of the Outcome**
Virtually certain	99-100% probability
Very likely	90-100% probability
Likely	66-100% probability
About as likely as not	33 to 66% probability
Unlikely	0-33% probability
Very unlikely	0-10% probability
Exceptionally unlikely	0-1% probability

* Additional terms that were used in limited circumstances in the AR4 (*extremely likely* – 95-100% probability, *more likely than not* – >50-100% probability, and *extremely unlikely* – 0-5% probability) may also be used in the AR5 when appropriate.

IPCC Fifth Assessment Report on Consistent Treatment of Uncertainties

„It is *virtually certain* that hot extremes (including heatwaves) have become more frequent and more intense across most land regions since the 1950s, while cold extremes (including cold waves) have become less frequent and less severe, with *high confidence* that human-induced climate change is the main driver of these changes. Some recent hot extremes observed over the past decade would have been *extremely unlikely* to occur without human influence on the climate system. Marine heatwaves have approximately doubled in frequency since the 1980s (*high confidence*), and human influence has *very likely* contributed to most of them since at least 2006."

Statistik und Geographie

Geographische Themen | Politik und Gesellschaft

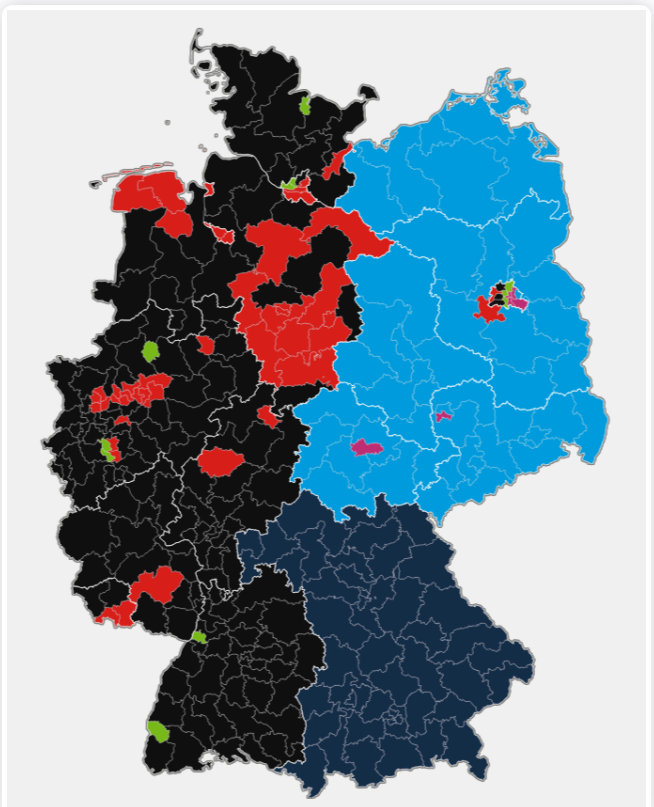

Bundestagswahlen 2025, Quelle: Tagesschau.de

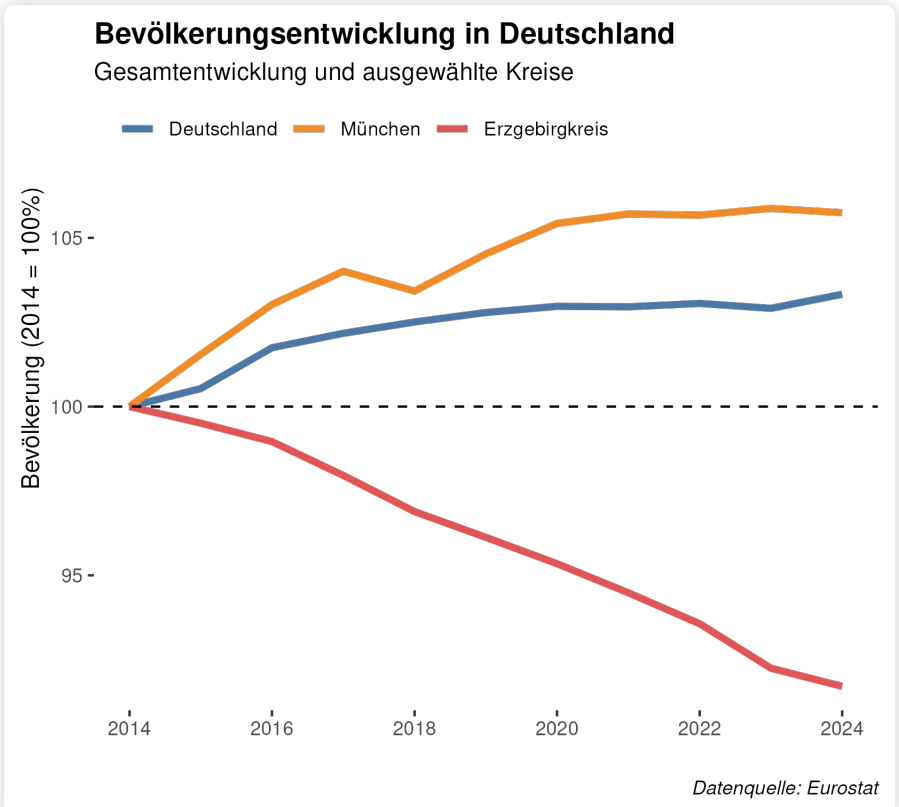

Geographische Themen | Politik und Gesellschaft

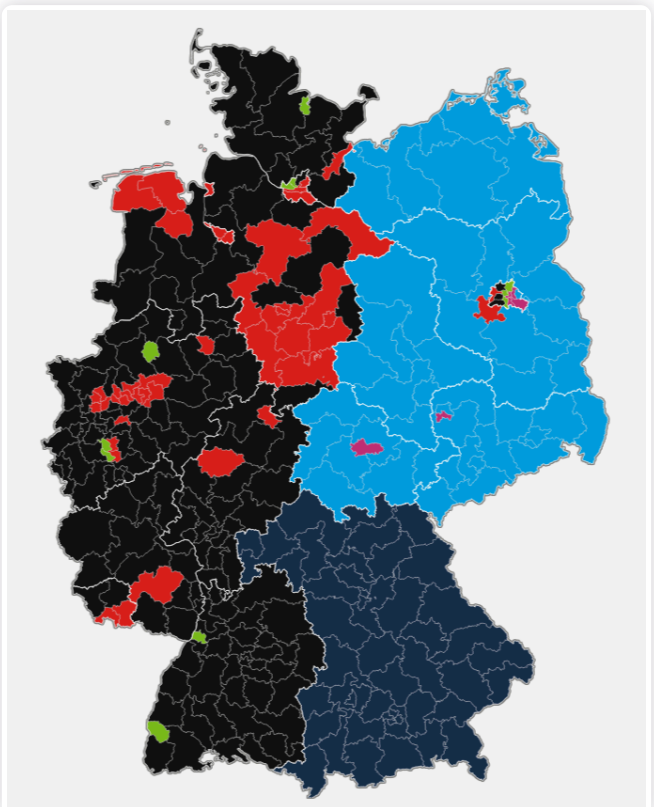

Bundestagswahlen 2025, Quelle: Tagesschau.de

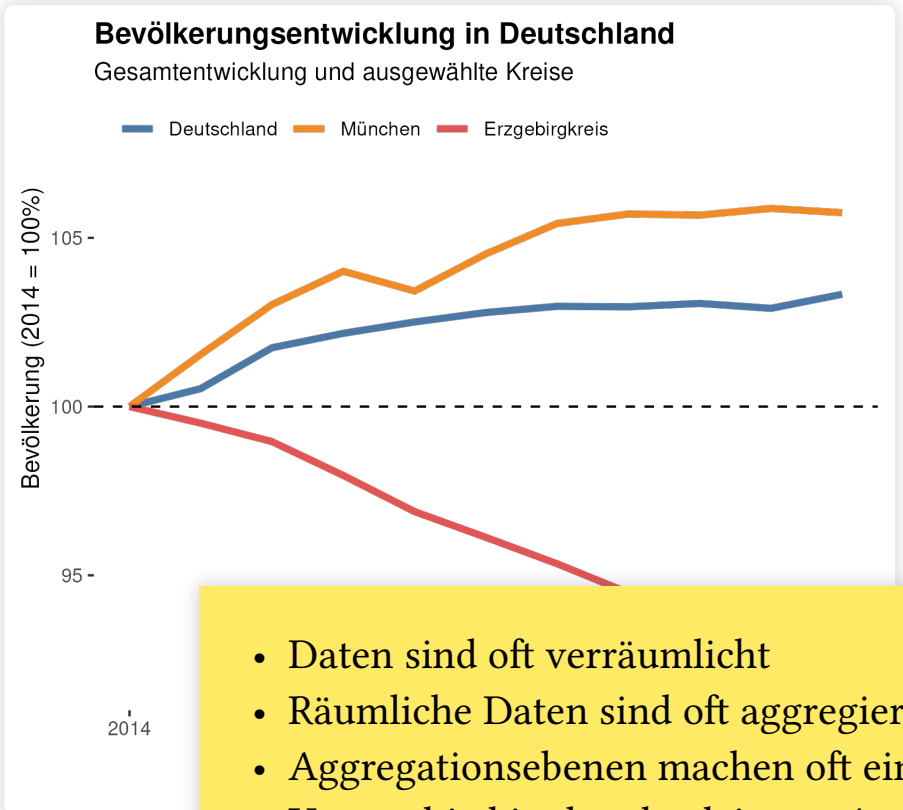

- Daten sind oft verräumlicht
- Räumliche Daten sind oft aggregiert
- Aggregationsebenen machen oft einen Unterschied in der abgeleiteten Aussage

Exkurs | Politische Kartographie der USA

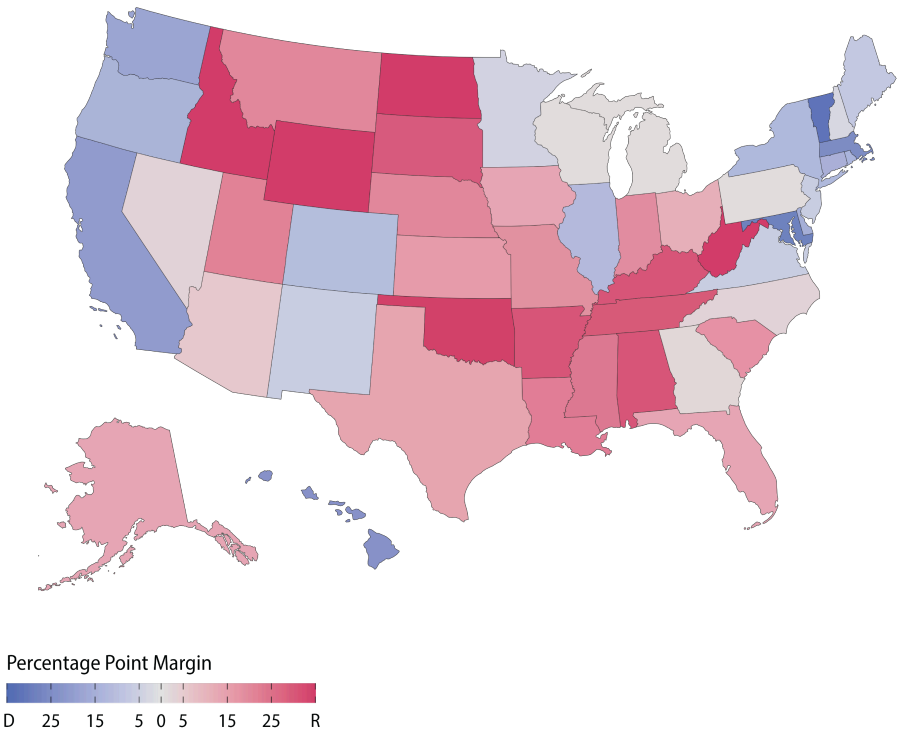

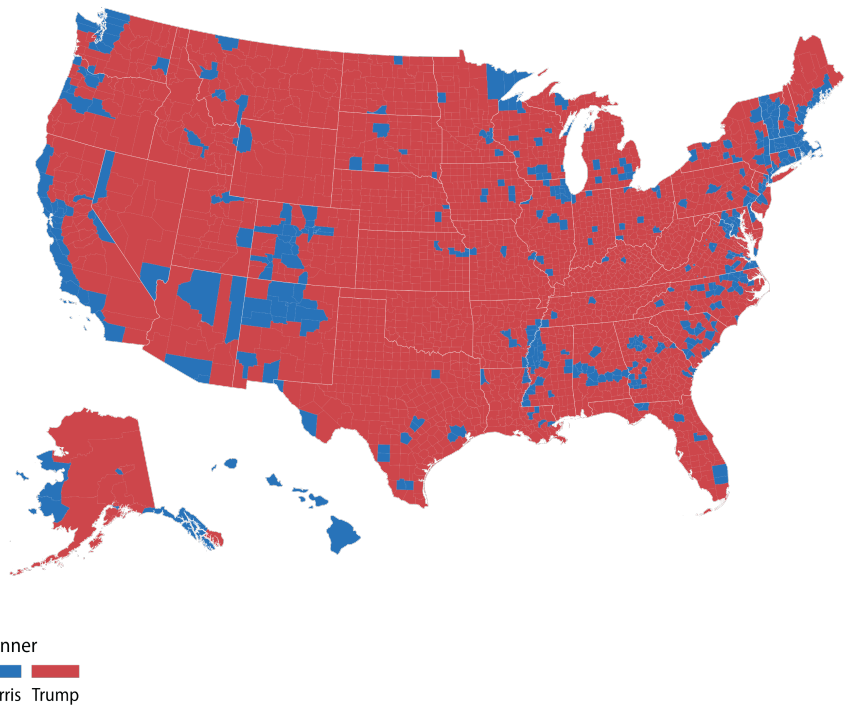

Healy, K. (2018). Data Visualization. Princeton University Press.

Exkurs | Politische Kartographie der USA

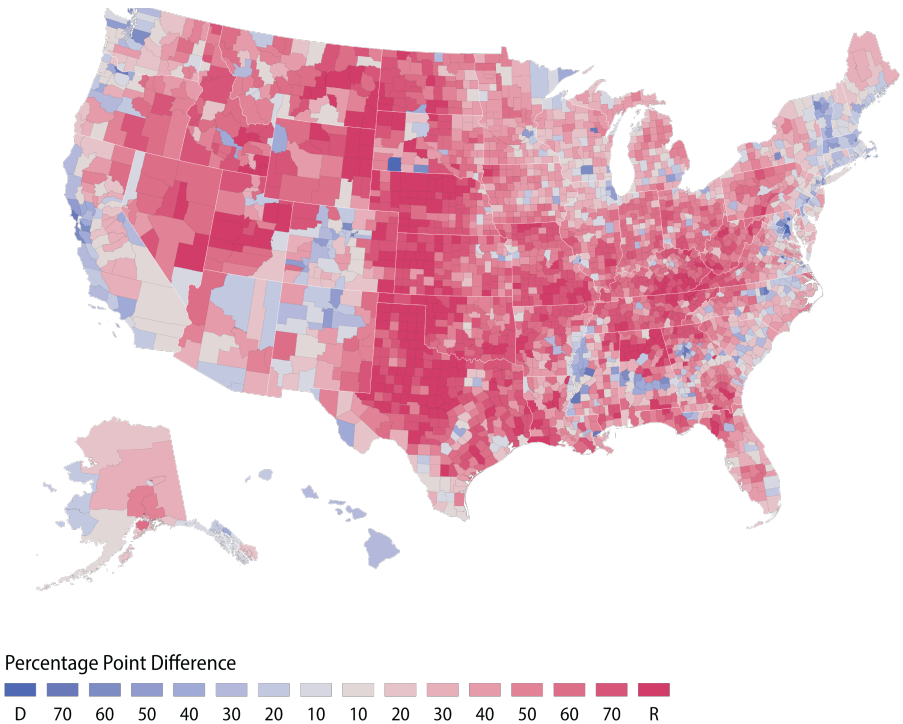

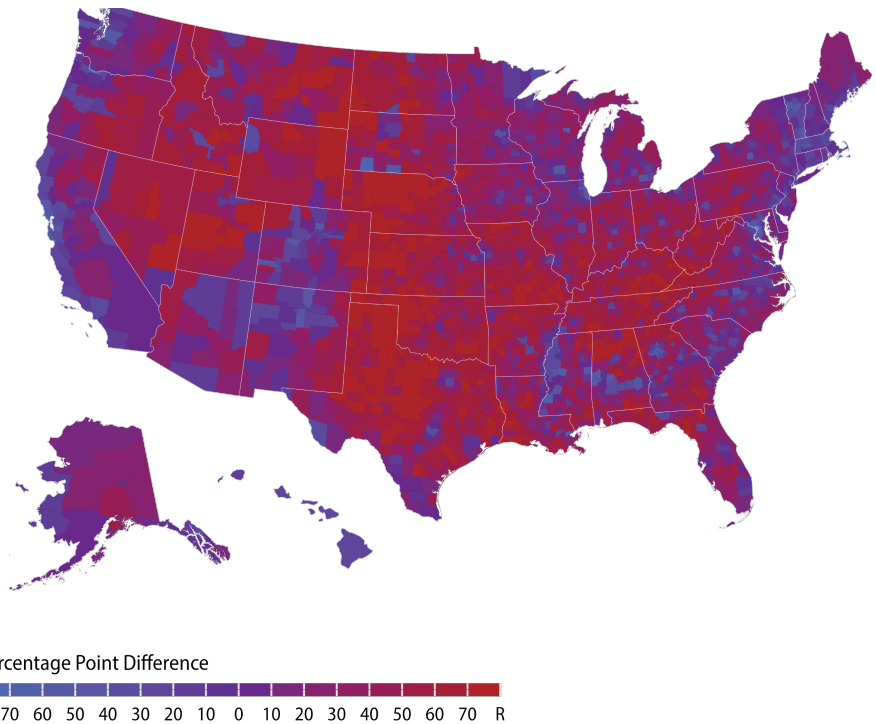

Healy, K. (2018). Data Visualization. Princeton University Press.

Exkurs | Politische Kartographie der USA

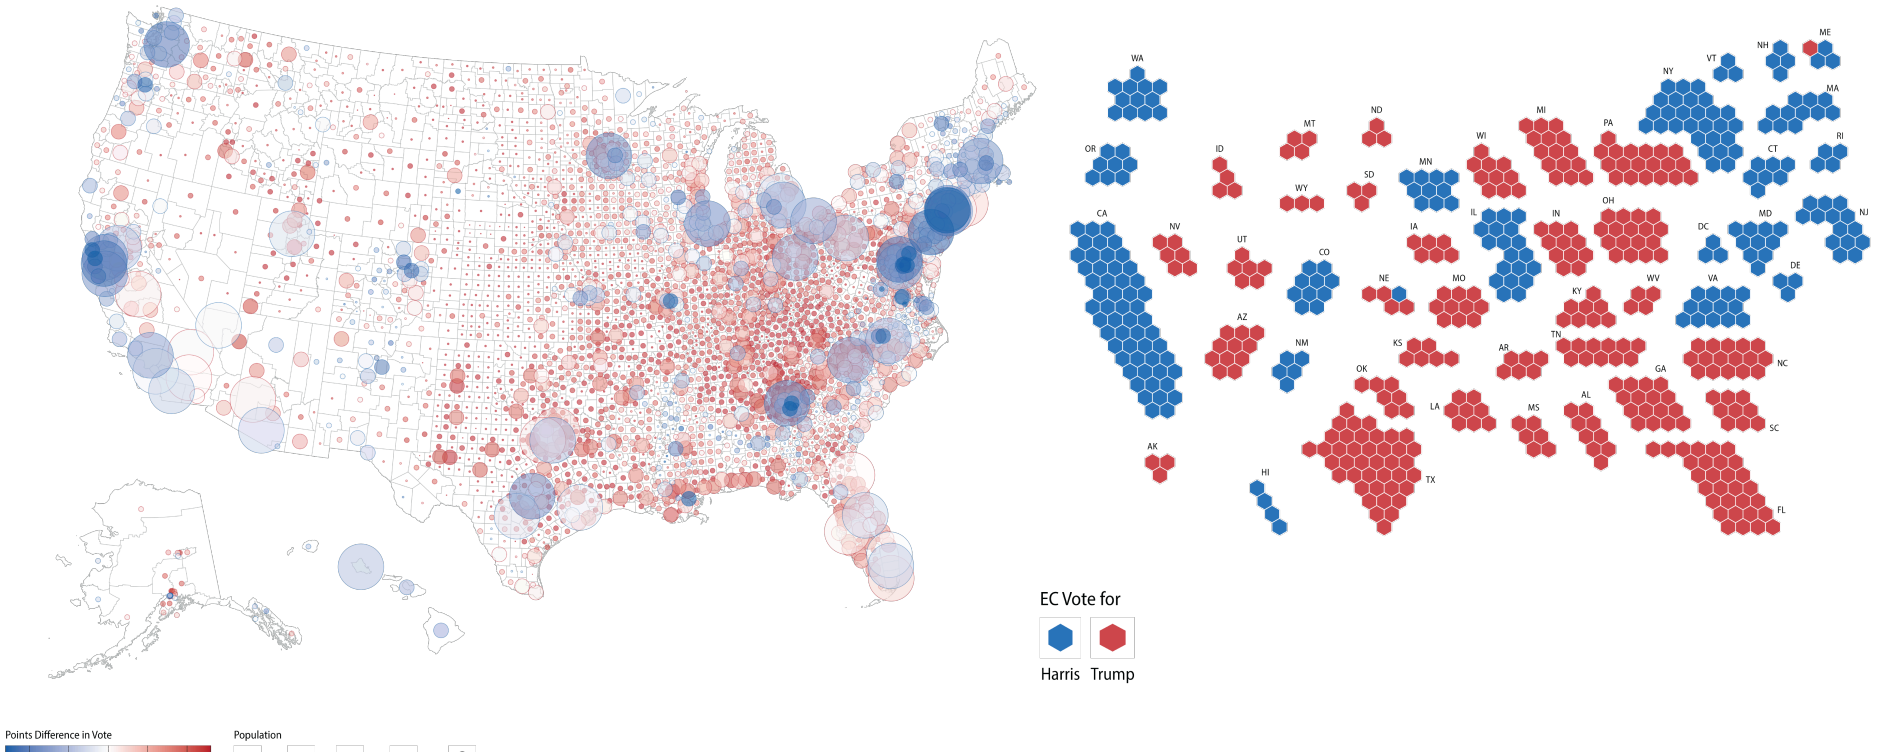

Healy, K. (2018). Data Visualization. Princeton University Press.

Geographische Themen | Stadt und Infrastruktur

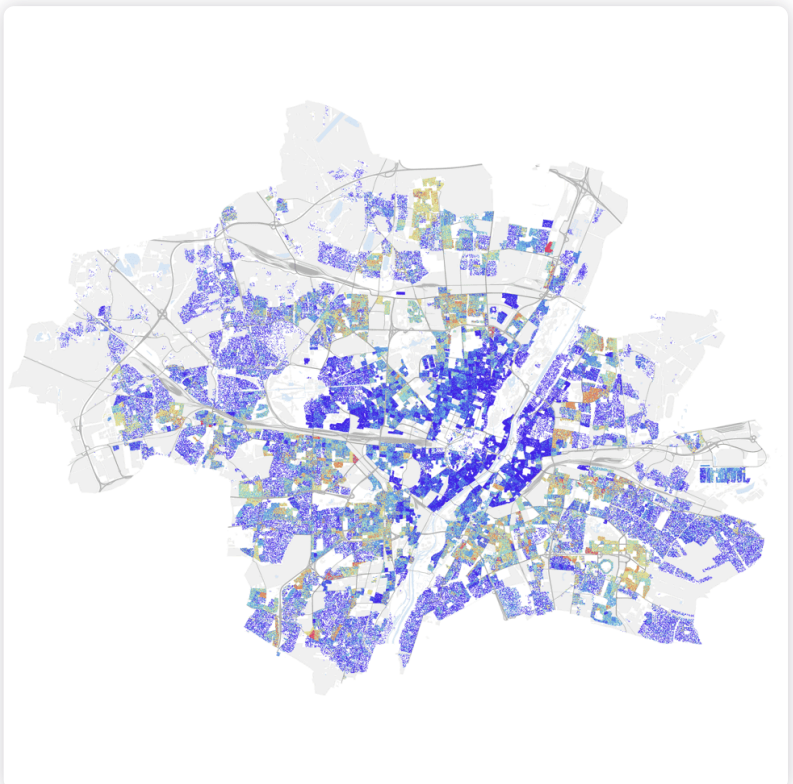

Einkommen in München (Zeit.de)

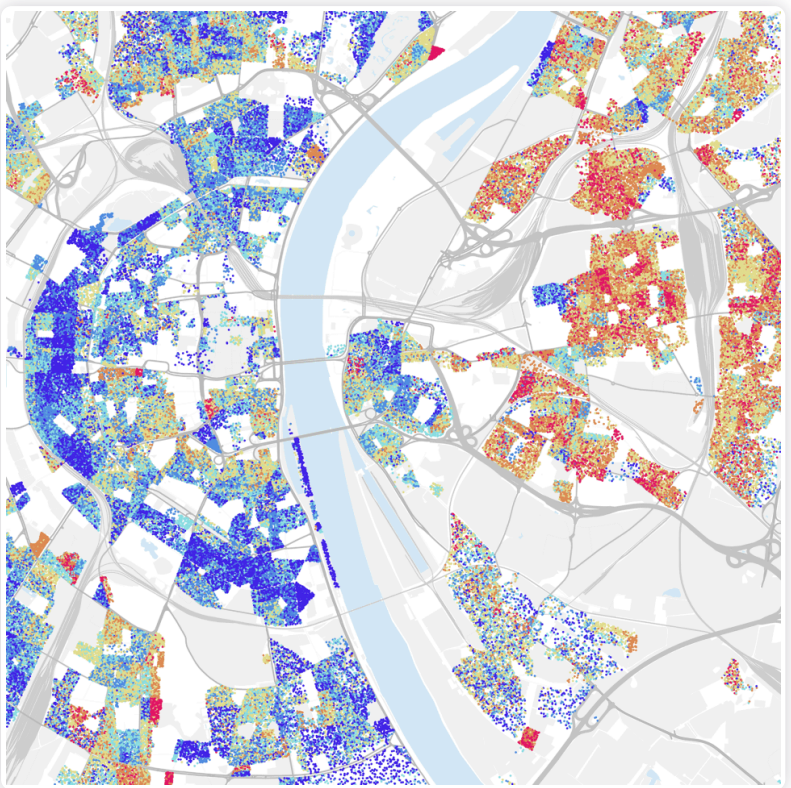

Einkommen in Köln (Zeit.de)

Geographische Themen | Stadt und Infrastruktur

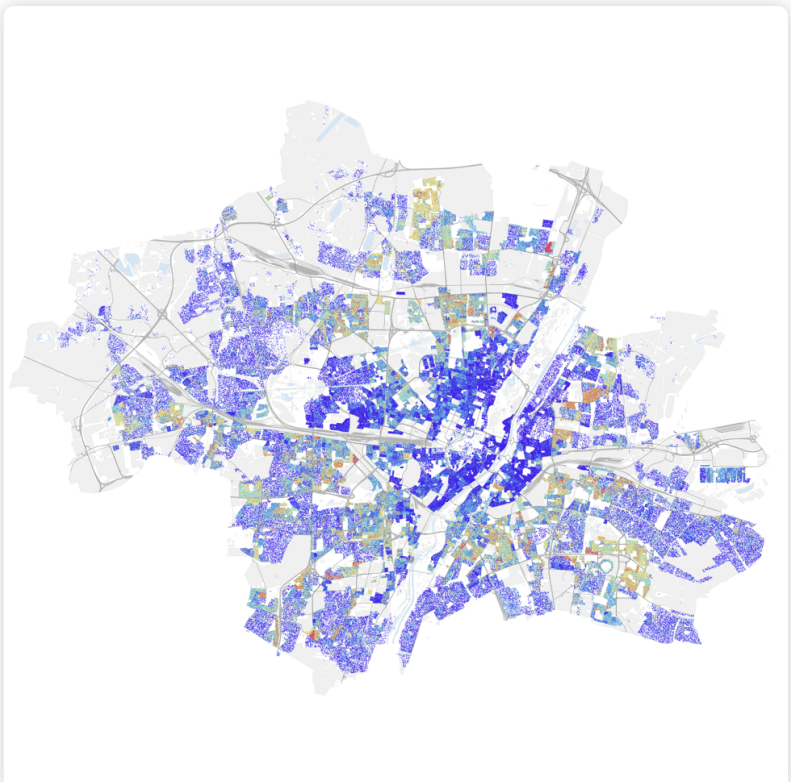

Einkommen in München (Zeit.de)

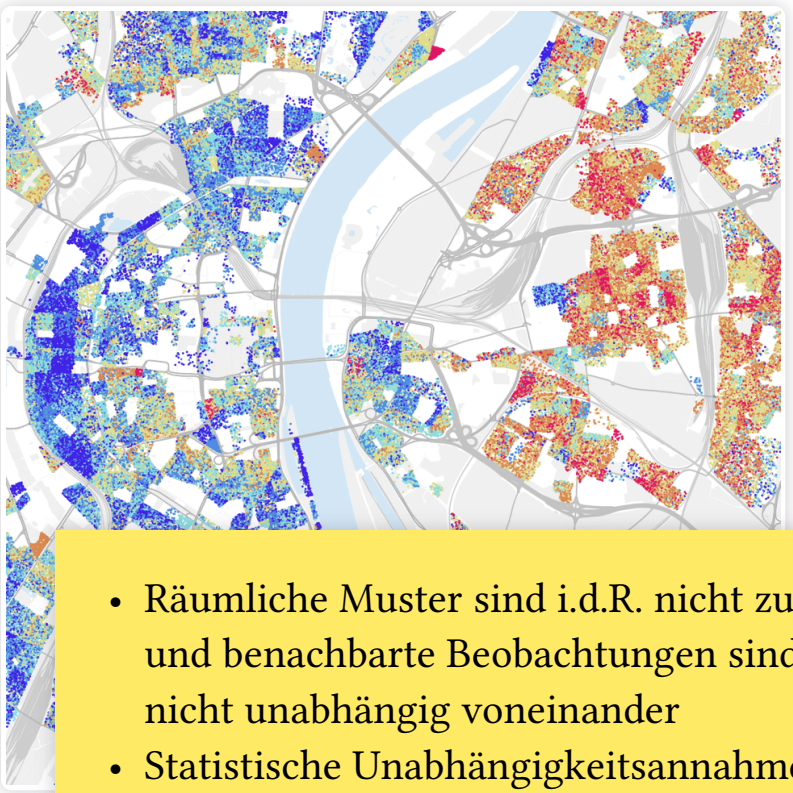

- Räumliche Muster sind i.d.R. nicht zufällig und benachbarte Beobachtungen sind oft nicht unabhängig voneinander
- Statistische Unabhängigkeitsannahmen sind bei räumlichen Daten oft verletzt

Geographische Themen | Wirtschaft und Entwicklung

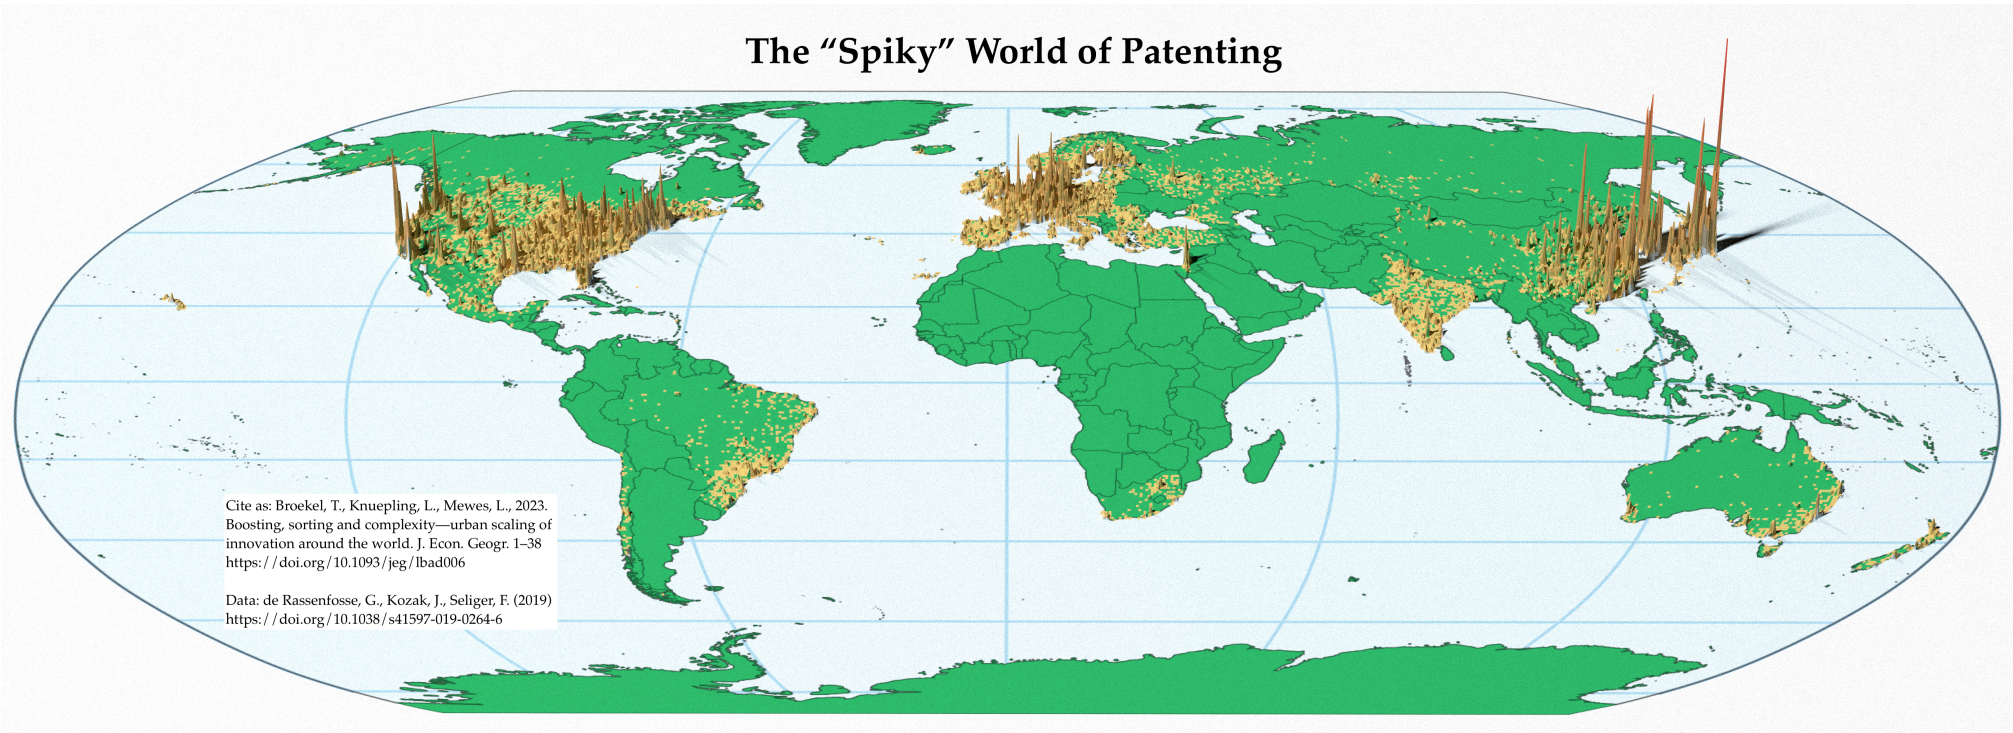

Geographische Themen | Wirtschaft und Entwicklung

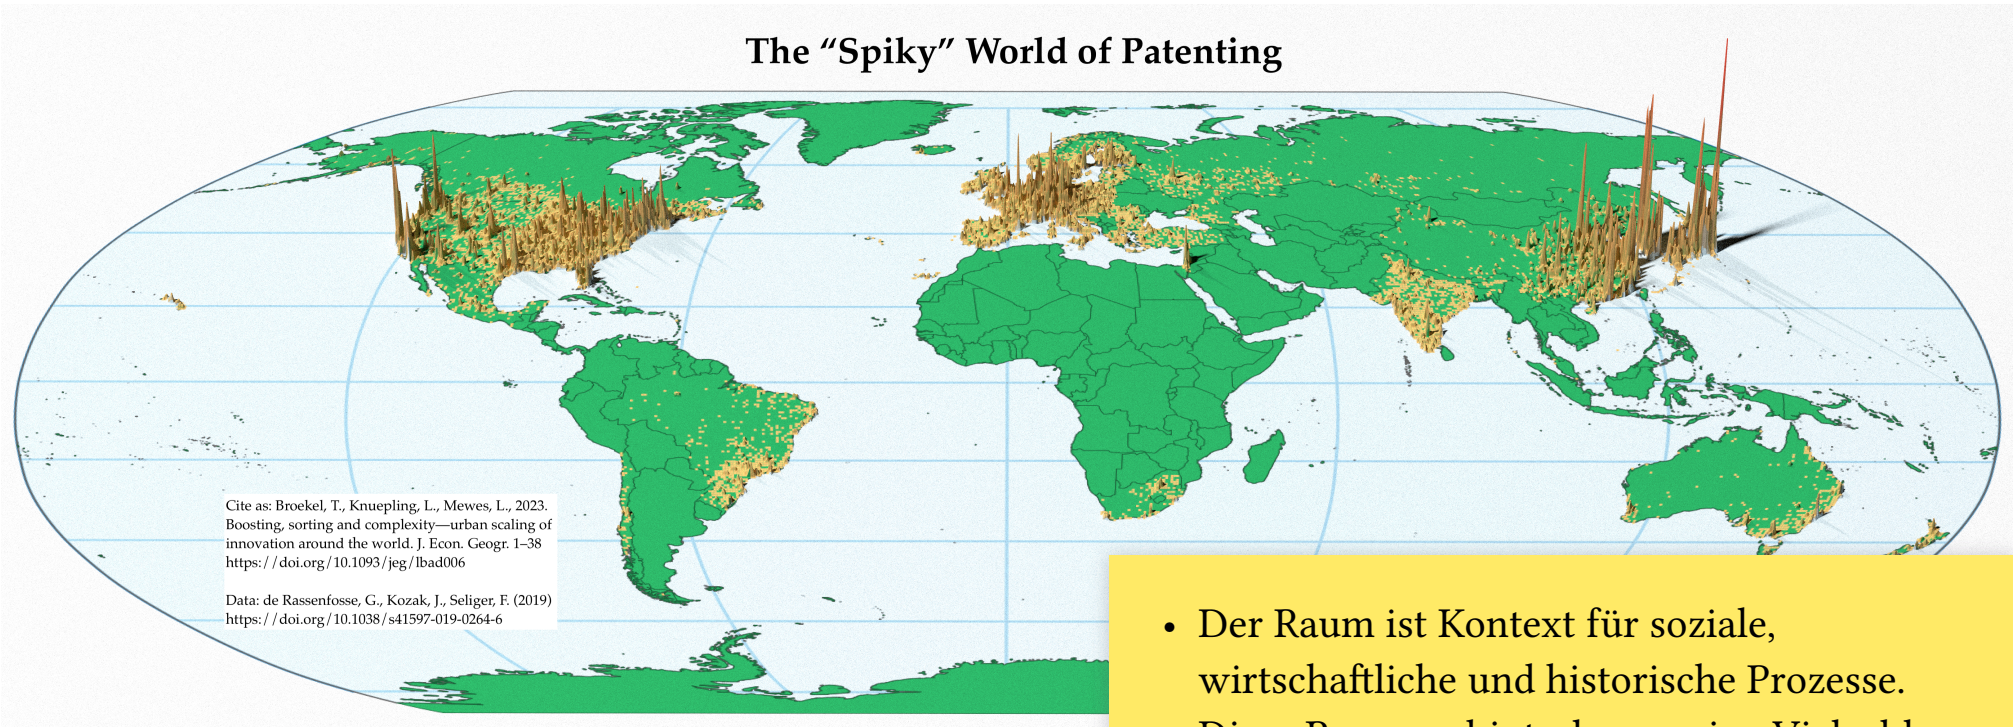

- Der Raum ist Kontext für soziale, wirtschaftliche und historische Prozesse.
- Diese Prozesse hinterlassen eine Vielzahl an oft kontextabhängigen „Datenspuren“ die oft schwer vergleichbar sind.

Geographische Themen | Klimawandel und Anpassung

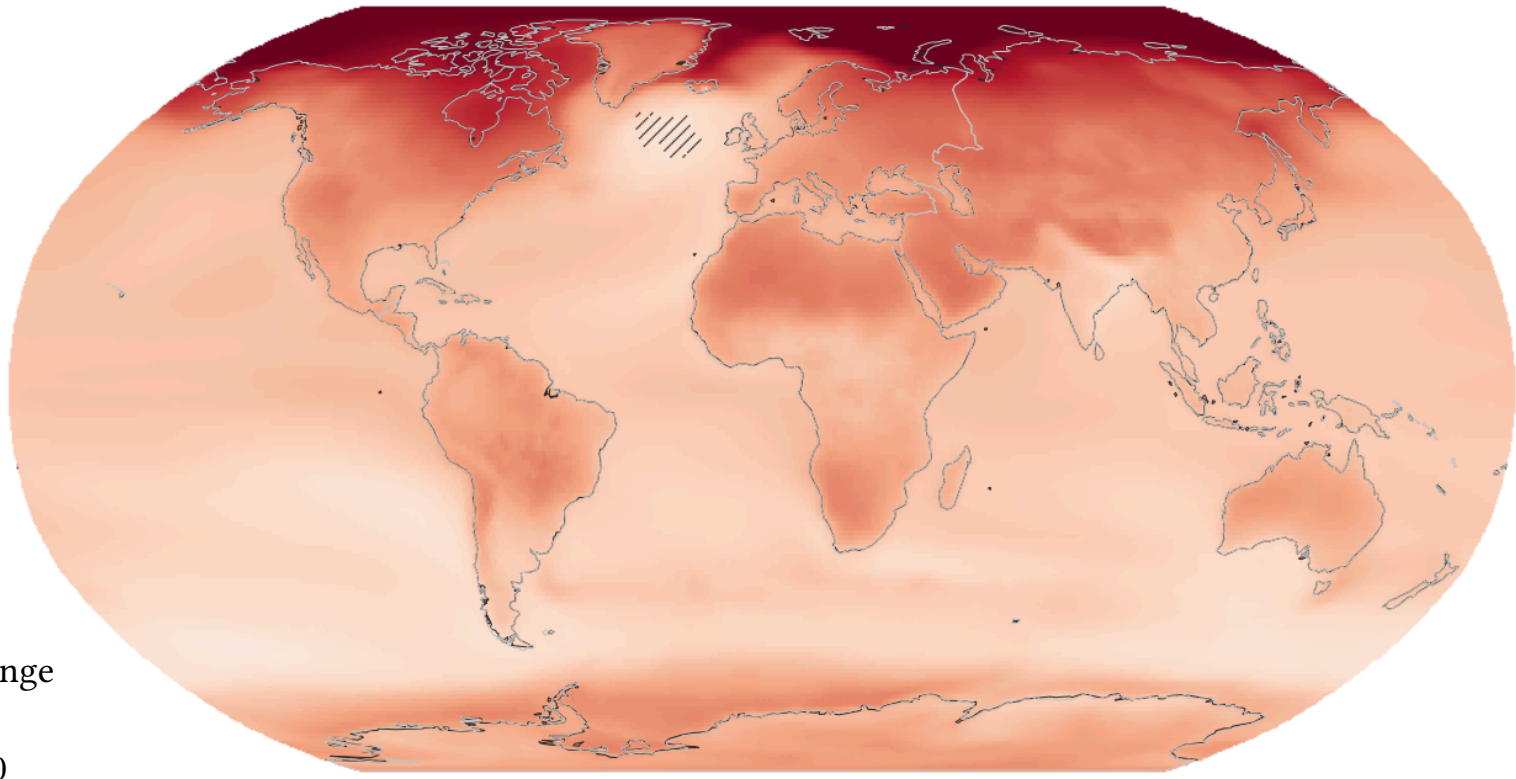

CMIP6
mean temp. change
at 2°C warming
rel. to 1850-1900

Geographische Themen | Klimawandel und Anpassung

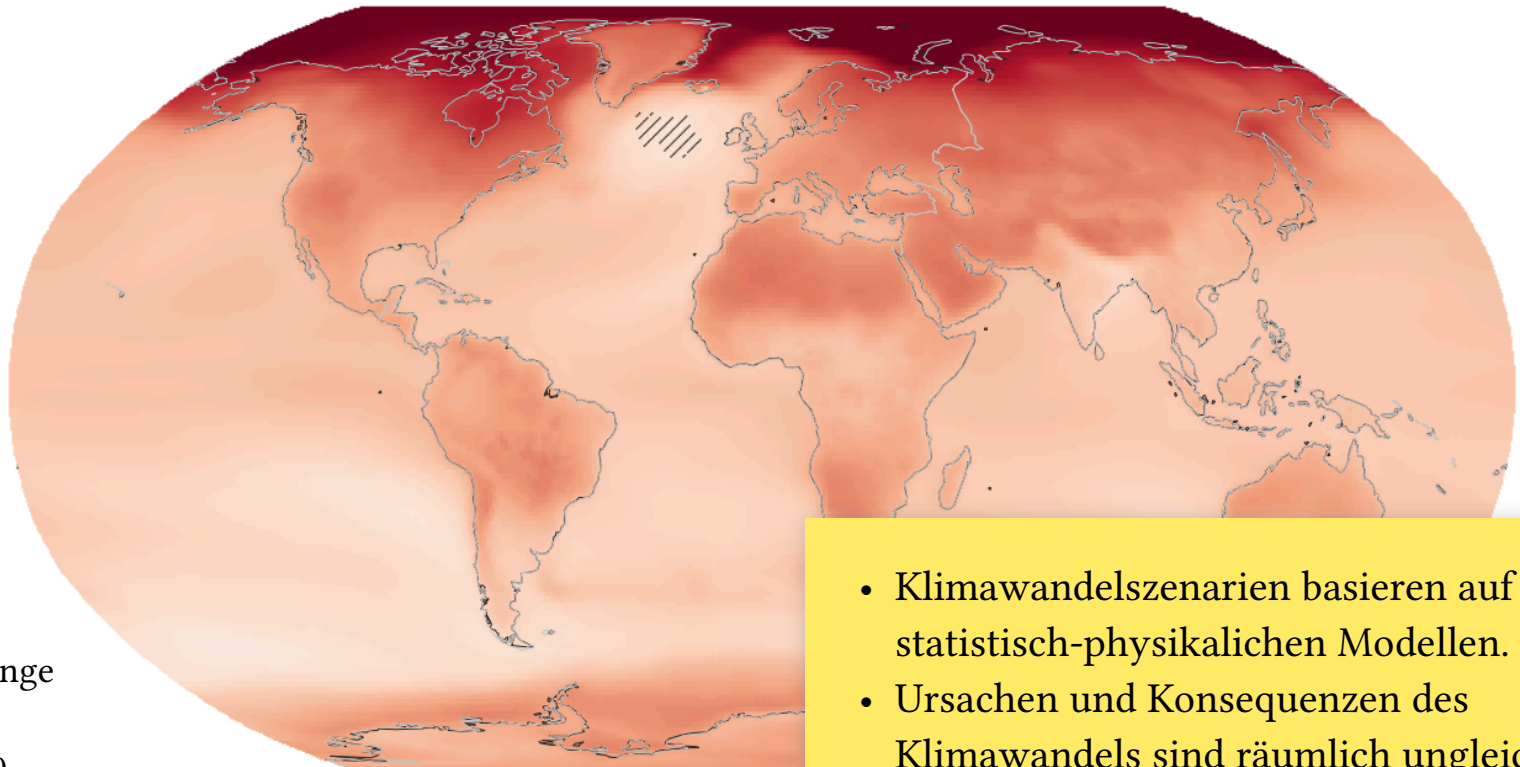

CMIP6
mean temp. change
at 2°C warming
rel. to 1850-1900

- Klimawandelszenarien basieren auf komplexen statistisch-physikalichen Modellen.
- Ursachen und Konsequenzen des Klimawandels sind räumlich ungleich verteilt.

https://interactive-atlas.ipcc.ch/regional-information

Inhalte der Vorlesung

Themenüberblick

1 Deskriptive Statistik (W1-4)

- *Verteilungen* beschreiben und visualisieren
- *Zusammenhänge* beschreiben und visualisieren

2 Kausale Inferenz (W5-7)

- Experimente
- Beobachtungsstudien
- Identifikation von Interventionseffekten

3 Statistische Unsicherheit (W8-10)

- Stochastische Modelle
- Schätzunsicherheit
- Bayesianische Inferenz

4 Geographische Analysen (W11-12)

- Ökologische Analysen und Fehlschlüsse
- Räumliche Autokorrelation

Übung zur Vorlesung

- Ein erheblicher Teil statistischer Praxis liegt in der Aufbereitung von Daten. Die Übung macht Studierende mit der Anwendung statistischer Verfahren *und* dem Umgang mit Daten vertraut.
- Der Besuch der Übung ist nicht optional - nur die Vorlesung zu besuchen ist so sinnvoll wie ein Führerschein ohne Fahrpraxis.
- Geographen setzen auf eine Vielzahl an Softwaretools (z.B. Spezialsoftware wie `SPSS` oder Programmiersprachen wie `R`, `Python` oder `Julia`).

Moodle zur Vorlesung

Name | Einführung in die Statisitk 26/27

Passwort | statistik2026

Die Folien werden Montags vor der Sitzung hochgeladen

Leistungsnachweis

Welche der folgenden Aussagen ist richtig? Bei einer rechtsschiefen Verteilung ist der Median…

- [x] immer kleiner als das arithmetische Mittel
- [ ] immer größer als das arithmetische Mittel
- [ ] immer gleich groß wie das arithmetische Mittel
- [ ] mal größer und mal kleiner als das arithmetische Mittel

- Die Vorlesung wird durch eine **Klausur** am letzten Vorlesungstermin (Ende Januar) abgeschlossen.
- Die Klausur prüft Kenntnisse der **Vorlesungs- und der Übungsinhalte** mittels eines Multiple-Choice-Verfahrens.
- Multiple-Choice: Auswahlverfahren, bei dem **mindestens eine** Option richtig ist.

Lernmaterialien

Lehrbuch in deutscher Sprache

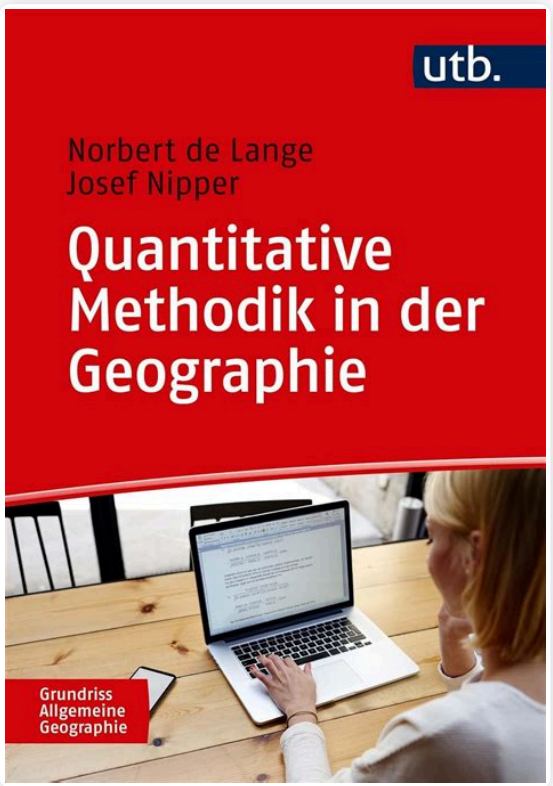

- Lehrbuch in deutscher Sprache
- Fachbezug zur Geographie
- Breite Abdeckung der Grundlagen
- Nachschlagwerk für Verfahren

Datenvisualisierung

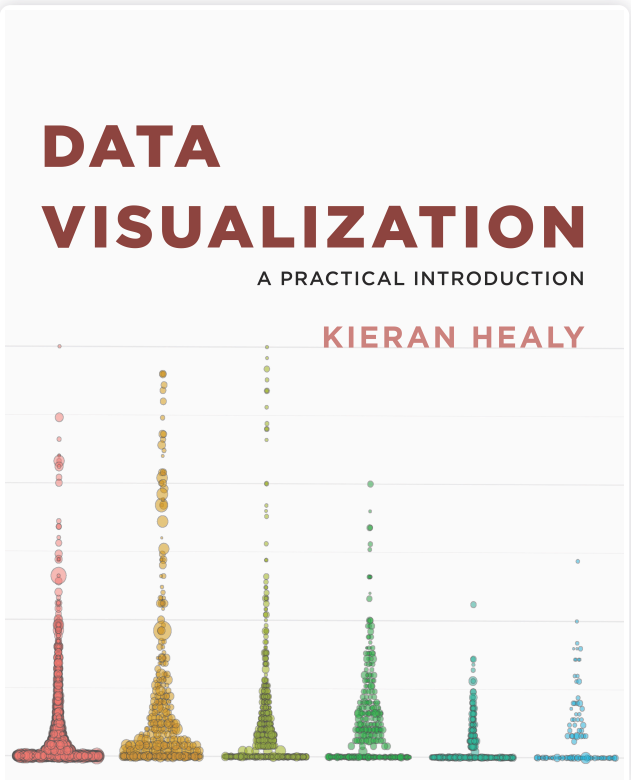

- Einführung in die statistische Visualisierung mit R
- Viele sozialwissenschaftliche Beispiele
- Online verfügbar unter: https://socviz.co/

Regressionsanalyse

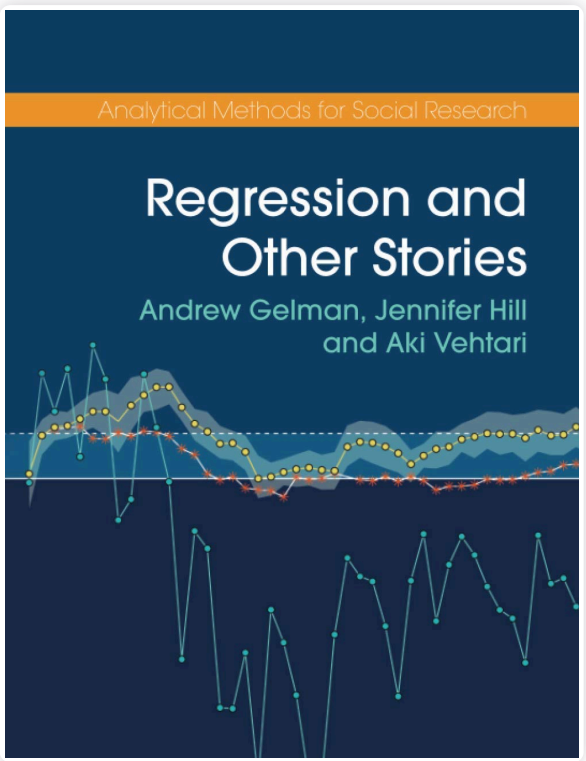

- Umfassende und moderne Einführung in die Regressionsanalyse
- Viele sozial- und politikwissenschaftliche Anwendungsbeispiele in R
- Online verfügbar unter: https://avehtari.github.io/ROS-Examples/

Statistische Modellierung

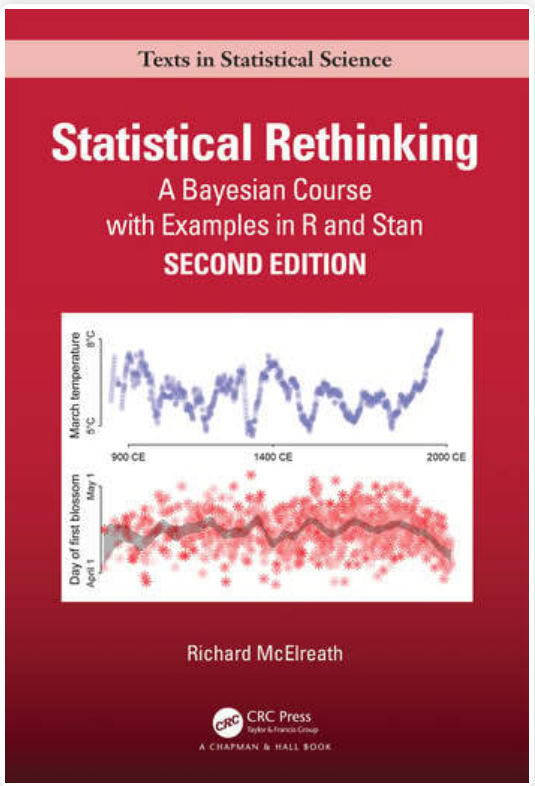

- Moderne perspektive auf statistische Modellierung
- Bayesianische Statistik, Anwendung in R
- Online verfügbar unter: https://xcelab.net/rm/

Wahrscheinlichkeitstheorie

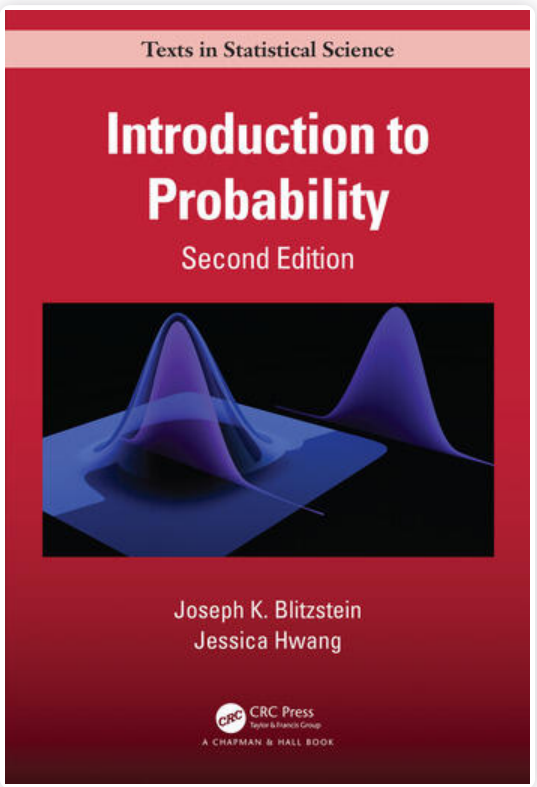

- Umfassende aber zugängliche Einführung in die Wahrscheinlichkeitstheorie
- Anwendungsbeispiele in R
- Online verfügbar unter: https://projects.iq.harvard.edu/stat110/home

Prüfungsfragen

Prüfungsfragen

- Unter welchen Umständen kann selbst eine große Stichprobe in die Irre führen?
- Was ist das GIGO-Prinzip und warum ist es für die statistische Argumentation wichtig?
- Was ist bei vergleichen, die einen kausalen Zusammenhang demonstrieren sollen, zu berücksichtigen?
- Welche Probleme können bei räumlichen Daten auftreten?