Einführung in die Statistik

Deskriptive Statistik I

Dr. Jakob Hoffmann

Economic Geography Group, Department für Geographie

Ludwig-Maximilians-Universität, München

Ziele und Herausforderungen quantitativer Forschung

1 Beschreiben

- Beschreibung der Variation eines Phänomens in einer Zielpopulation
- Vergleiche zwischen Subpopulationen
- Gemeinsame Verteilung von Merkmalen

Validität: Messen die Daten die gewünschten theoretischen Konstrukte?

Repräsentativität: Beschreiben die Daten die gewünschte Population unverzerrt?

2 Erklären

- Statistische Identifikation von theoretisch plausiblen kausalen Effekten
- Kontrafaktische Vergleiche
- Abwägung von alternativen Erklärungen

Identifikation: Kann der Ergebnisunterschied der Intervention zugeschrieben werden?

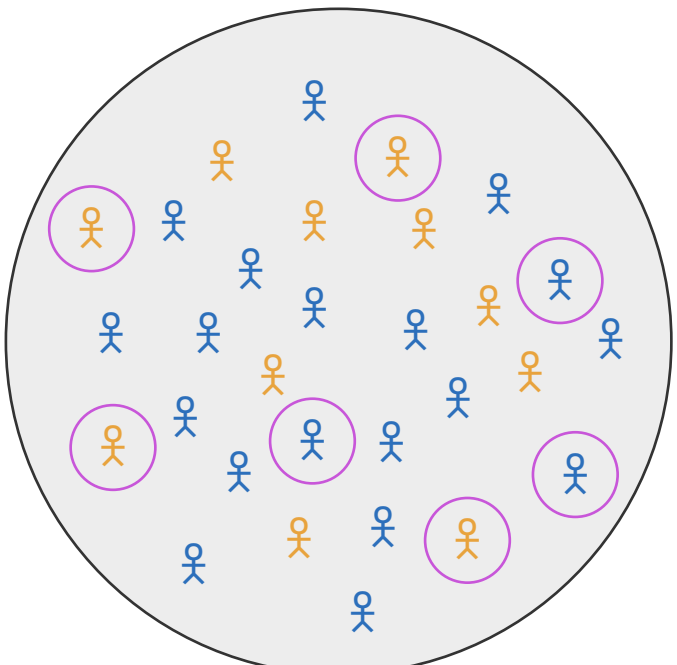
Robustheit: Wie abhängig ist das Ergebnis von der gewählten Methode?

Was ist deskriptive Statistik (nicht)?

- **Ist:** Beschreibung der *Verteilungseigenschaften* bestimmter *Merkmale* in einer *Population* (quantitative Beschreibung)
- **Ist nicht:** Individuenspezifische Beschreibung einzelner *Merkmalsträger* oder Beobachtungen (qualitiative Beschreibung)
- **Ist nicht:** Überprüfung kausaler Effekte (Erklärung nicht Beschreibung)

- **Merkmalsträger** (Beobachtung) · *Untersuchungseinheit* : z.B. Studierende/r
- **Merkmal** (Variable) · *Messgröße* : z.B. Note
- **Merkmalsausprägung** · *Wert einer Messgröße* : z.B. 0 – 15 Punkte

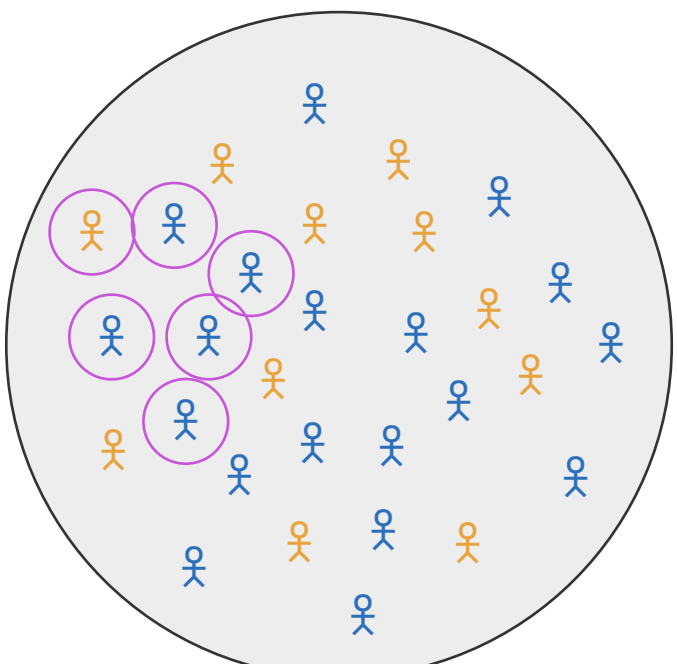
Was soll beschrieben werden?



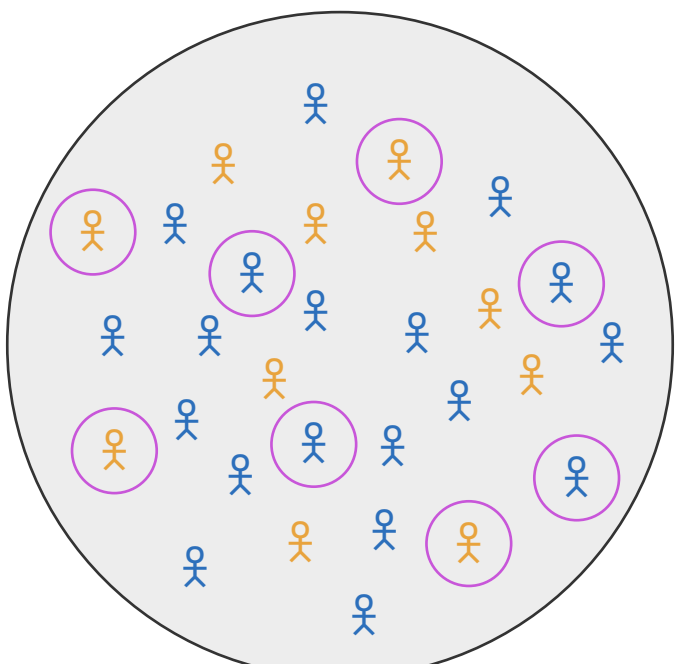
- Vollerhebungen, die eine *Population* in ihrer Gesamtheit erfassen, sind oft nicht machbar.
- Stattdessen werden *Stichproben* (Teilmengen der Population) gezogen.
- Eine Stichprobe sollte *repräsentativ* sein, d.h. sie sollte relevante Verteilungseigenschaften der Population teilen.
- Zufallsauswahl ist der einfachste Weg statistische Repräsentativität zu gewährleisten.

Repräsentative Stichproben

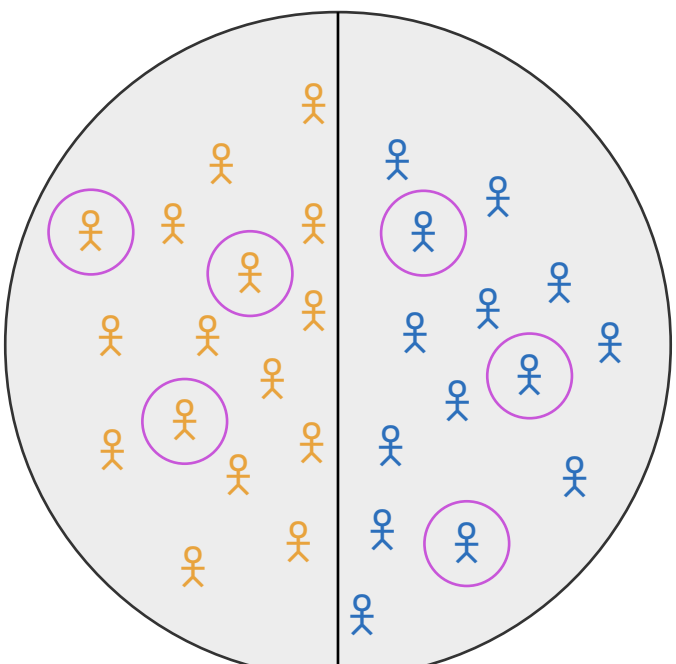
Selektiv ✖



Zufällig ✔



Stratifiziert ✔



Herausforderungen

- Population muss für Zufallsauswahl zugänglich sein
- Selektives Antwortverhalten kann Repräsentativität gefährden
- Kleine Teilgruppen können bei Zufallsauswahl übersehen werden (s. *stratifizierte* Stichproben, die Beobachtungszahlen für Teilgruppen vorgeben)
- Zufallsauswahl induziert statistische Unsicherheit, die quantifiziert werden muss
- Population ist nicht immer klar definiert (z.B. Fallstudien) oder ist unendlich groß (z.B. wiederholbares Experiment)

Datenformate und Datentypen

Datenformate

Name	Fach	Semester
Denise	Physik	6
Daniel	Geographie	3
Klara	Geographie	1
Yannick	BWL	3

Beobachtungen



Variablen

- Daten sind eine strukturierte Repräsentation von Information
- Geläufigste Struktur: Tabellarische Anordnung von Beobachtungen (Zeilen) und Variablen (Spalten)

Datenformate

Land	Jahr	Wert
USA	2000	12.8
USA	2001	13.3
USA	2002	12.2
USA	…	…
FRA	2000	9.2
FRA	2001	8.7
…	…	…

Long format

Jahr	USA	FRA	…
2000	12.8	9.2	
2001	13.3	8.7	
2002	12.2	…	
…	…	…	

Wide format

- Daten sind eine strukturierte Repräsentation von Information
- Geläufigste Struktur: Tabellarische Anordnung von Beobachtungen (Zeilen) und Variablen (Spalten)
- Es gibt unterschiedliche tabellarische Datenformate (long- vs. wide-format)
- Es gibt viele nicht-tabellarische Datenformate (z.B. hierarchische Formate, unstrukturierte Daten wie Text oder Bild)

Datentypen und -qualitäten

Numerisch

Diskret · *abzählbar*

- Personen in Haushalt, Tore im Fußball

Kontinuierlich · *überabzählbar*

- Niederschlag, Temperatur

Kategorisch

Nominal · *ungeordnet*

- Geschlecht, Studiengang

Ordinal · *geordnet*

- Bildungsabschluss, Likert-Rating

Skalierungsunterschiede numerischer Variablen

- Intervallskala · *kein natürlicher Nullpunkt* : Jahr, Temperatur in Celsius
- Verhältnisskala · *natürlicher Nullpunkt* : Alter, Temperatur in Kelvin

Beispiele



Quizz

Datentypen

Fallstudie | Brexit-Referendum

Wer unterstützte den Brexit?

- Am 23. Juni 2016 stimmte eine knappe Mehrheit der britischen Wähler (51.9%) für den Austritt aus der EU.
- Im Vorlauf des Referendums hat die *British Election Study* eine große repräsentative Befragung durchgeführt (Beispiel aus Llaudet & Imai, *Data Analysis for Social Science*, Kap. 3).
- Frage: Wie unterscheiden sich Unterstützer und Gegner des Brexit?

Überblick der Daten

vote	leave	education	age
leave	1	3	60
leave	1	NA	56
stay	0	5	73
leave	1	4	64
don’t know	NA	2	68
…	…	…	…

- **Beobachtungen:** 30 895 Befragte (Zeilen)
- **Variablen** (Spalten):
  - `vote` · *kategorisch, nominal*
  - `leave` · *dummy von `vote`*
  - `education` · *kategorisch, ordinal*
  - `age` · *numerisch, diskret*
- `NA` markiert **fehlende Werte**
- Die Variable `education` nutzt numerische Werte die aber *kategorische* Ausprägungen repräsentieren.

Verteilungen kategorischer Variablen

Häufigkeitstabellen

Eine *Häufigkeitstabelle* ist eine einfache univariate Zusammenfassung, die zählt wie oft jede Ausprägung einer kategorischen Variable vorkommt.

`vote`

Ausprägung	Häufigkeit
leave	13 692
stay	14 352
don’t know	2 314
won’t vote	537

`education`

Ausprägung	Häufigkeit
1 Keine Qualifikation	2 045
2 GCSE	5 781
3 A-Level	6 272
4 Bachelor	10 676
5 Master/PhD	2 696
NA	3 425

Relative Häufigkeiten

vote	absolut	relativ
leave	13 692	44.3%
stay	14 352	46.5%
don't know	2 314	7.5%
won't vote	537	1.7%
Gesamt (n)	30 895	100%

- Die **relative Häufigkeit** der Ausprägung k ist der Anteil aller n Beobachtungen mit Ausprägung k:

$$p_k = \frac{n_k}{n} \cdot 100$$

- Absolute Zahlen sind abhängig vom Stichprobenumfang, relative Zahlen sind vergleichbar (z.B. mit dem Referendumsergebnis).

Fehlende Werte und selektives Antwortverhalten

- Von 30 895 Befragten haben 25 097 sowohl ein eindeutiges Wahlverhalten (`leave`) als auch ihren Bildungsabschluss (`education`) angegeben (11 843 Leave (47.2%) und 13 254 Remain (52.8%)).
- Wenn Personen mit bestimmten Eigenschaften (z.B. Alter) dazu tendieren, die Angabe zu verweigern, liegt ein Selektionsproblem vor (*non-response bias*).
- Die Analyse der *vollständigen* Beobachtungen erlaubt nur unter der Annahme *zufälliger* fehlender Werte (MCAR, missing completely at random) oder unter statistischer Modellierung des Selektionsprozesses unverfälschte Inferenzen.

Multivariate Häufigkeiten

Absolute Häufigkeiten

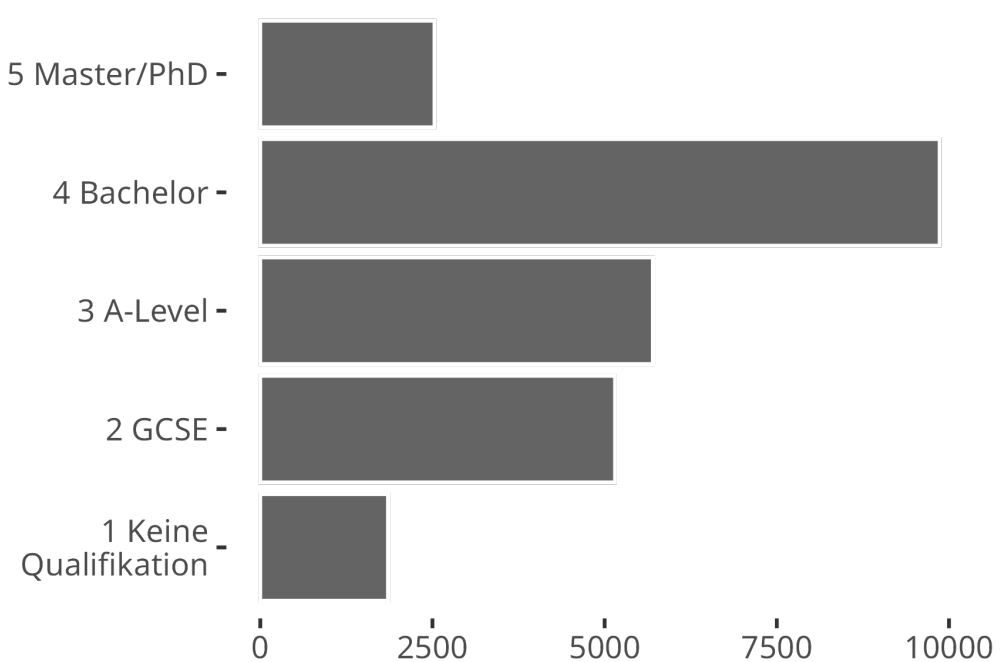
	1	2	3	4	5
Remain	498	1 763	3 014	6 081	1 898
Leave	1 356	3 388	2 685	3 783	631

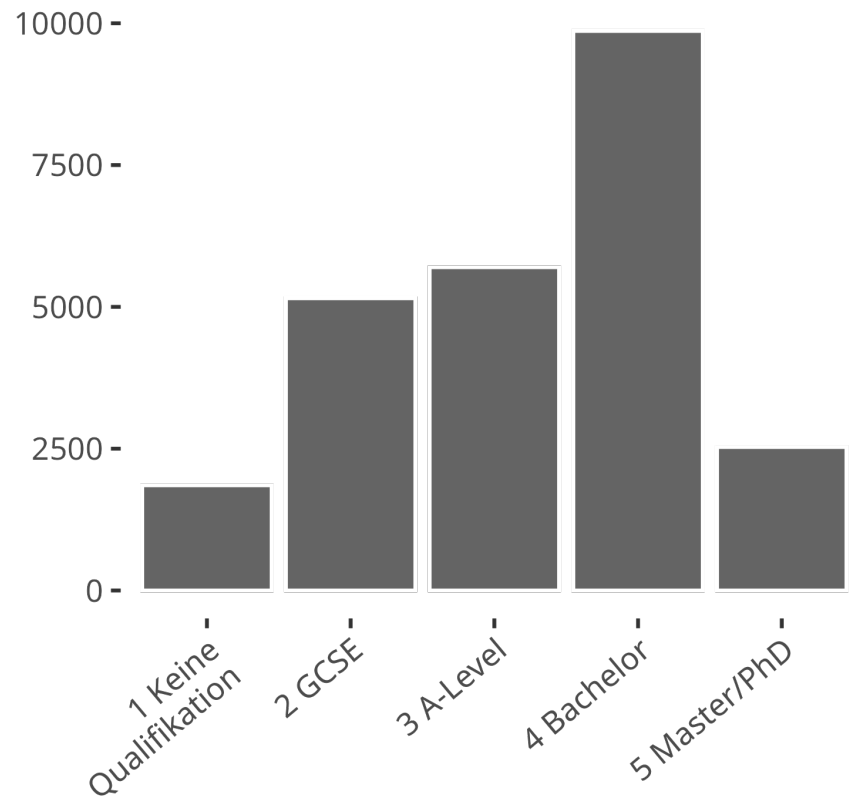
Anteile nach Bildungsniveau

	1	2	3	4	5
Remain	27%	34%	53%	62%	75%
Leave	73%	66%	47%	38%	25%

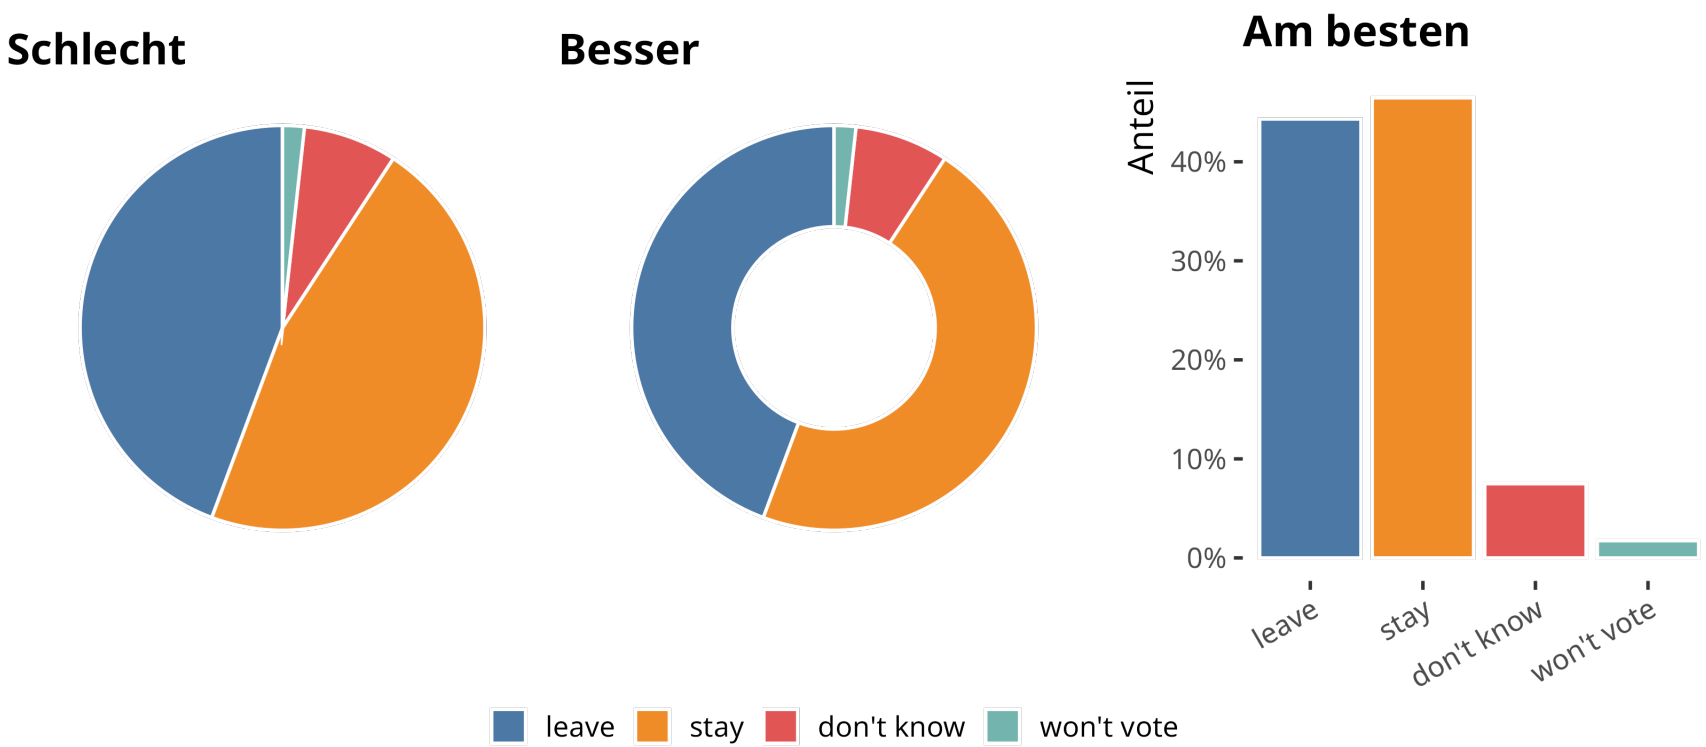
- Bivariate Häufigkeitstabellen zählen *Kombinationen* von Ausprägungen zweier Variablen.
- Relative Häufigkeiten können als Anteile von Reihen- oder Spaltensummen berechnet werden (hier: Spalten) und eignen sich für Vergleiche zwischen Gruppen.
- **Vorsicht:** Ein statistisches Muster beschreibt nicht notwendigerweise einen *kausalen* Zusammenhang. Bildung hängt z.B. mit Alter, Einkommen und Wohnort zusammen, die die Abstimmung ebenfalls beeinflussen können.

Säulendiagramme

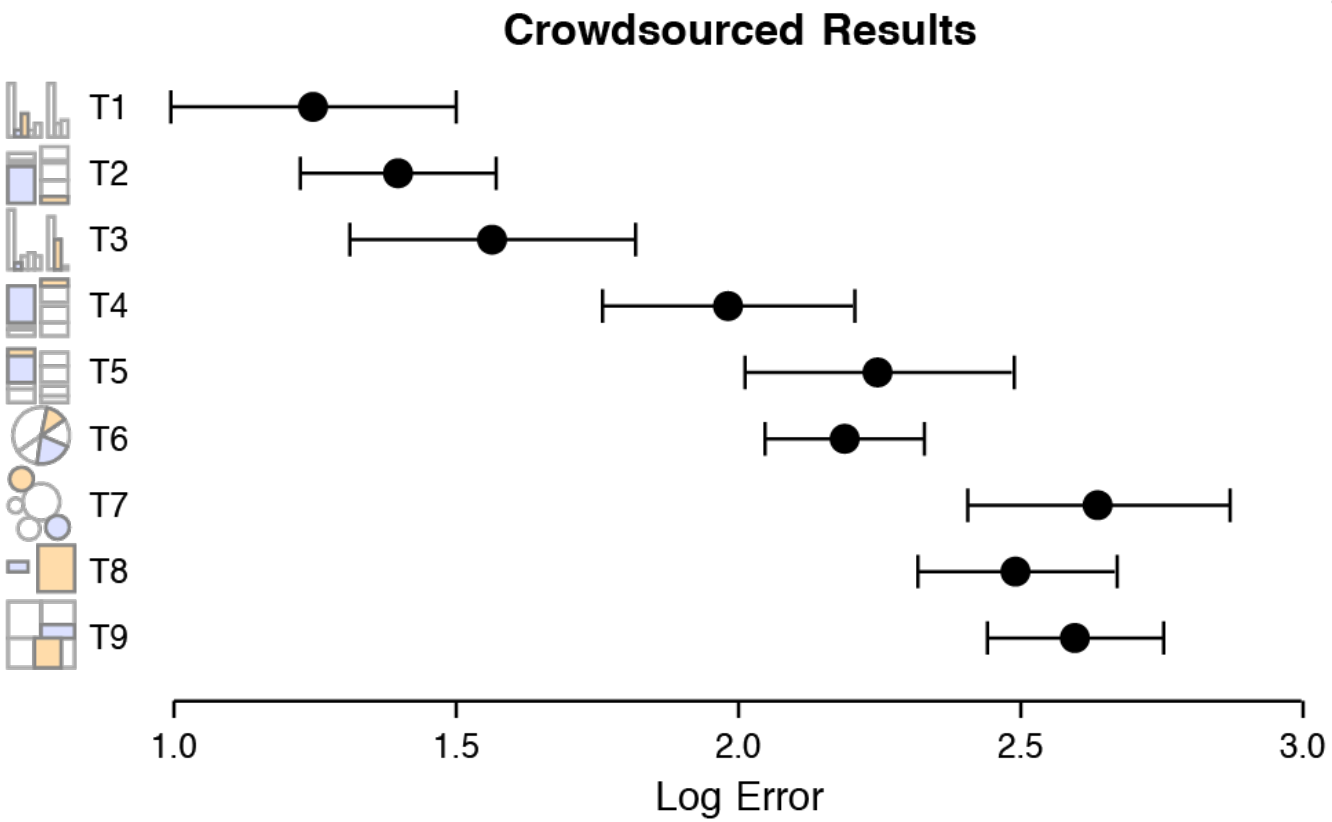




Kreisdiagramme



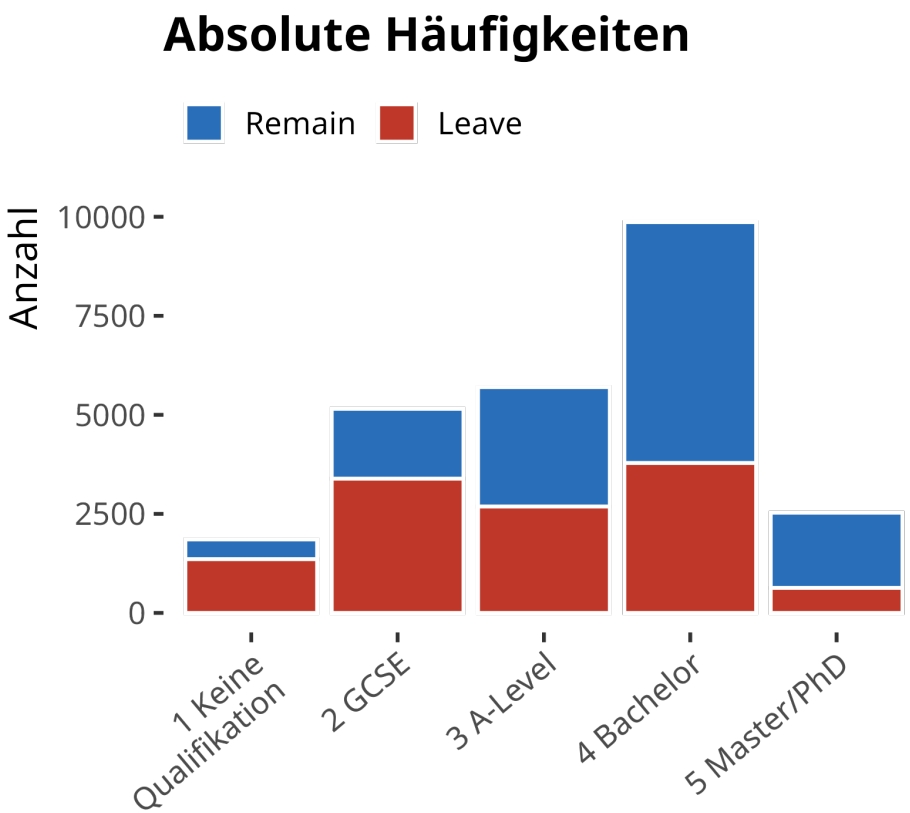
Balken sind am einfachsten zu interpretieren

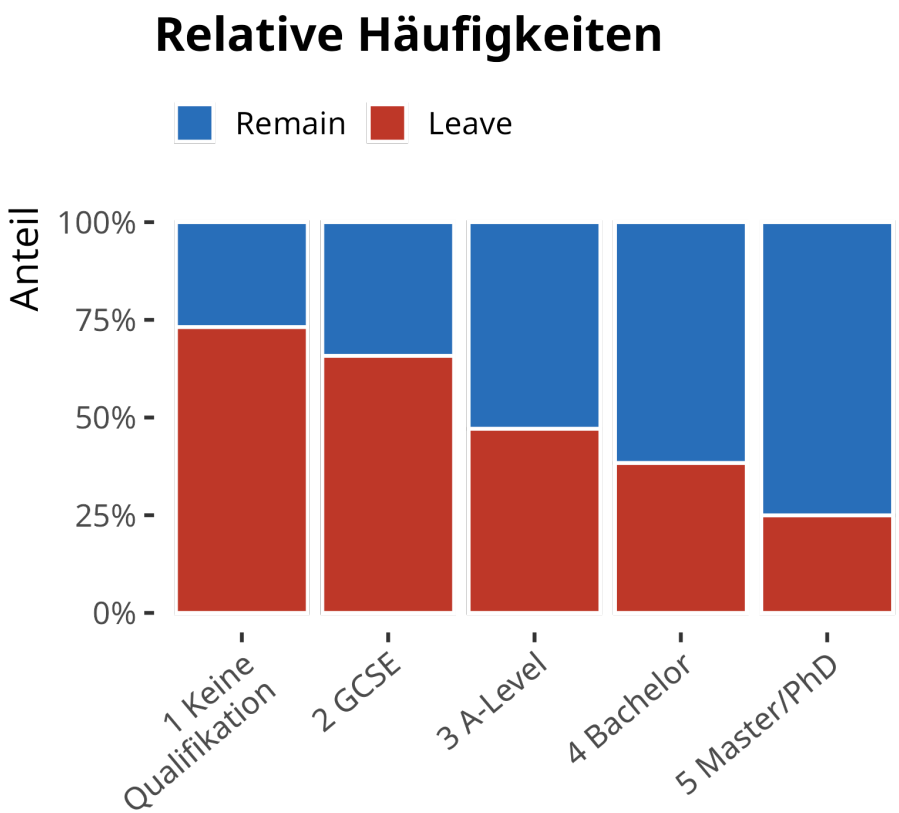


- Studien zur visuellen Vergleichbarkeit von Längen, Winkeln und Flächen zeigen einen eindeutigen Vorteil von (gleich verankerten) Längen.

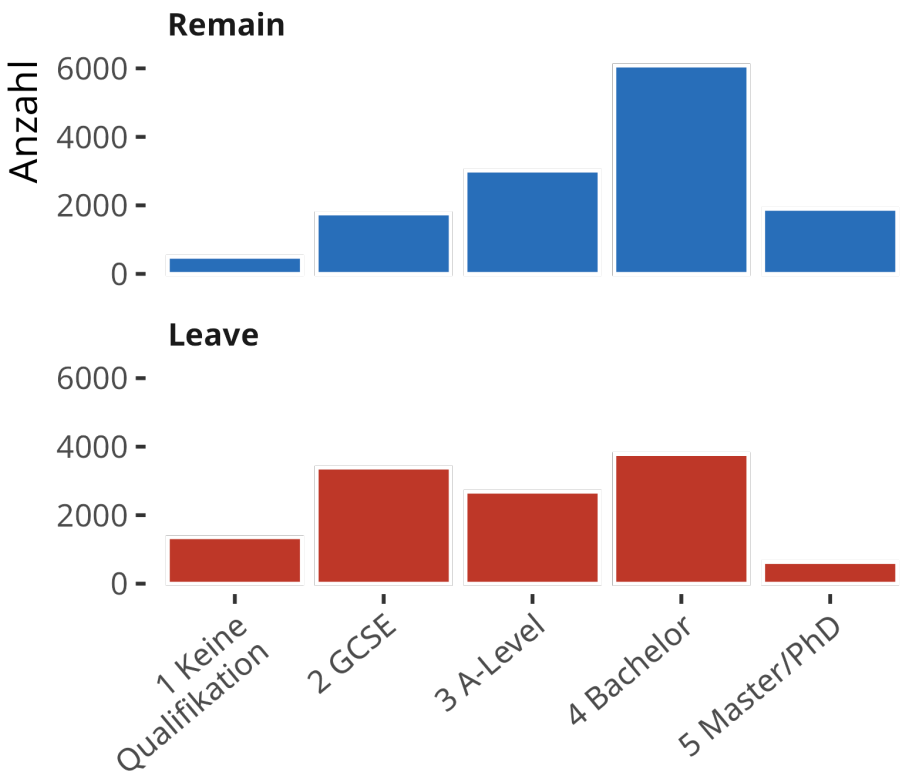
Heer, J., & Bostock, M. (2010). Crowdsourcing graphical perception: Using mechanical turk to assess visualization design. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems, CHI '10, 203–212.

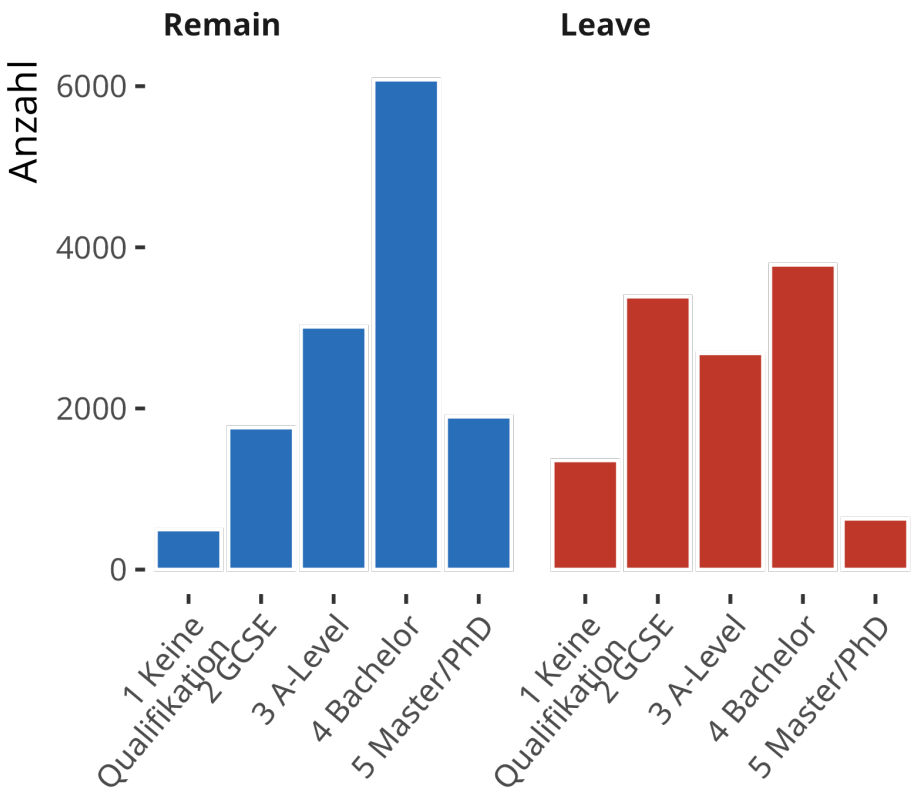
Säulendiagramme | Multivariate Vergleiche



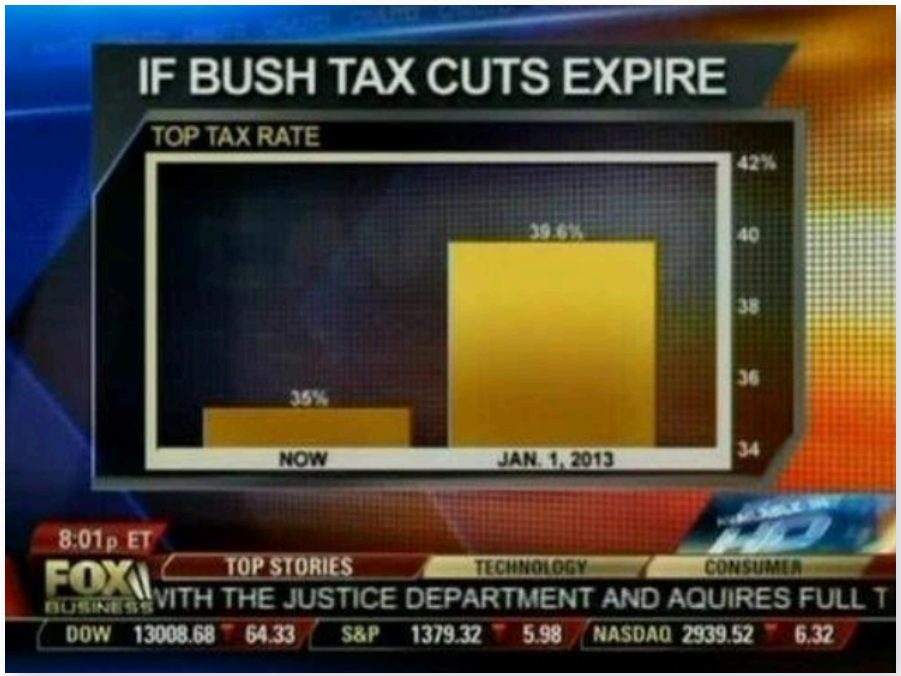


Säulendiagramme | Facettierung und Anordnung



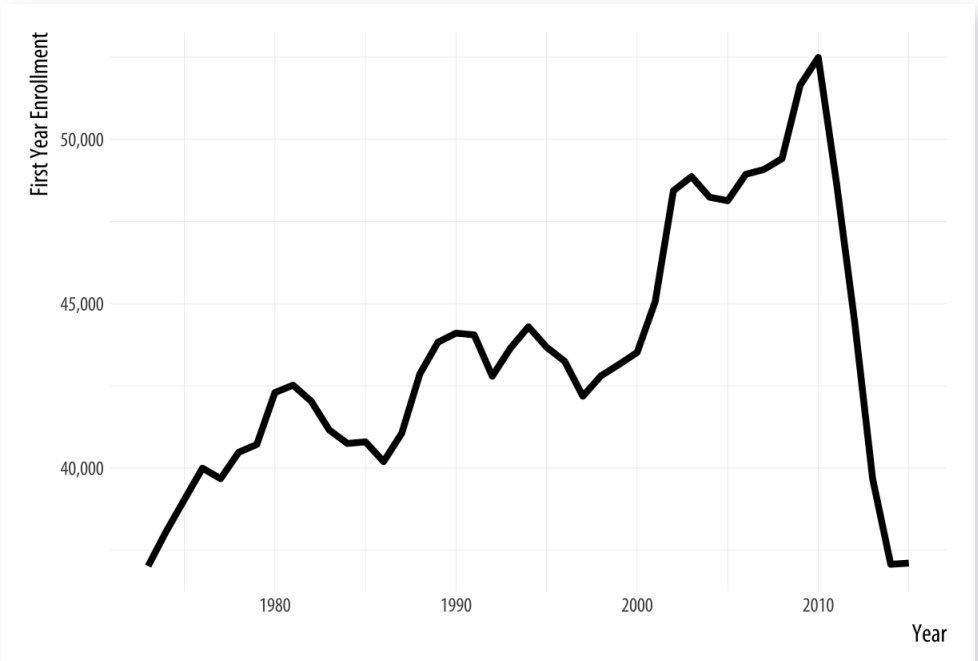


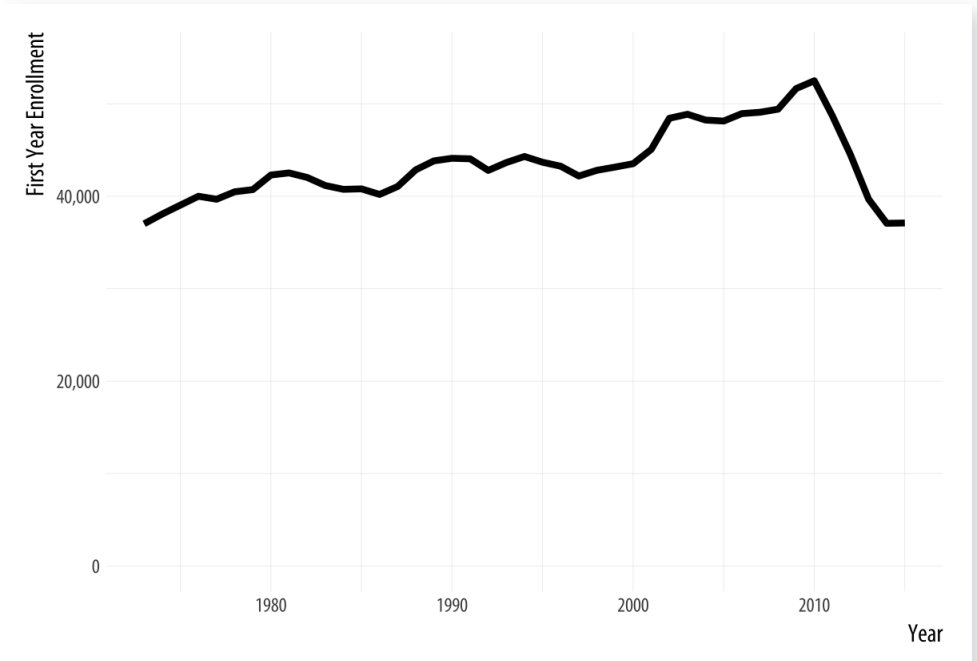
Exkurs | Verzerrte Balkeindiagramme





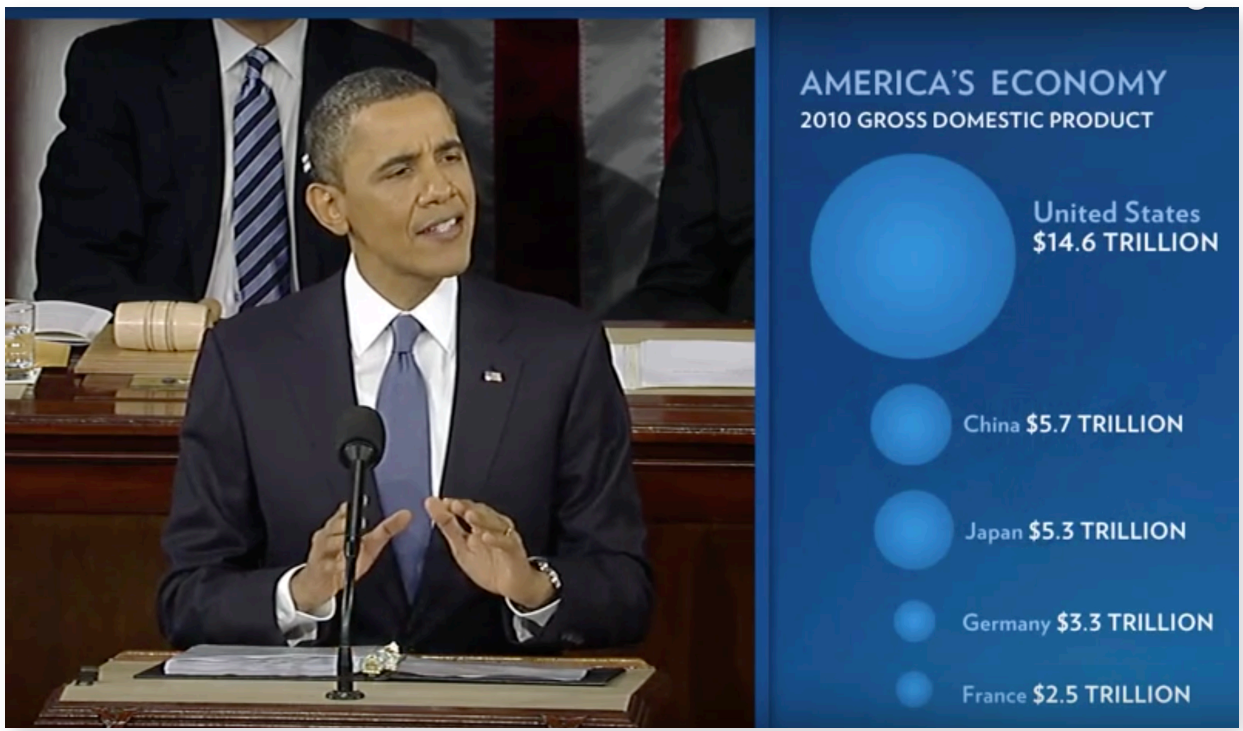
Exkurs | Wann muss die 0 gezeigt werden?

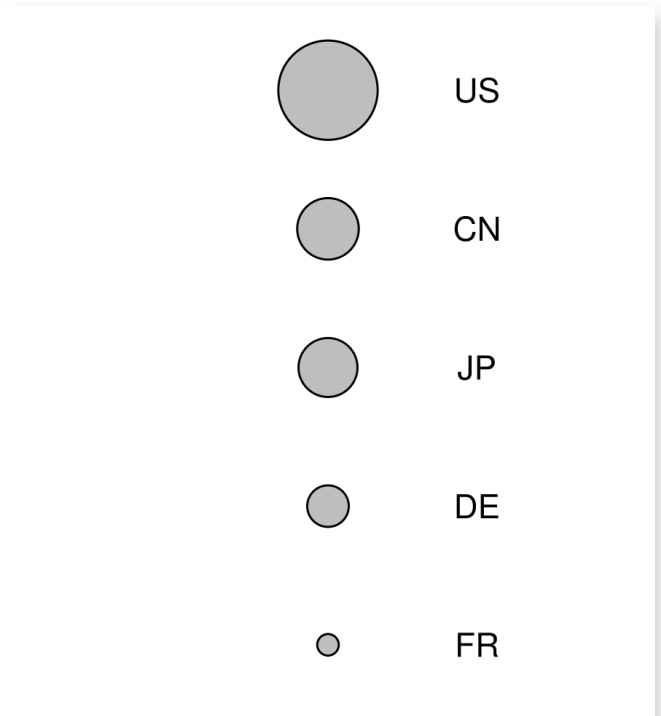




Healy, K. (2018). Data Visualization. Princeton University Press.

Exkurs | Verzerrte Kreisdiagramme

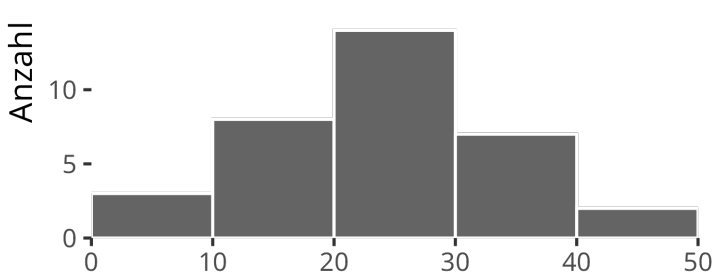




Verteilungen numerischer Variablen

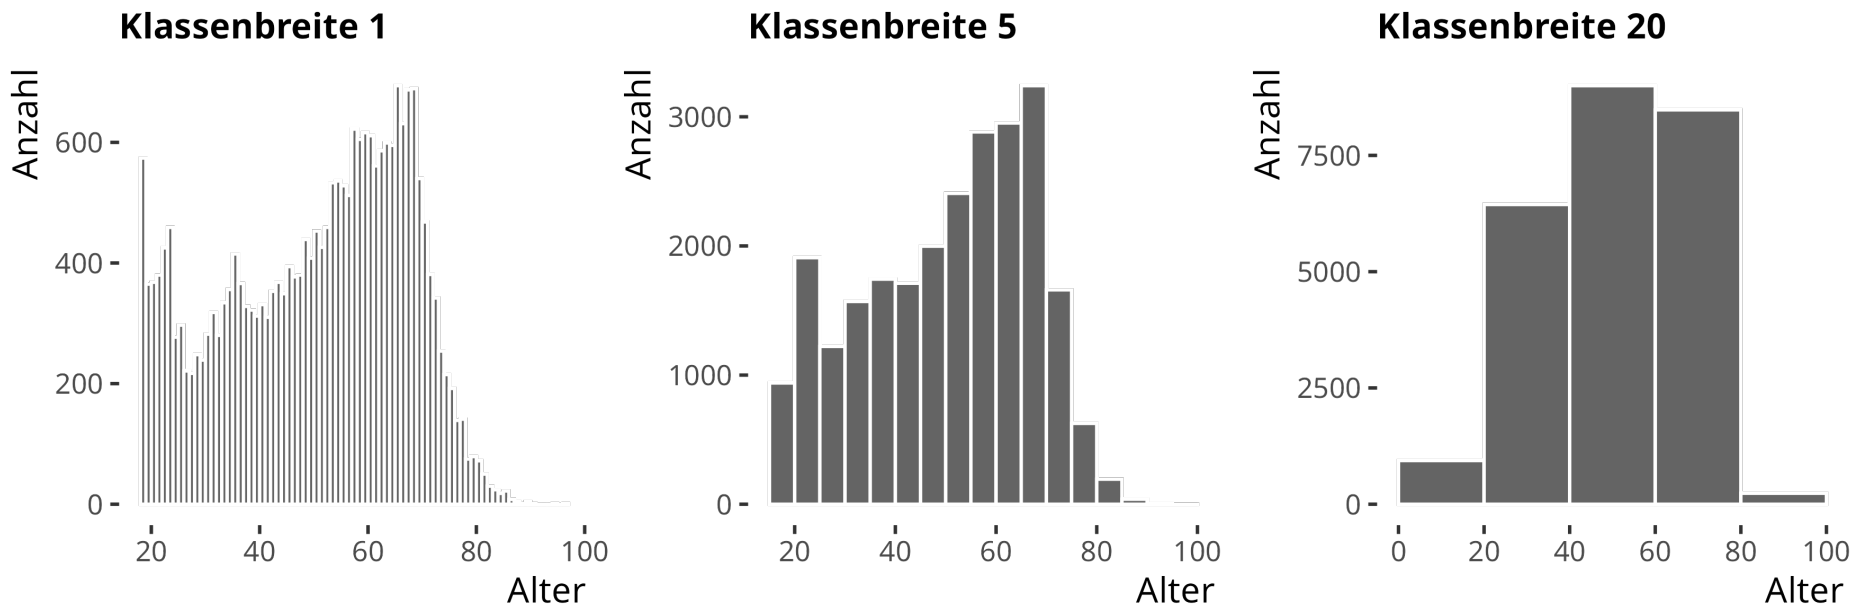
Das Histogramm

Klasse	Häufigkeit
0–9	3
10–19	8
20–29	14
30–39	7
40–49	2



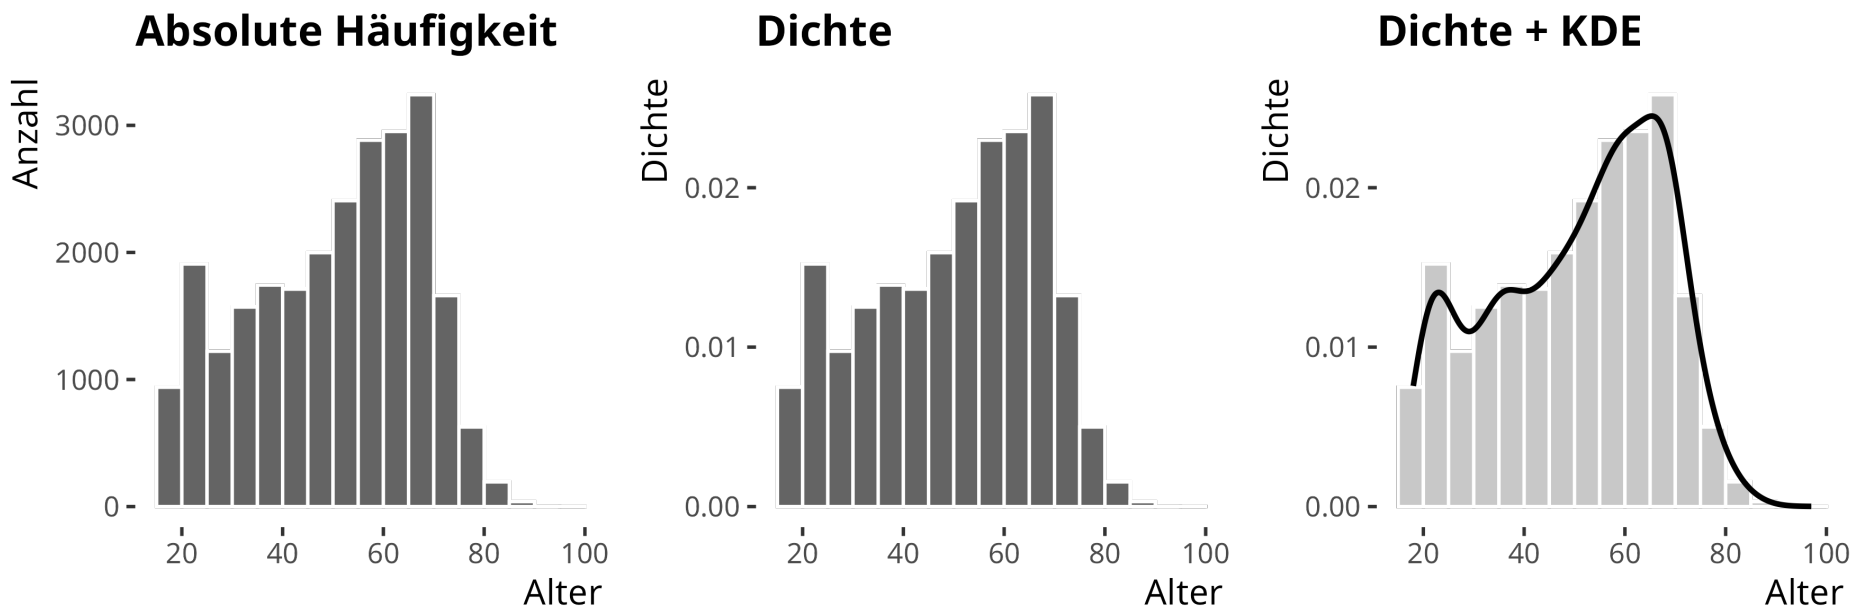
- Für numerische Variablen gibt es zu viele mögliche Merkmalsausprägungen um sinnvoll Häufigkeiten auszuzählen.
- Das Histogramm aggregiert Werte in Klassen gleicher Breite.
- Die (geordneten) Klassenhäufigkeiten können wie gehabt tabellarisch oder graphisch dargestellt werden.

Das Histogramm | Klassenbreite



Unterschiedliche Klassenbreiten können zu unterschiedlichen visuellen Interpretationen der Verteilungsform führen und sollten sinnvoll ausgewählt werden.

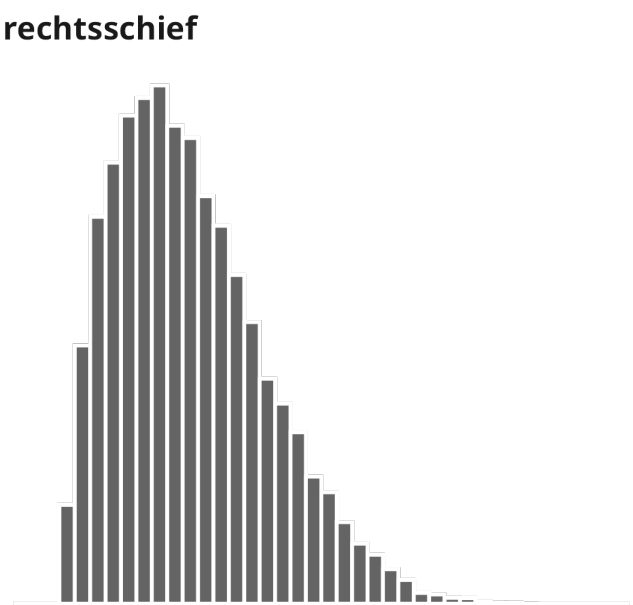
Das Histogramm | Dichte und Glättung

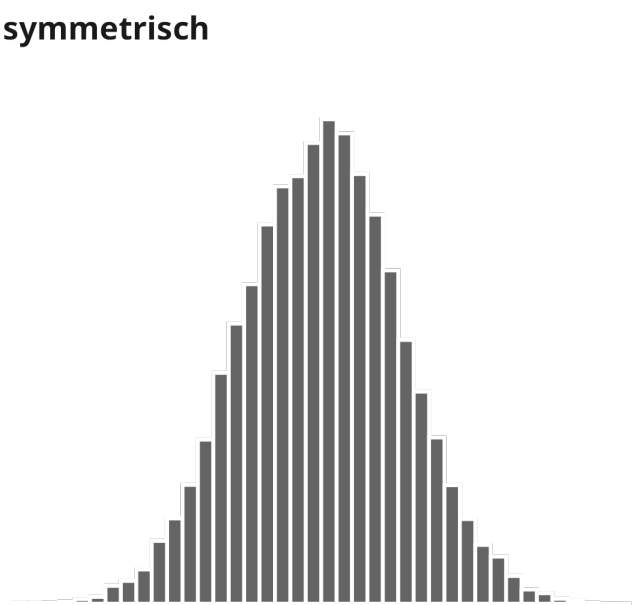


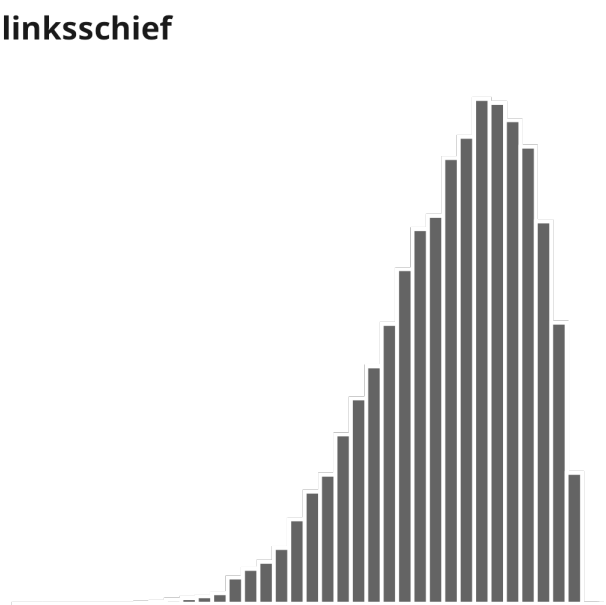
Dichte statt absoluten Häufigkeiten: Balkenfläche entspricht dem Anteil der Beobachtungen, was einfachere Vergleiche von Gruppen unterschiedlicher Größe erlaubt (KDE = Kernel Density Estimate entspricht einem geglätteten Histogramm).

Verteilungsformen

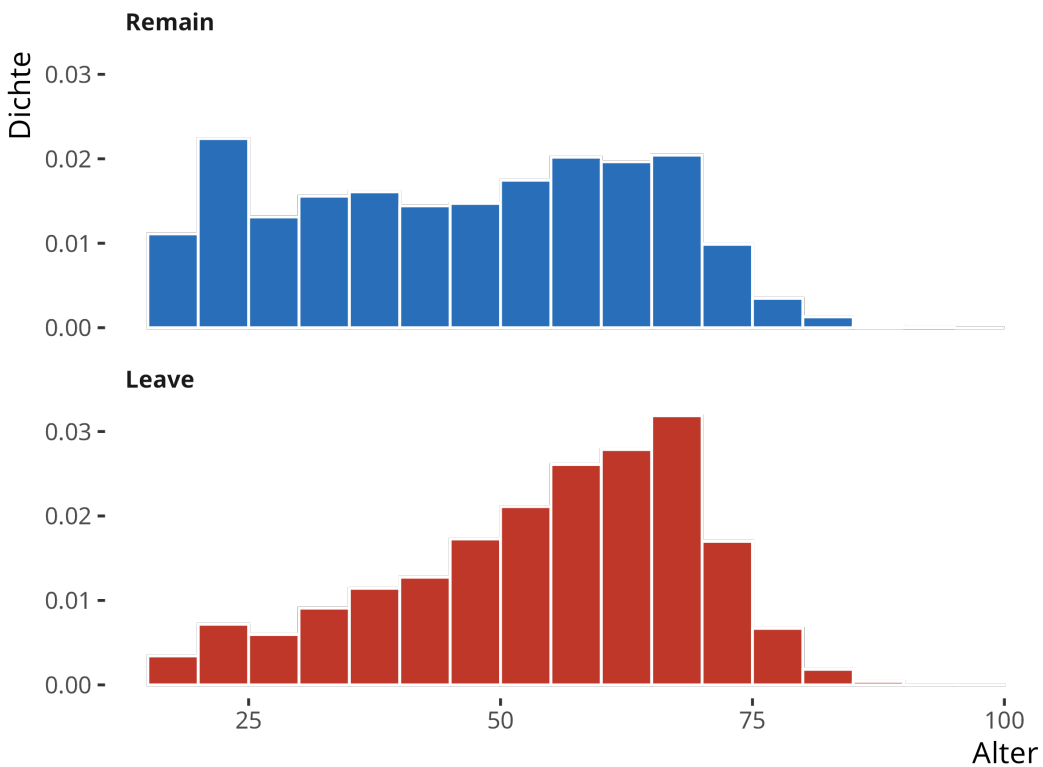
Numerische Verteilungen können unterschiedliche Formen annehmen; Geläufige Beschreibungen sind *symmetrisch*, *rechtsschief*, *linksschief* (und *multimodal*).







Alter und Abstimmungsverhalten



- Um Gruppen unterschiedlicher Größe zu vergleichen, sollten Dichten anstelle absoluter Häufigkeiten verwendet werden.
- Beobachtung: Leave-Wähler sind im Schnitt älter als Remain-Wähler: Die Verteilung der Remain-Wähler hat mehr Masse bei jüngeren Altersgruppen.

Prüfungsfragen

Prüfungsfragen

- Warum sollten Sie neben relativen auch absolute Häufigkeiten berichten?
- Was gilt es bei der Anordnung von Visualisierungen mit mehreren Panels zu berücksichtigen?
- Woran erkennen Sie in einem dichtebasierten Histogramm visuell die relative Häufigkeit einer Klasse?
- Was ist der Unterschied zwischen verhältnisskalierten und intervallskalierten Variablen?
- Können Sie die Frage nach den Ursachen der Gender-Pay-Gap mit deskriptiver Statistik beantworten?
- Wie können Sie die Repräsentativität einer Stichprobe gewährleisten?
- Wann können fehlende oder unvollständige Beobachtung ein Problem für die Interpretation statistischer Ergebnisse darstellen?