Einführung in die Statistik

Lage- und Streuungsmaße

Dr. Jakob Hoffmann

Economic Geography Group, Department für Geographie

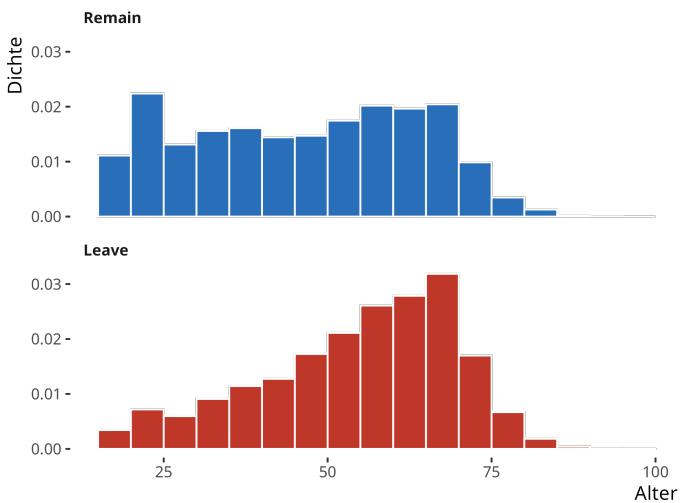
Ludwig-Maximilians-Universität, München

Wiederholung | Verteilungen

Kategorische Daten

vote	absolut	relativ
leave	13 692	44.3%
stay	14 352	46.5%
don’t know	2 314	7.5%
won’t vote	537	1.7%
Summe	30 895	100%

Numerische Daten



Lage- und Streuungsmaße

Das arithmetische Mittel

Das arithm. Mittel ist definiert als die Summe der Werte geteilt durch die Anzahl der Werte. Für die folgende Datenreihe x mit $n = 4$ Werten:

$$x = \{179, 163, 180, 192\}$$

gilt also:

$$\text{Arith. Mittel} = \overline{x} = \frac{179 + 163 + 180 + 192}{4} = 178.5$$

Das arithmetische Mittel

Das arithm. Mittel ist definiert als die Summe der Werte geteilt durch die Anzahl der Werte. Wir können diese Definition mit *Summennotation* formalisieren:

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Beispiel: Das mittlere Alter der $n = 25097$ Befragten in den BES-Daten ist $\overline{x} \approx 50.7$ Jahre.

Exkurs Summen

Das große Sigma Σ zeigt eine Summation über die Werte der Datenreihe x an.

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{1}{4}(x_1 + x_2 + x_3 + x_4)$$

Der Laufindex i indiziert die Werte in x, startet bei $i = 1$ und läuft bis n (in Schritten von 1).

Dummyvariablen

Im Fall einer Dummyvariable (die die Werte 0 oder 1 annehmen kann), gibt das arithmetische Mittel den Anteil der mit 1 kodierten Ausprägung an:

$$x = \left\{ \overset{0}{\text{Remain}}, \overset{1}{\text{Leave}}, \overset{1}{\text{Leave}}, \overset{0}{\text{Remain}} \right\}$$

$$\overline{x} = \frac{1}{n}\left(\overset{0}{x_1} + \overset{1}{x_2} + \overset{1}{x_3} + \overset{0}{x_4} \right) = \frac{\#\ \text{Leave}}{\#\ \text{gesamt}} = \frac{1}{2}$$

Der Mittelwert der `leave` Dummyvariable in den BES-Daten ist 0.472, d.h. 47.2% der Befragten haben für Leave gestimmt.

Der Median

Der Median ist der Wert in der Mitte einer größensortierten Datenreihe. Bei einer geraden Anzahl an Werten n ist der Median das arithmetische Mittel der beiden mittleren Werte.

Für eine sortierte Datenreihe s gilt also:

$$\text{Median} = \begin{cases} s_{\frac{n+1}{2}}, \text{wenn } n \text{ ungerade} \\ \frac{s_{\frac{n}{2}} + s_{\frac{n}{2}+1}}{2}, \text{wenn } n \text{ gerade} \end{cases}$$

Der Median

Beispiel mit n ungerade:

$$s = \{163, 177, 179, 180, 192\}$$

$$s_{\frac{n+1}{2}} = 179$$

Beispiel mit n gerade:

$$s = \{163, 179, 180, 192\}$$

$$\frac{s_{\frac{n}{2}} + s_{\frac{n}{2}+1}}{2} = \frac{179 + 180}{2} = 179.5$$

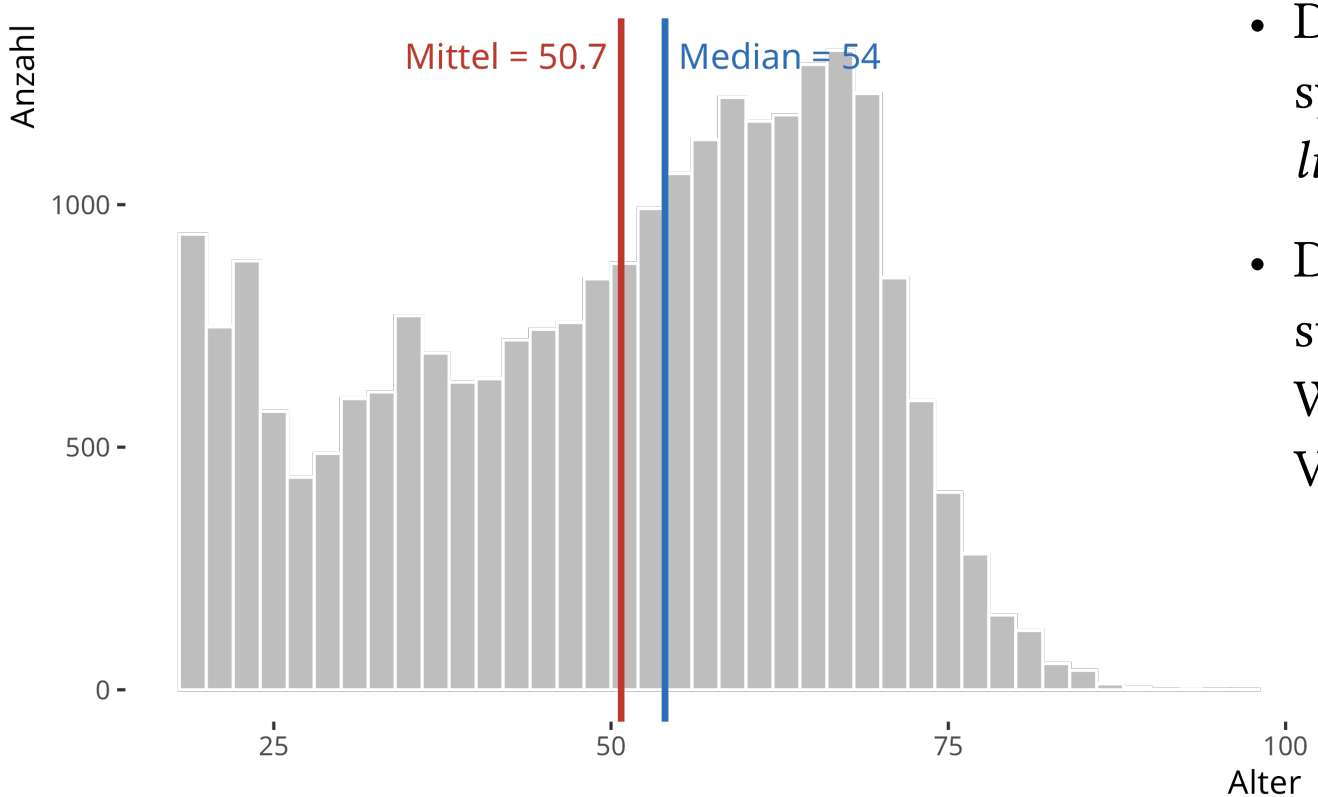
Robustheit gegenüber Ausreißern

Was passiert, wenn eine Datenreihe *Ausreißer* (ausergewöhnlich große oder kleine Werte) enthält?

$$s = \{163, 177, 179, 180, 192\} \quad \rightarrow \quad \overline{x} = 178.2, \quad \text{Median} = 179$$
$$s' = \{163, 177, 179, 180, 250\} \quad \rightarrow \quad \overline{x} = 189.8, \quad \text{Median} = 179$$

Beobachtung: Das arithmetische Mittel folgt dem Ausreißer, der Median nicht.

Median und Mittel des Alters



- Die Altersverteilung ist nicht symmetrisch sondern leicht *linksschief*.
- Das Arithmetische Mittel wird stärker durch die „extremen“ Werte am linken Rand der Verteilung beeinflusst.

Der Median für ordinale Daten

education	relativ	kumuliert
1 Keine Qualifikation	7.4%	7.4%
2 GCSE	20.5%	27.9%
3 A-Level	22.7%	50.6%
4 Bachelor	39.3%	89.9%
5 Master/PhD	10.1%	100%

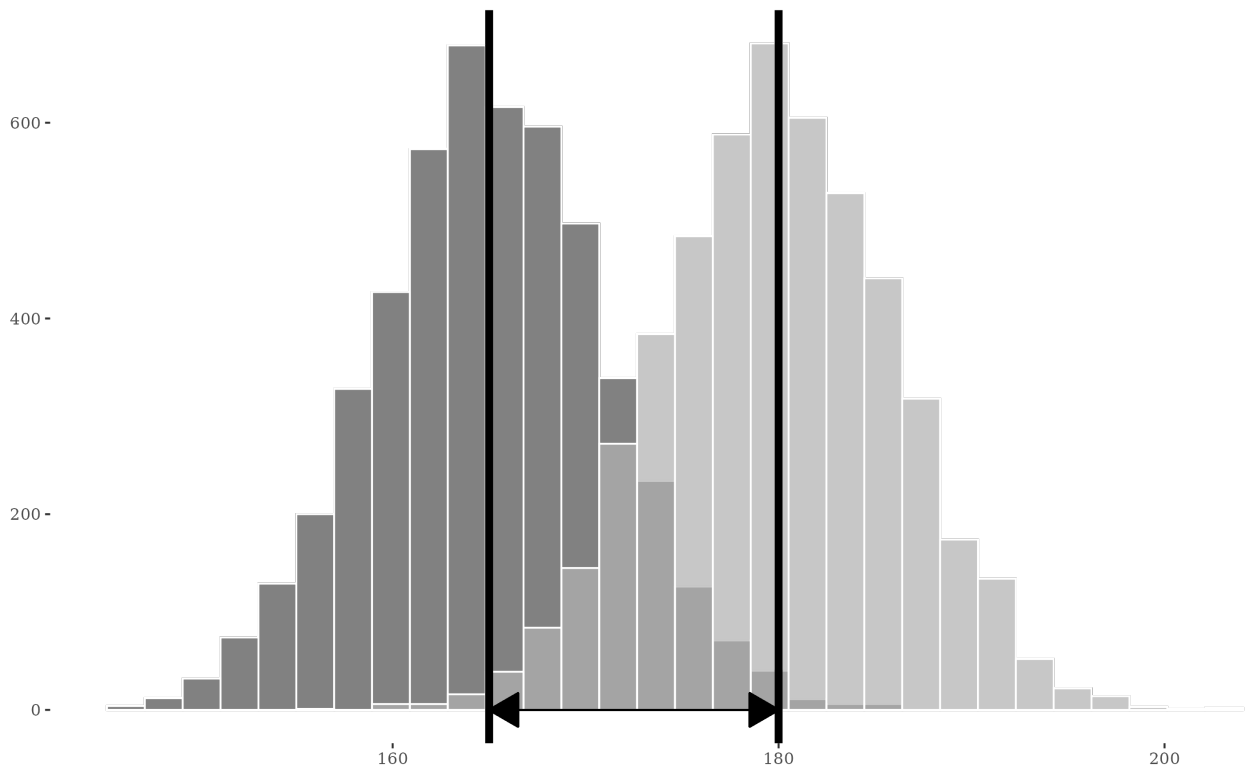
- Der Median benötigt nur eine Rangfolge und ist daher auch für **ordinale** Variablen geeignet.
- Der Median ist die erste geordnete Kategorie, bei der die kumulierte Häufigkeit 50% überschreitet.
- Im Falle der Variable `education` ist die dritte Ausprägung (A-Level) der Median.

Der Modus

Ausprägung	Häufigkeit
1	2 045
2	5 781
3	6 272
4	10 676
5	2 696
NA	3 425

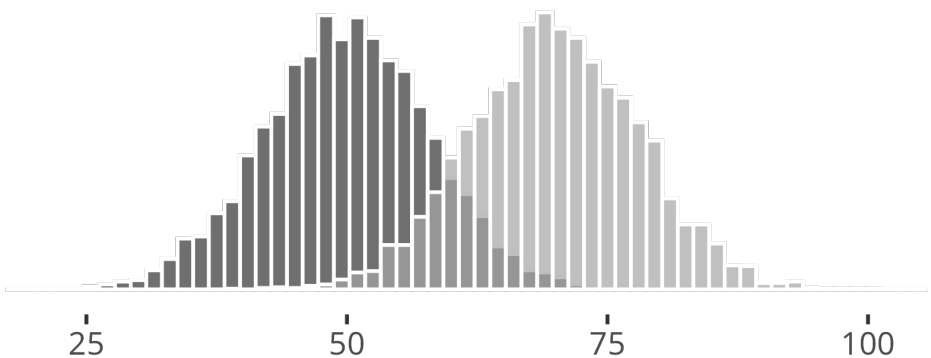
- Der **Modus** ist die am häufigsten vorkommende Ausprägung einer Variable und kann im Gegensatz zu Mittelwert und Median auch auf **nominale** Variablen angewendet werden.
- Im Falle numerischer Variablen ist der Modus ebenfalls der häufigste Wert (diskret) oder der Wert mit der größten Dichte (kontinuierlich).

Mittelwert, Median und Modus sind Lagemaße

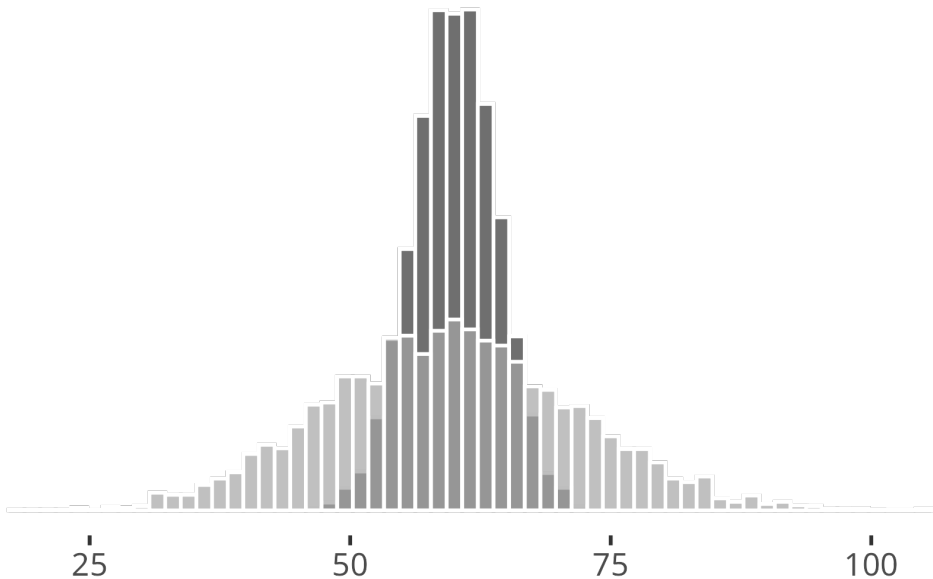


Lagemaße und Streuungsmaße

Gleiche Streuung, andere Lage



Gleiche Lage, andere Streuung



Varianz und Standardabweichung

Die **Varianz** einer Variable x ist definiert als die mittlere quadrierte Abweichung vom arithmetischen Mittel $\overline{x}$:

$$s^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})^2$$

Statt der Varianz (s^2) wird häufig die **Standardabweichung** (s) angegeben, die dieselbe Einheit wie die Variable hat und eine natürlichere Interpretation erlaubt:

$$s = \sqrt{s^2}$$

Häufig wird durch $n - 1$ statt durch n geteilt (s. erwartungstreue Schätzer).

Die Standardabweichung

Schritt 1: Berechnung des arithm. Mittels:

$$\overline{x} = \frac{1}{5}(163 + 177 + 179 + 180 + 192) = 178.2$$

Die Standardabweichung

Schritt 1: Berechnung des arithm. Mittels:

$$\overline{x} = \frac{1}{5}(163 + 177 + 179 + 180 + 192) = 178.2$$

Schritt 2: Quadrierte Differenzen:

$$\overset{231.04}{(163 - \overline{x})^2}, \quad \overset{1.44}{(177 - \overline{x})^2}, \quad \overset{0.64}{(179 - \overline{x})^2}, \quad \overset{3.24}{(180 - \overline{x})^2}, \quad \overset{190.44}{(192 - \overline{x})^2}$$

Die Standardabweichung

Schritt 1: Berechnung des arithm. Mittels:

$$\overline{x} = \frac{1}{5}(163 + 177 + 179 + 180 + 192) = 178.2$$

Schritt 2: Quadrierte Differenzen:

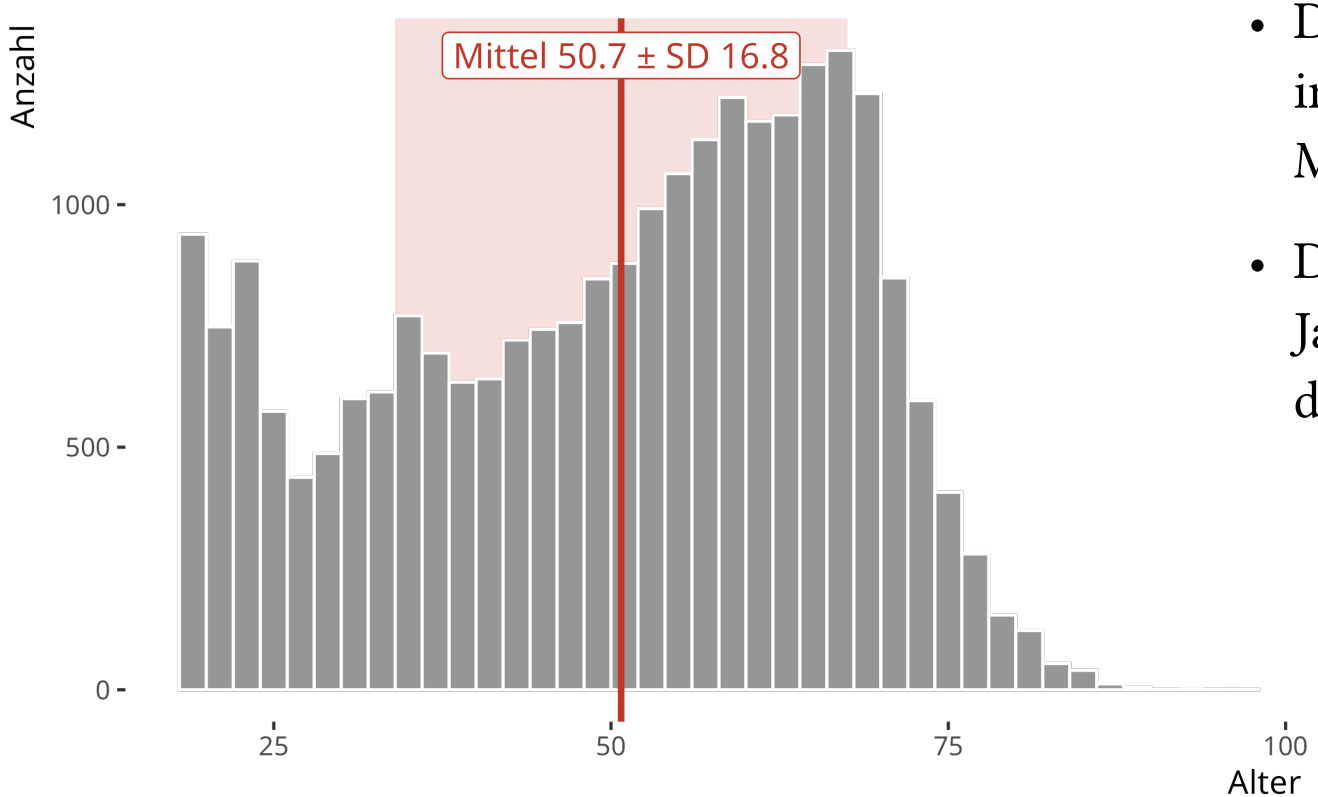
$$\overset{231.04}{(163 - \overline{x})^2}, \quad \overset{1.44}{(177 - \overline{x})^2}, \quad \overset{0.64}{(179 - \overline{x})^2}, \quad \overset{3.24}{(180 - \overline{x})^2}, \quad \overset{190.44}{(192 - \overline{x})^2}$$

Schritt 3: Mittelwert der quadrierten Differenzen:

$$s^2 = \frac{1}{5}(231.04 + 1.44 + 0.64 + 3.24 + 190.44) = 85.36$$

$$s = \sqrt{s^2} = \sqrt{85.36} = 9.24$$

Standardabweichung des Alters



- Das Alter der Befragten weicht im Schnitt um **16.8 Jahre** vom Mittelwert (50.7) ab.
- Das Intervall $\overline{x} \pm s$ (34 – 67.5 Jahre) umfasst einen Großteil der Befragten.

Absolutabweichung vom Median (MAD)

MAD ist ein robusteres Streuungsmaß als SD, analog zu Median vs. Mittel.

Schritt 1: Berechnung des Medians von x:

$$\tilde{x} = \text{median}(163, 177, 179, 180, 192) = 179$$

Absolutabweichung vom Median (MAD)

MAD ist ein robusteres Streuungsmaß als SD, analog zu Median vs. Mittel.

Schritt 1: Berechnung des Medians von x:

$$\tilde{x} = \text{median}(163, 177, 179, 180, 192) = 179$$

Schritt 2: Absolutdifferenzen zum Median:

$$\overset{16}{|163 - \tilde{x}|} \quad \overset{2}{|177 - \tilde{x}|} \quad \overset{0}{|179 - \tilde{x}|} \quad \overset{1}{|180 - \tilde{x}|} \quad \overset{13}{|192 - \tilde{x}|}$$

Absolutabweichung vom Median (MAD)

MAD ist ein robusteres Streuungsmaß als SD, analog zu Median vs. Mittel.

Schritt 1: Berechnung des Medians von x:

$$\tilde{x} = \text{median}(163, 177, 179, 180, 192) = 179$$

Schritt 2: Absolutdifferenzen zum Median:

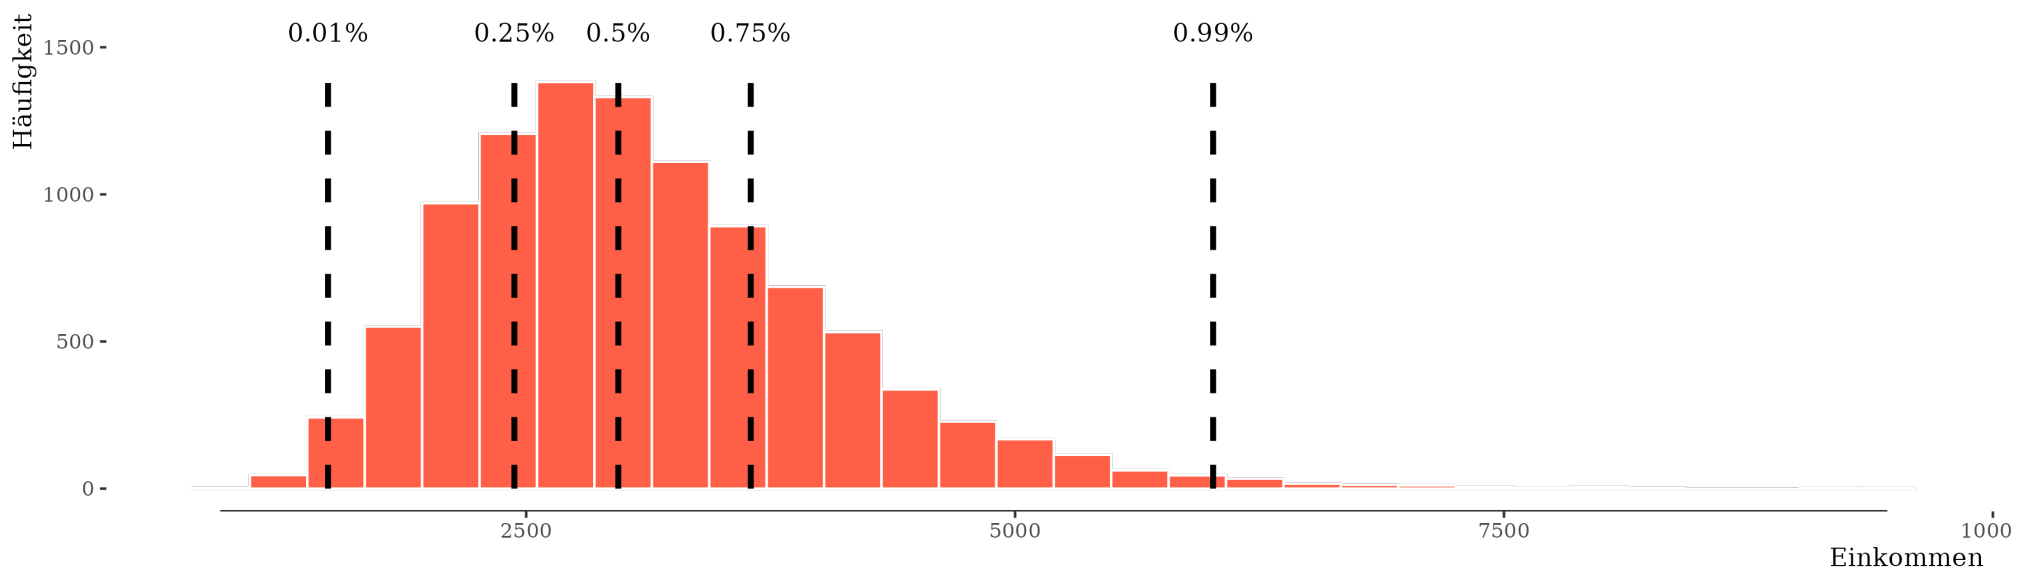
$$\overset{16}{|163 - \tilde{x}|} \quad \overset{2}{|177 - \tilde{x}|} \quad \overset{0}{|179 - \tilde{x}|} \quad \overset{1}{|180 - \tilde{x}|} \quad \overset{13}{|192 - \tilde{x}|}$$

Schritt 3: Median der Absolutdifferenzen:

$$\text{MAD} = \text{median}(0, 1, 2, 13, 16) = 2$$

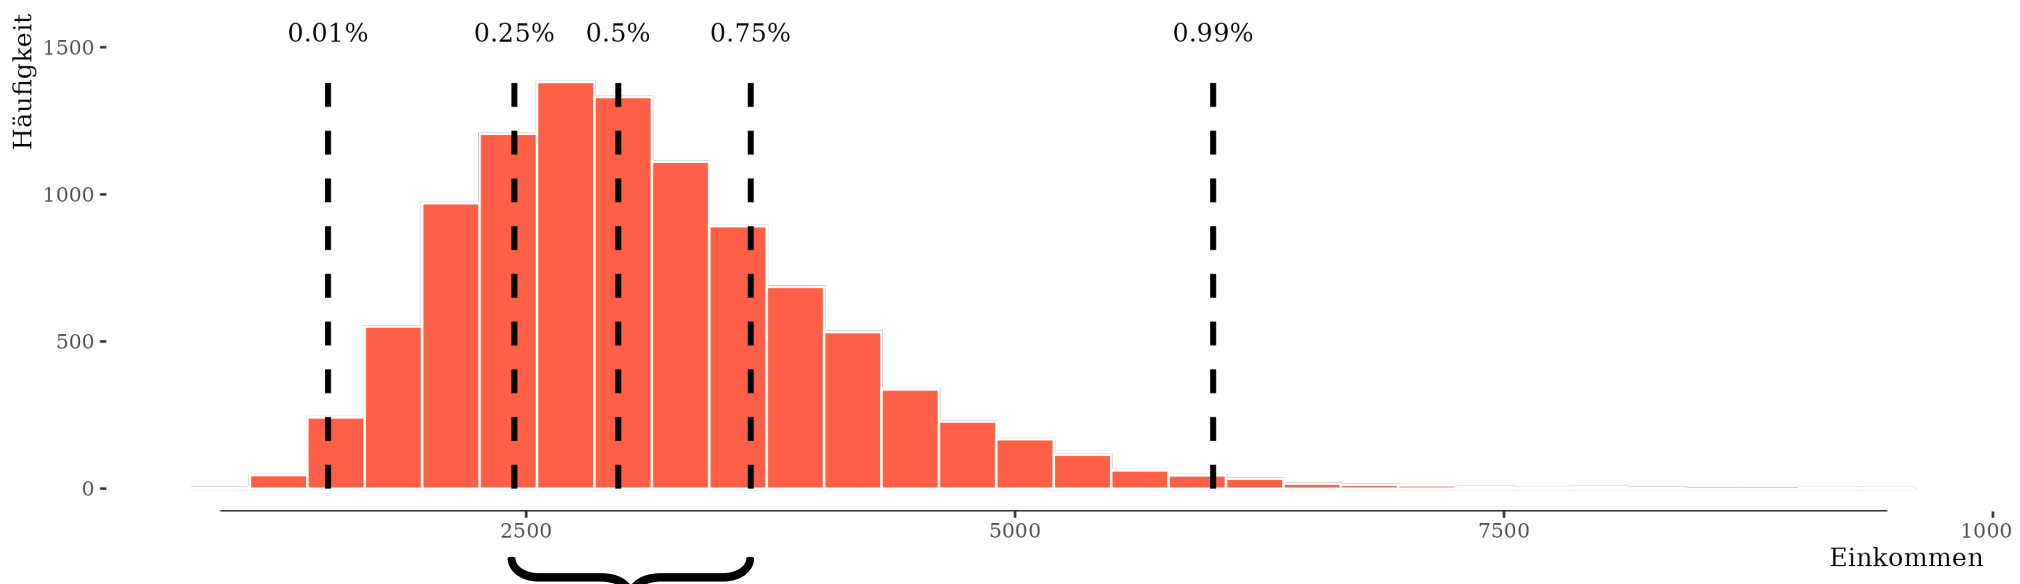
Quantile, Perzentile und IQA

- Der Median ist das 0.5-Quantil (50%-Perzentil) , d.h. 50% der Werte sind kleiner als der Median.
- Andere Quantile erlauben z.B. eine Aussage über einen „Großteil“ (z.B. 90%) der Daten.



Quantile, Perzentile und IQA

- Der Median ist das 0.5-Quantil (50%-Perzentil) , d.h. 50% der Werte sind kleiner als der Median.
- Andere Quantile erlauben z.B. eine Aussage über einen „Großteil“ (z.B. 90%) der Daten.



Interquartilsabstand (IQA) = $Q_{75\%} - Q_{25\%}$

Alter und Abstimmungsverhalten

	Remain	Leave
Mittel	46.9	55.1
Median	48	58
SD	17.3	15.0
MAD	15	10

- Leave-Wähler sind im Mittel gut 8 Jahre älter als Remain-Wähler (Median: 10 Jahre).
- Die Altersverteilung der Leave-Wähler ist konzentrierter: sowohl SD als auch MAD sind kleiner.
- Bei den Leave-Wählern liegen SD (15.0) und MAD (10) weit auseinander.

Ausblick und Vertiefung

- **Geometrische Mittelwerte**: für multiplikative Größen wie Wachstumsraten
- **Gewichtete Mittelwerte**: wenn Beobachtungen unterschiedlich stark zählen sollen (z.B. Regionen mit unterschiedlicher Bevölkerung)
- Numerische Zusammenfassungen kategorischer Verteilungseigenschaften (Entropie, Dissens)
- Weitere Lage-, Streuungs- und Konzentrationsmaße

Prüfungsfragen

- Wann ist der Median dem Mittelwert zu bevorzugen?
- Welches Maß quantifiziert die ‚Mitte' einer nominalskalierten Variable?
- Welches Streuungsmaß könnten sie als robuste Alternative zur Standardabweichung einsetzen?
- Welchem Quantil entspricht der Median? Was ist der Interquartilsabstand?