Einführung in die Statistik

Deskriptive Statistik III

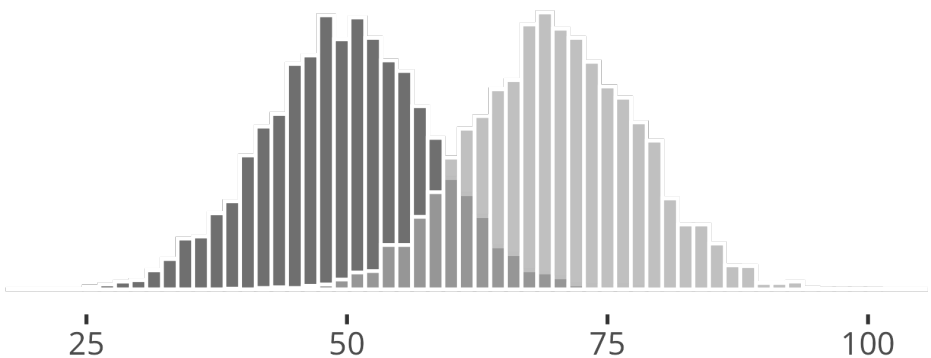
Dr. Jakob Hoffmann

Economic Geography Group, Department für Geographie

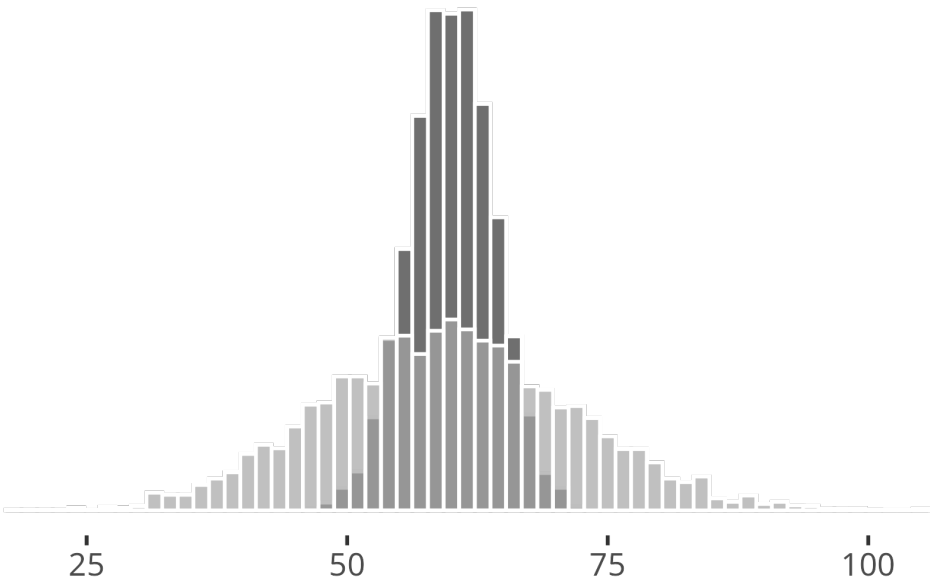
Ludwig-Maximilians-Universität, München

Wiederholung | Lage- und Streuungsmaße

Gleiche Streuung, andere Lage



Gleiche Lage, andere Streuung

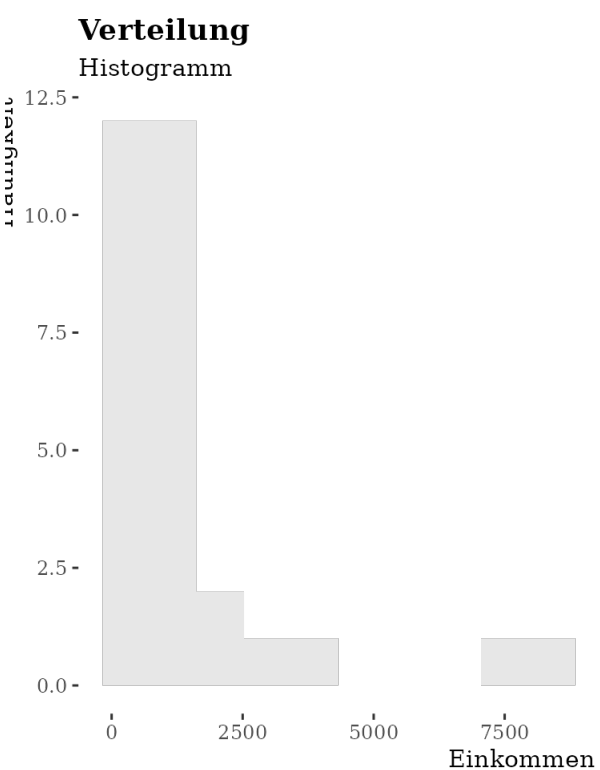


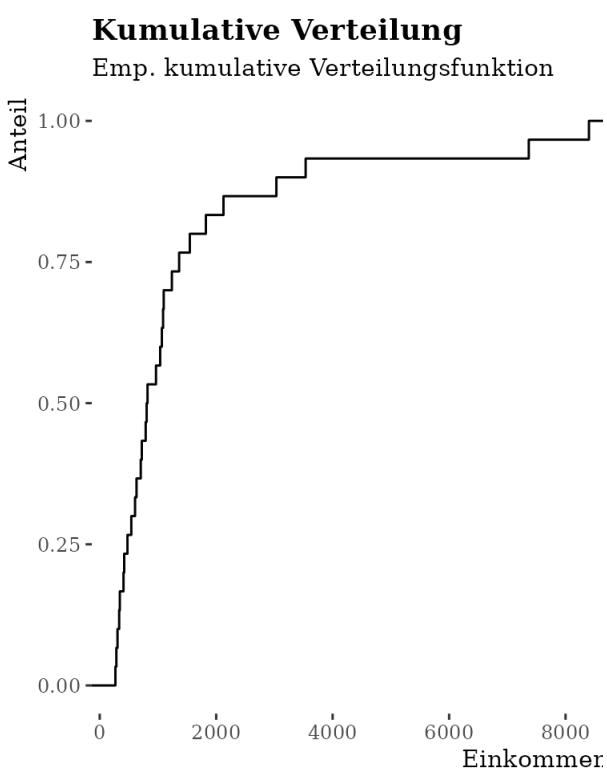
Konzentrationsmaße

Konzentrationsmaße

- Klassiche Streuungsmaße wie die Standardabweichung quantifizeren das Ausmaß der Abweichung vom Mittelwert einer Verteilung.
- Einen Spezialfall bilden Streuungsmaße, die stattdessen die *Konzentration* einer Variable über die Merkmalsträger bewerten.
- Der Gini-Koeffizient wurde z.B. entwickelt, um die Ungleichverteilung (d.h. Konzentration) von Einkommen in der Bevölkerung zu messen.

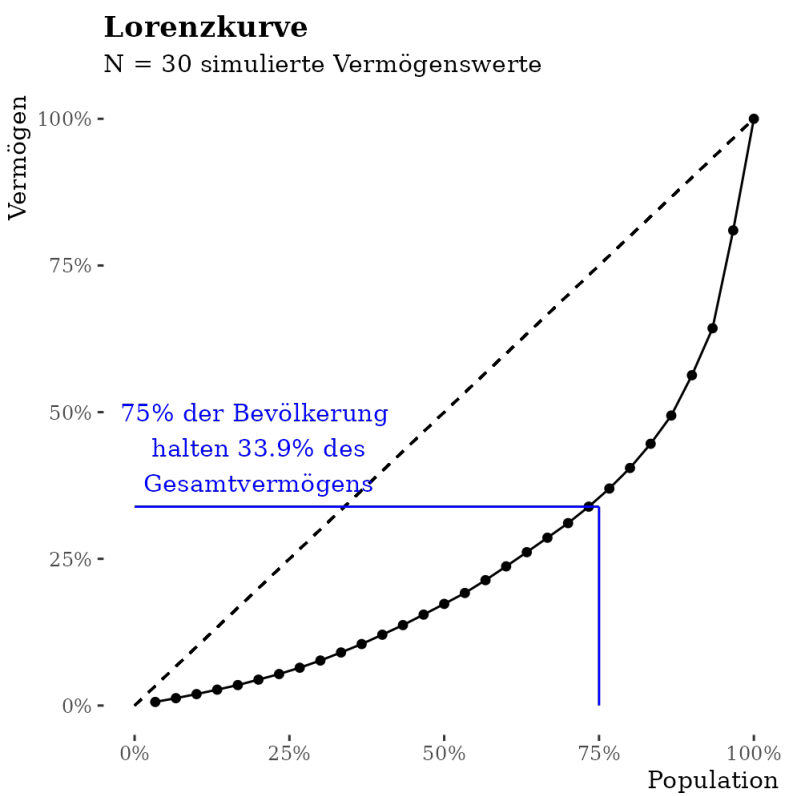
Exkurs | Kumulative Verteilungen





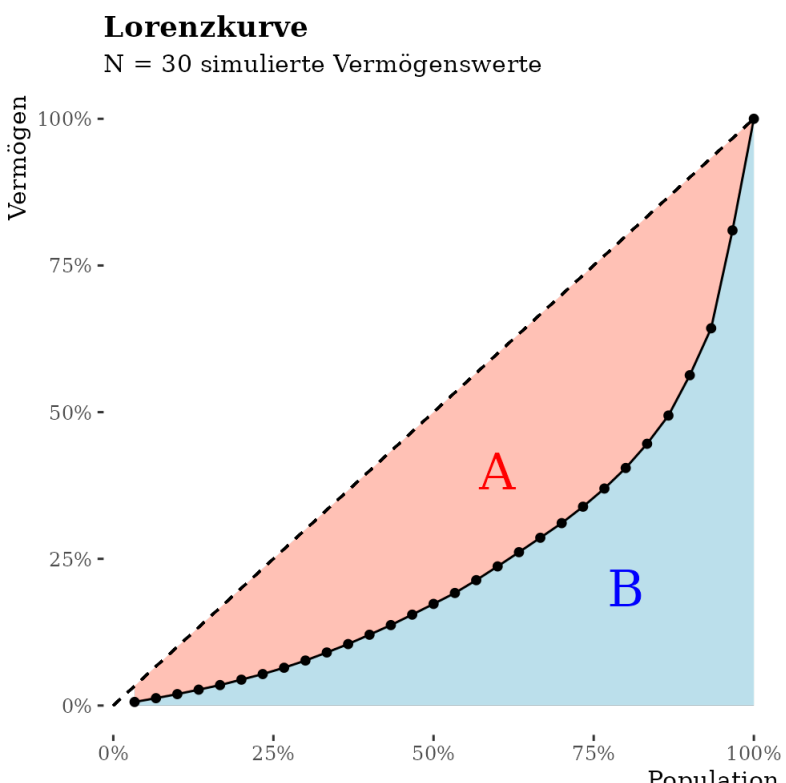
- Die empirische kumulative Verteilungsfunktion (ECDF) zeigt für jedes x den Anteil der Werte die kleiner oder gleich x sind.
- Die ECDF ist eine alternative Zusammenfassung einer Verteilung, die z.B. leichteres Ablesen von Quantilen erlaubt.

Die Lorenzkurve



- Die Lorenzkurve bildet den kumulativen Anteil der Population gegen den kumulativen Anteil der betrachteten Größe (z.B. Vermögen) ab.
- Die Lorenzkurve bentwortet Fragen wie: “Welcher Anteil des Gesamtvermögens entfällt auf die reichsten x%?”
- Die Diagonale / Isolinie zeigt eine perfekte Gleichverteilung an (10% der Bevölkerung besitzen 10% des Vermögens etc.).
- Je weiter die Lorenzkurve von der Isolinie entfernt ist, umso ungleicher ist die zugrundeliegende Größe verteilt.

Der Gini-Koeffizient



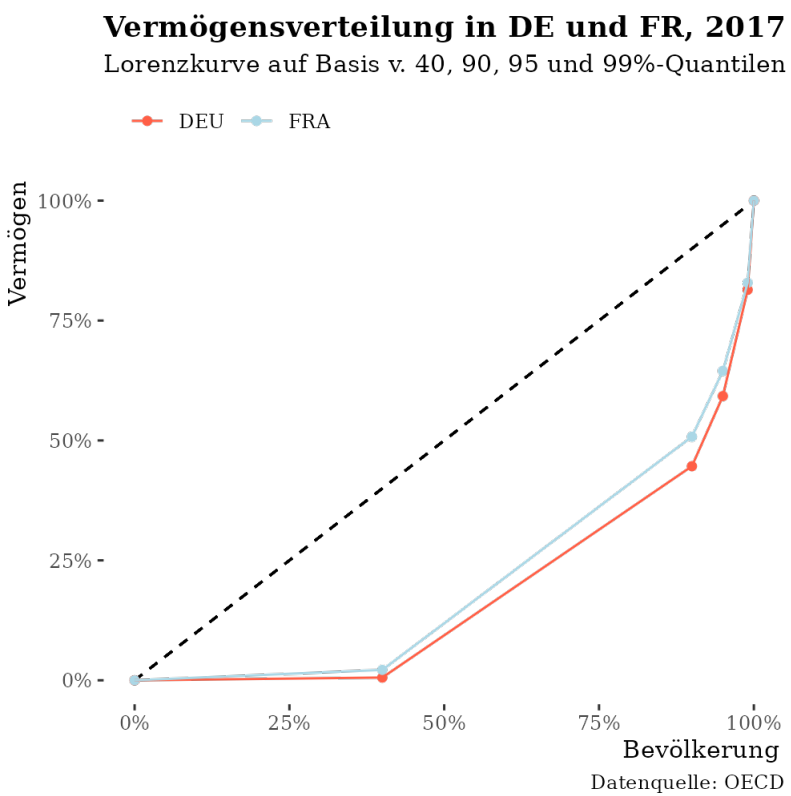
- Der Gini-Koeffizient entspricht der Fläche unter der Lorenzkurve geteilt durch die Gesamtfläche unter der Isolinie:

$$G = \frac{A}{A + B} = 2A$$

- $G = 1$ bedeutet vollständige Ungleichverteilung, $G = 0$ entspricht einer perfekten Gleichverteilung.
- Der Gini-Koeffizient ist alternativ $G = \frac{1}{2}\frac{\text{MD}}{\text{AM}}$ wobei AM das arithmetische Mittel und MD die mittlere Absolutabweichung bezeichnet:

$$\text{MD} = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n}|x_i - x_j|$$

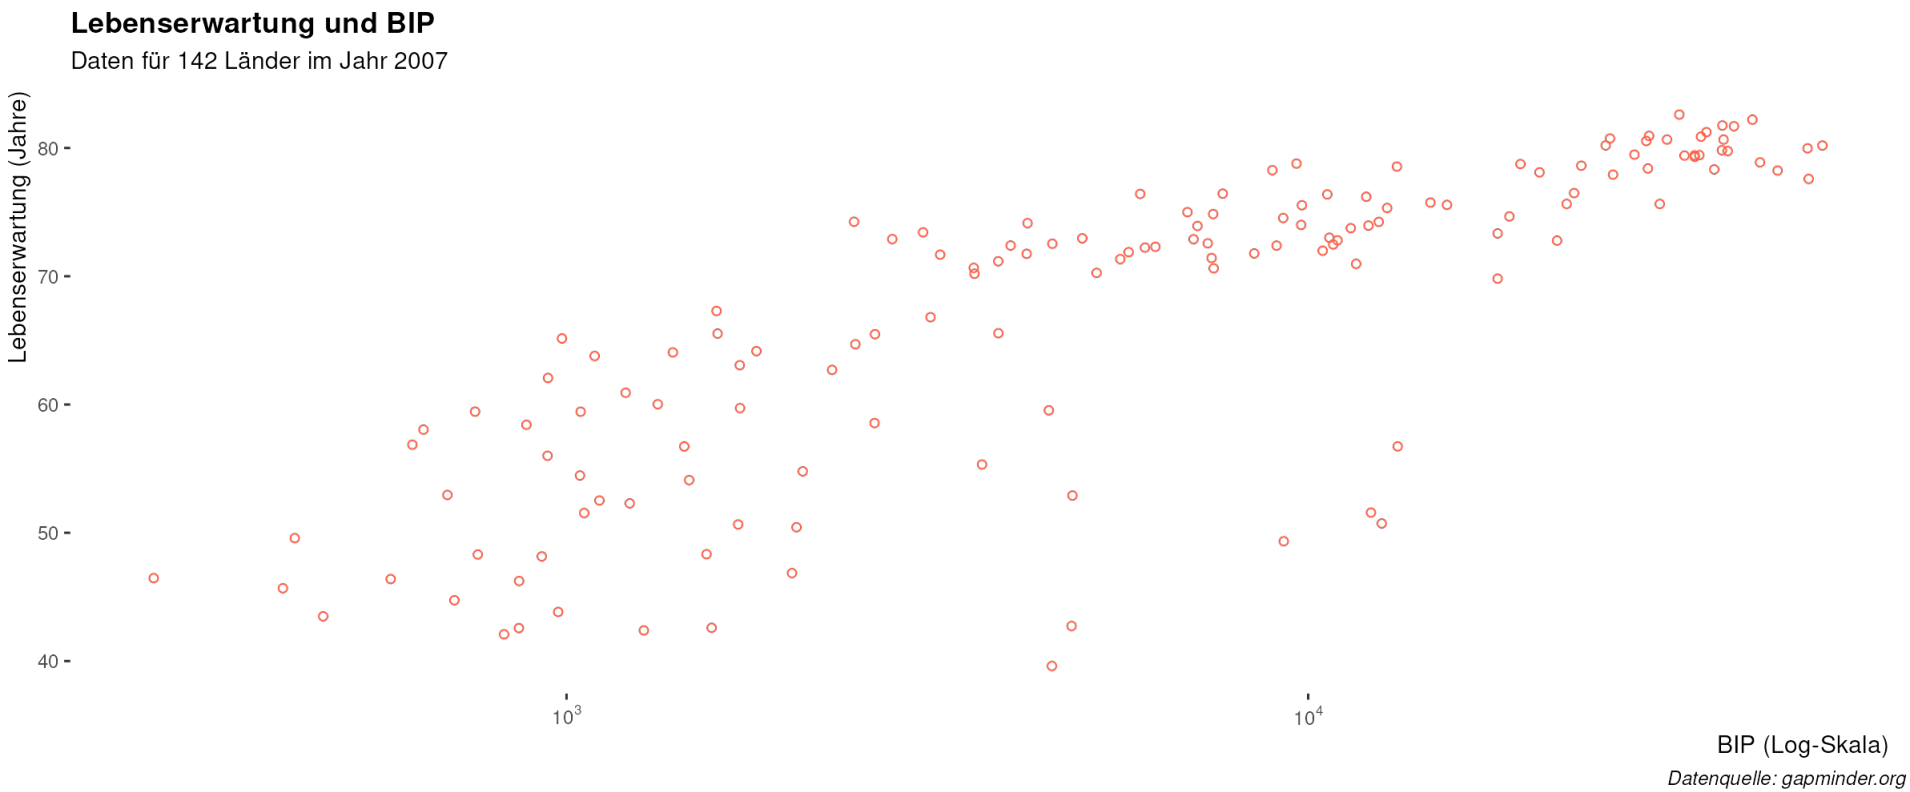
Vermögen in Deutschland und Frankreich



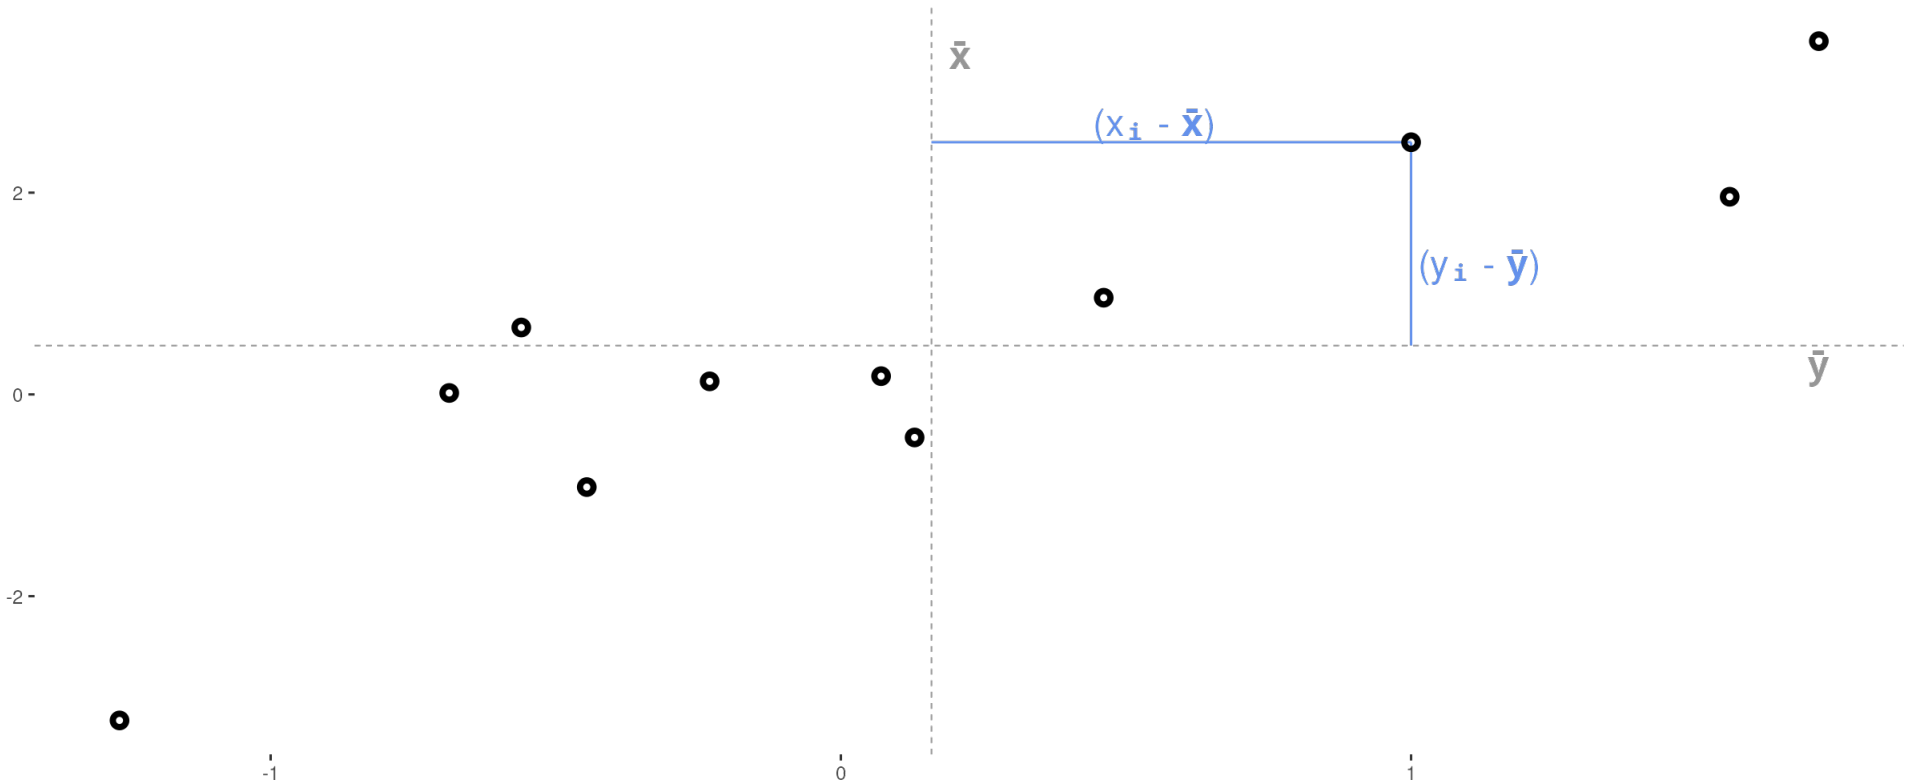
- Die unteren 40% verfügen in DEU und FRA über 0.56% bzw. 2.16% des Gesamtvermögens.
- Auf die reichsten 5% der Bevölkerung entfallen je 40.8% (DEU) bzw. 35.5% (FRA).
- Auf Basis der aggregierten Referenzwerte ergibt sich ein Gini-Koeffizient von 0.66 (DEU) bzw. 0.62 (FRA).
- Die tatsächlichen Werte auf Basis höher aufgelöster Daten sind noch höher, ca. 0.78 in Deutschland im Jahr 2017 (Sachverständigenrat der Wirtschaft, 2019).

Zusammenhänge numerischer Variablen

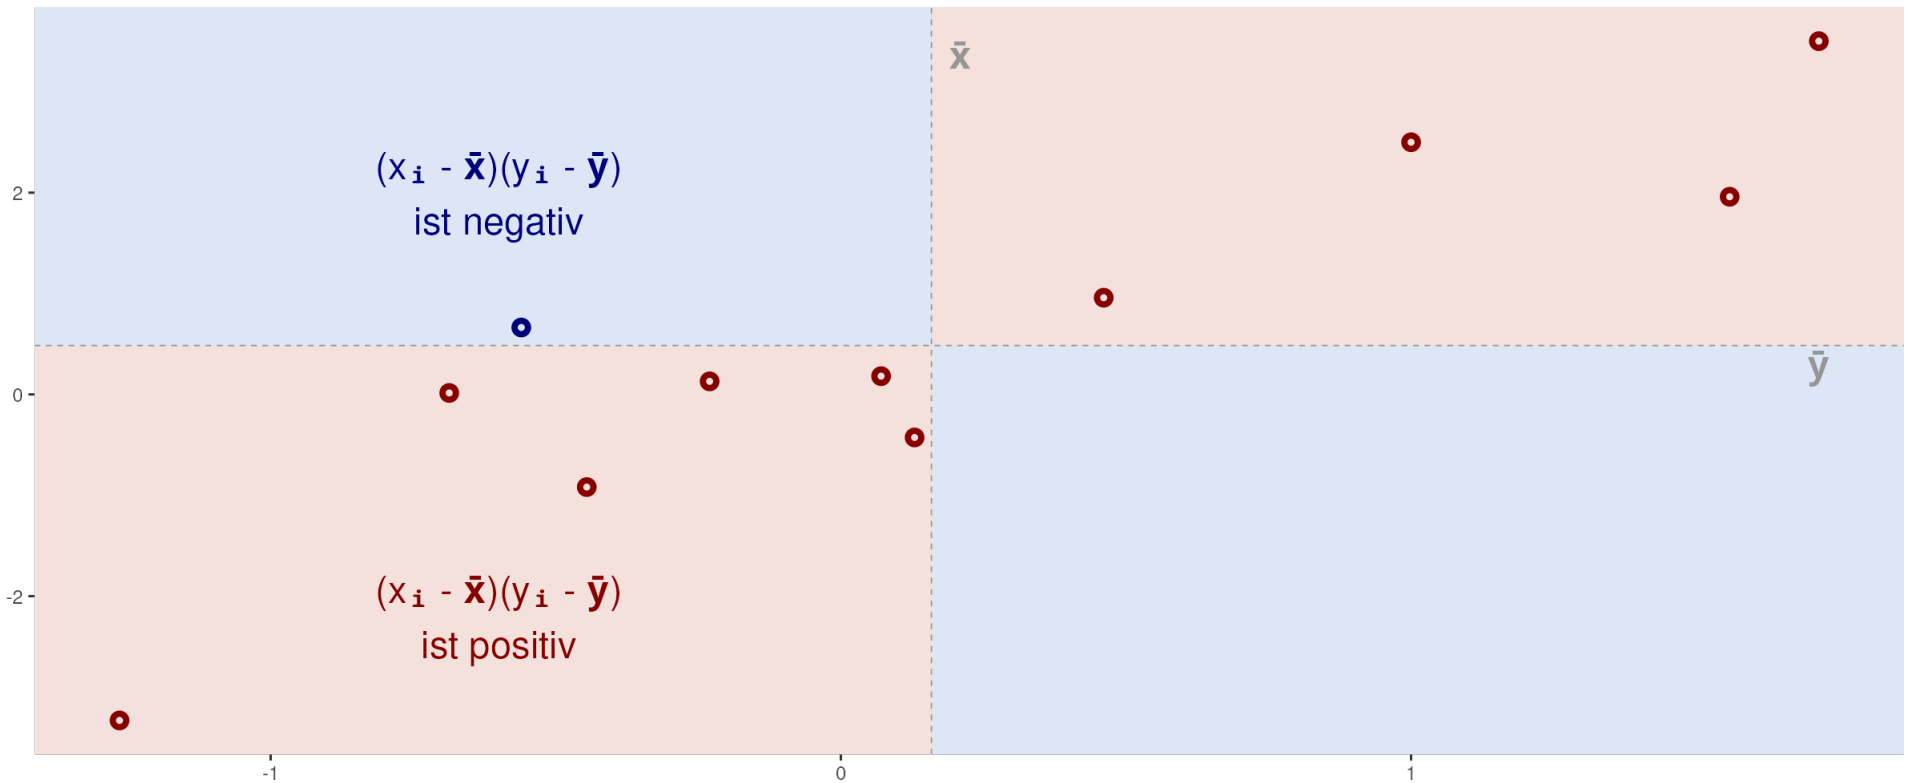
Streudiagramm (Scatterplot)



Kovarianz



Kovarianz


$(x_i - \bar{x})(y_i - \bar{y})$
ist negativ
$(x_i - \bar{x})(y_i - \bar{y})$
ist positiv
$\bar{x}$
$\bar{y}$
2
0
-2
-1
0
1

Kovarianz

Analog zur Varianz ist die **Kovarianz** zweier Variablen x und y definiert als der Mittelwert der Produkte der Abweichungen von den jeweiligen Mittelwerten:

$$s_{xy} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$

Die Kovarianz ist positiv (negativ) wenn höhere Werte von x mit höheren (niedrigeren) Werten von y einhergehen.

Kovarianz

Die Kovarianz zweier Variablen x und y ist symmetrisch (d.h. es gibt keine abhängige und unabhängige Variable):

$$s_{xy} = s_{yx}$$

Die Kovarianz ist zwar invariant unter der Addition von Konstanten, wird aber durch Faktoren der Variablen skaliert:

$$s_{ax+b,cy+d} = a \cdot c \cdot s_{xy}$$

Abhängigkeit von der Skalierung der Variablen macht die Kovarianz schwierig zu interpretieren / zu vergleichen.

Korrelationskoeffizient

Normalisierung der Kovarianz durch das ‘Herausteilen’ der Standardabweichungen gibt uns den *Korrelationskoeffizienten* mit Wertebereich −1 bis 1:

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

Die Normalisierung auf den Bereich −1 bis 1 kann durch die Cauchy-Schwarz-Ungleichung oder durch Anwendung der Kosinusdefinition des Skalarprodukts bewiesen werden.

Korrelationskoeffizient

Für die beiden Datenreihen

$$x = 1.4 \quad 2.3 \quad 1.1 \quad 2.7 \qquad y = 5.3 \quad 4.3 \quad 0.4 \quad 4.8$$

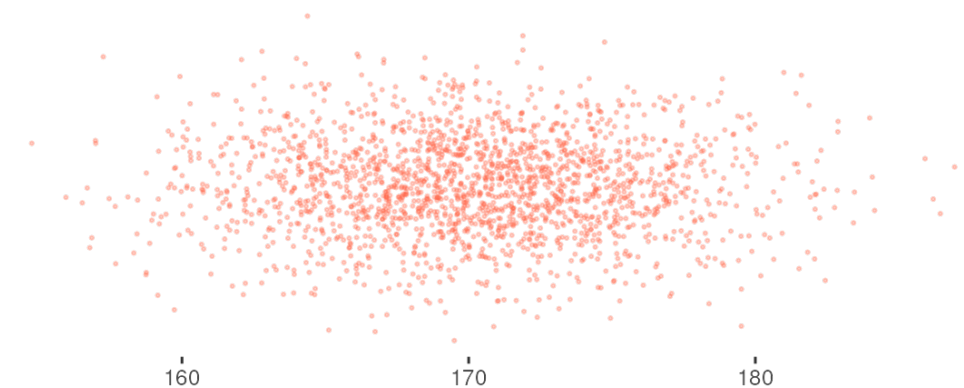
ist die Kovarianz

$$s_{xy} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y}) = 0.74$$

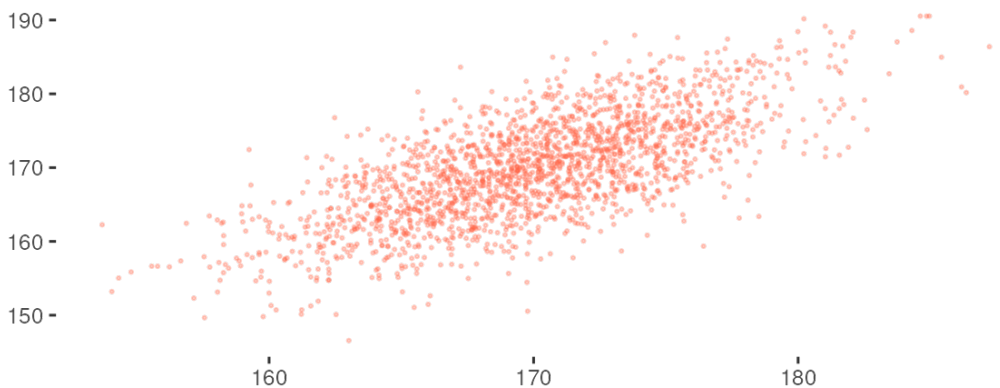
Mit $s_x = 0.65$ und $s_y = 1.94$ ist der Korrelationskoeffizient r_{xy}

$$r_{xy} = \frac{s_{xy}}{s_x s_y} = 0.59$$

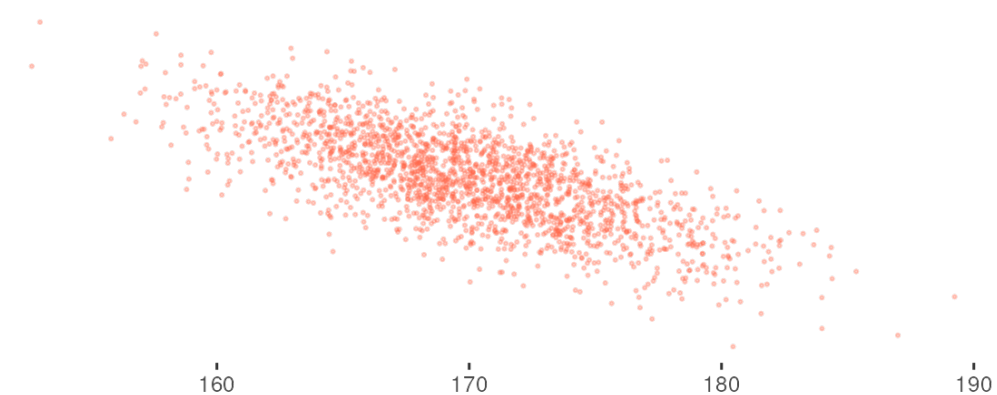
Kovarianz = -0.32 | Korrelation = -0.01



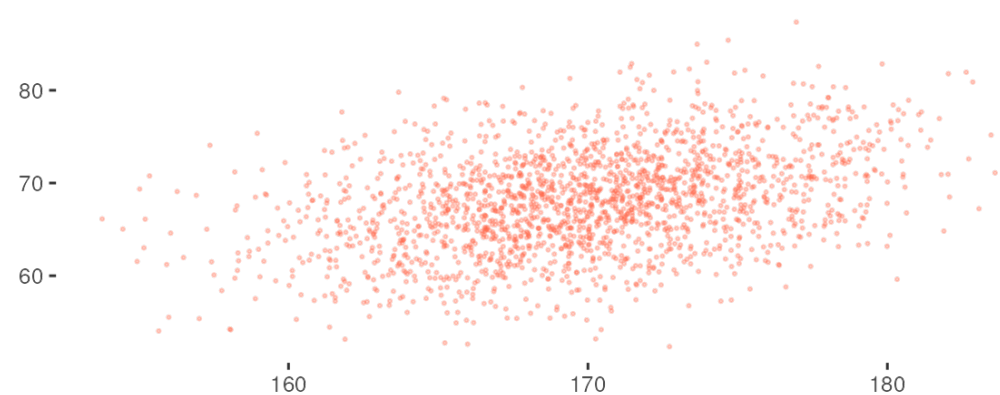
Kovarianz = 24.51 | Korrelation = 0.7

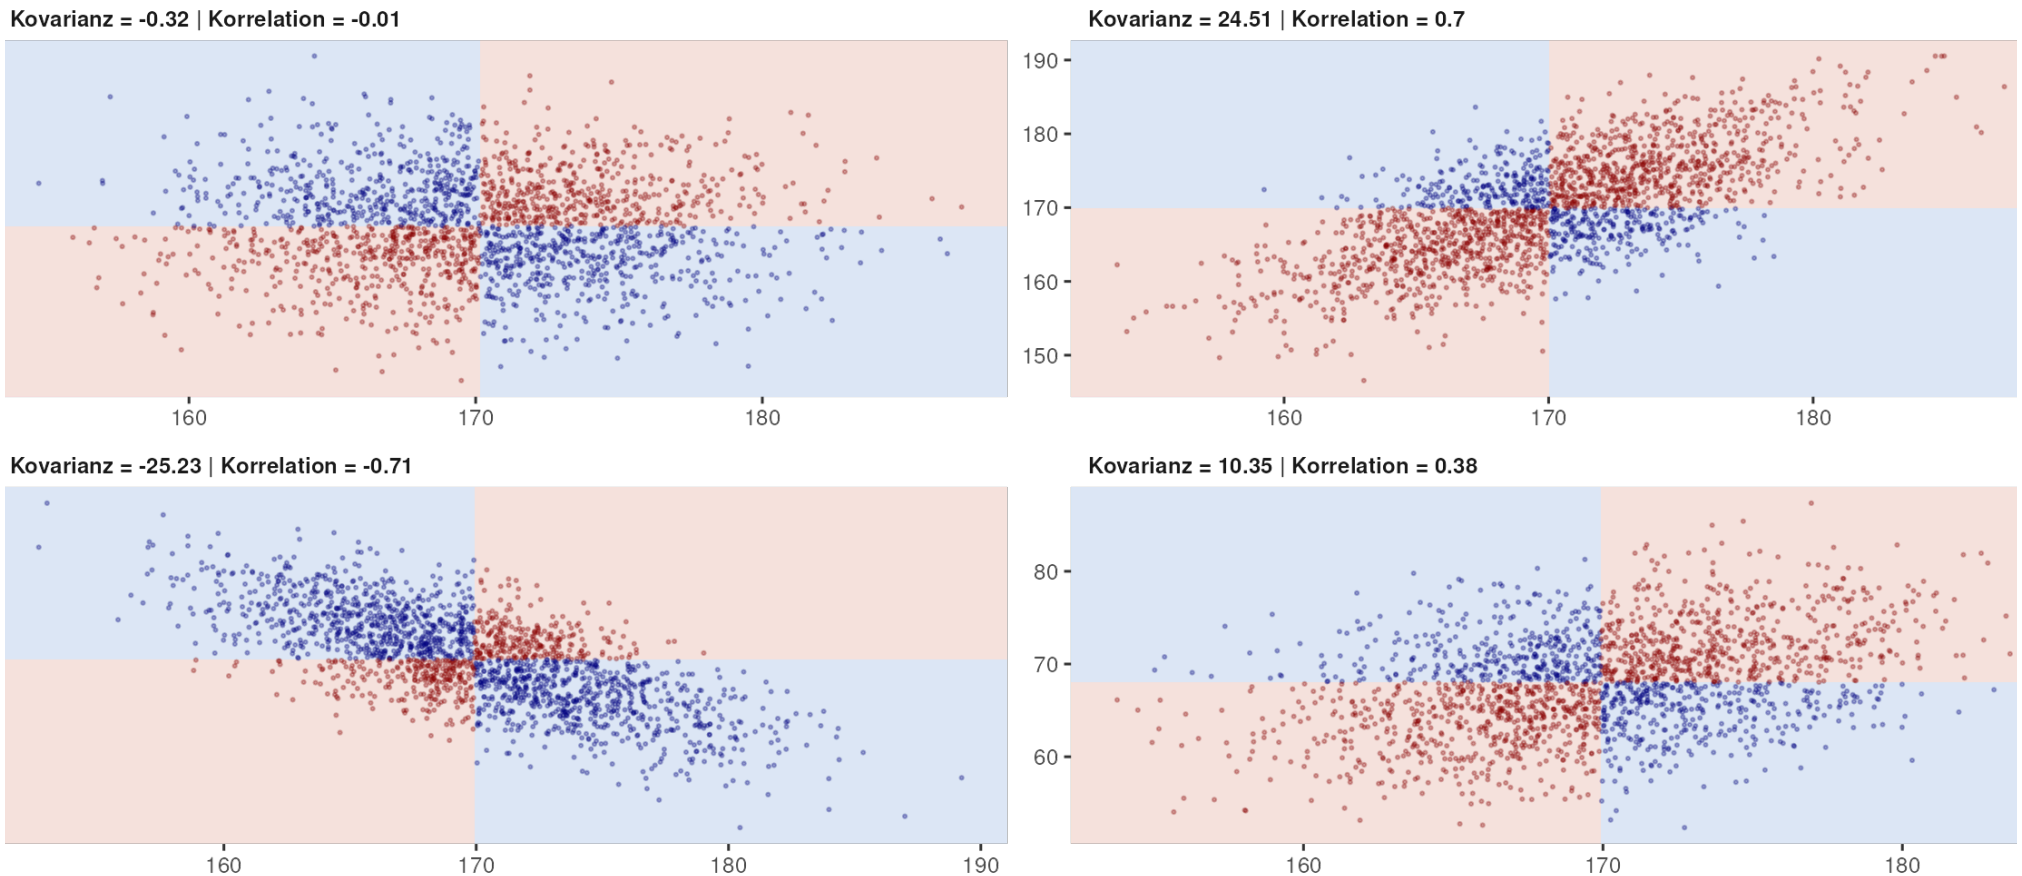


Kovarianz = -25.23 | Korrelation = -0.71

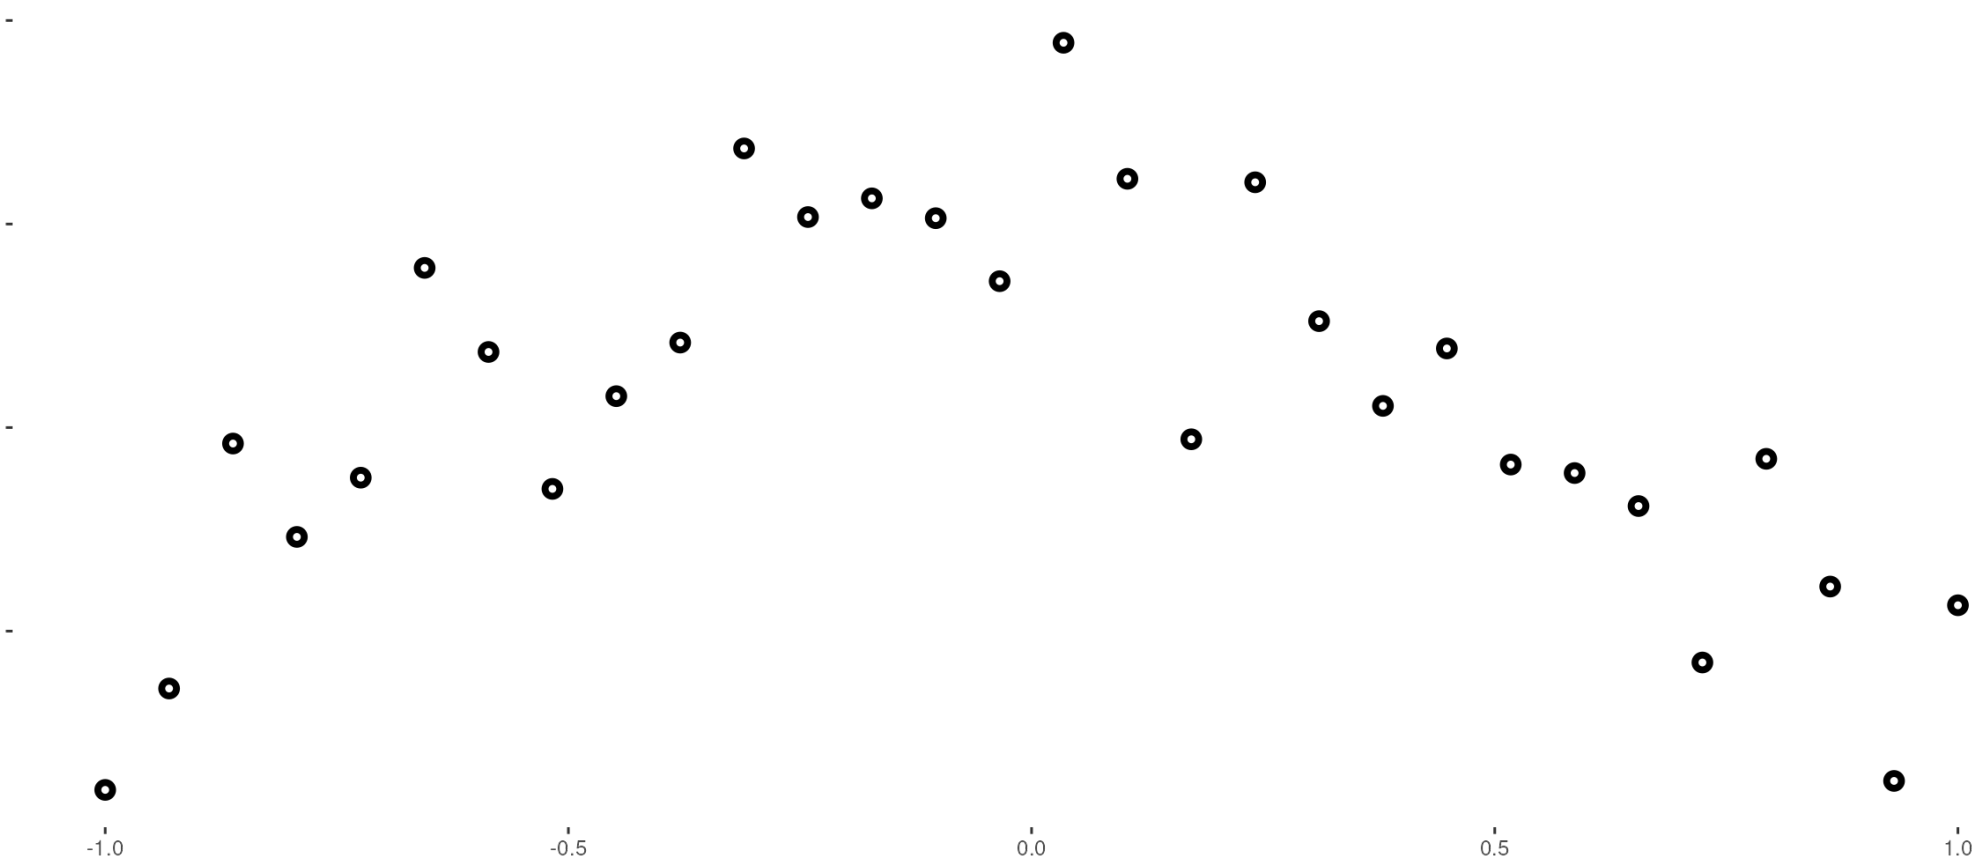


Kovarianz = 10.35 | Korrelation = 0.38

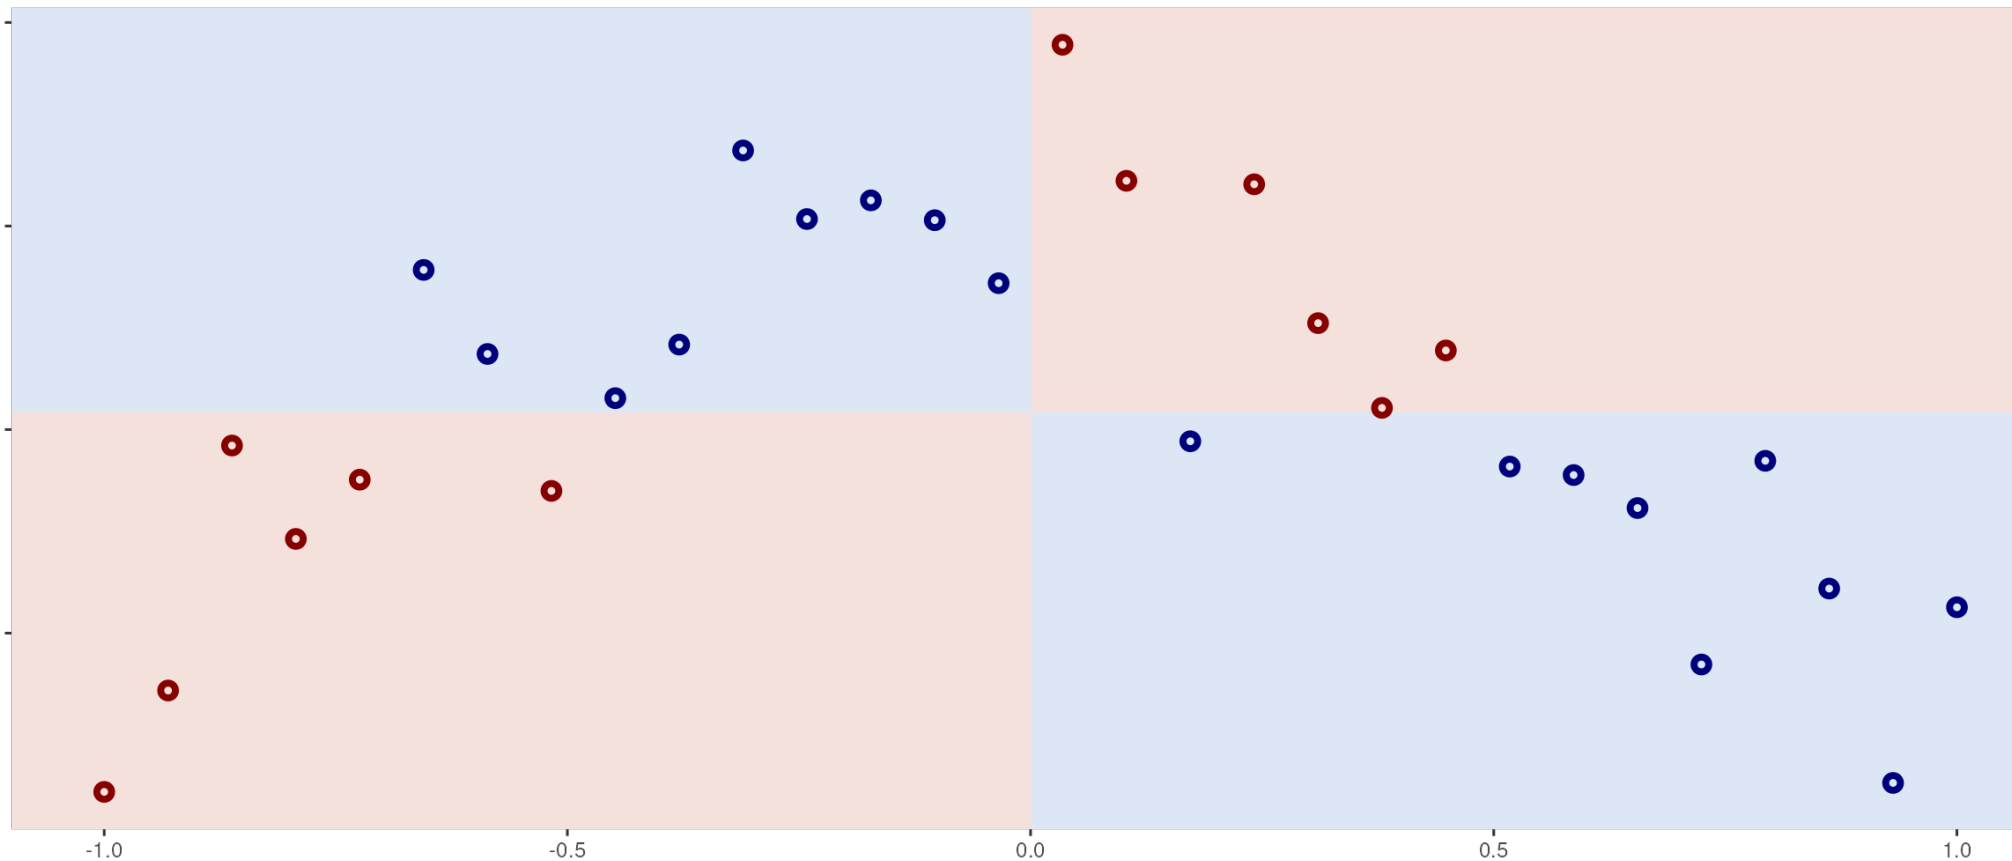



Kovarianz = -0.32 | Korrelation = -0.01
160
170
180
Kovarianz = 24.51 | Korrelation = 0.7
190
180
170
160
150
160
170
180
Kovarianz = -25.23 | Korrelation = -0.71
160
170
180
190
Kovarianz = 10.35 | Korrelation = 0.38
80
70
60
160
170
180

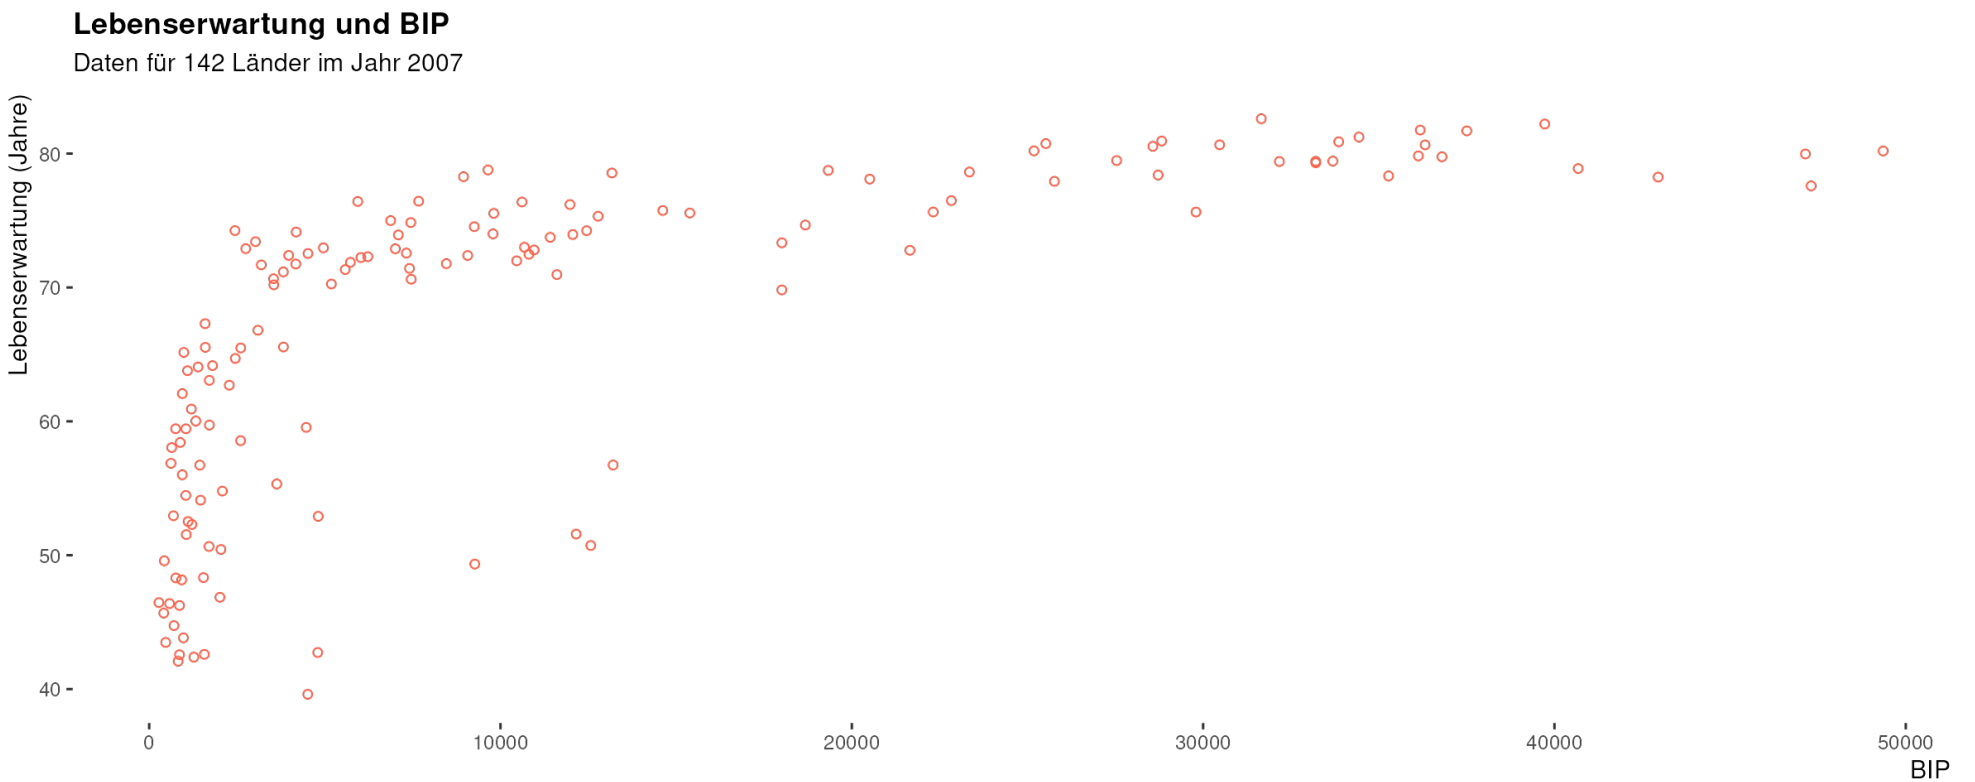
Nichtlineare Zusammenhänge



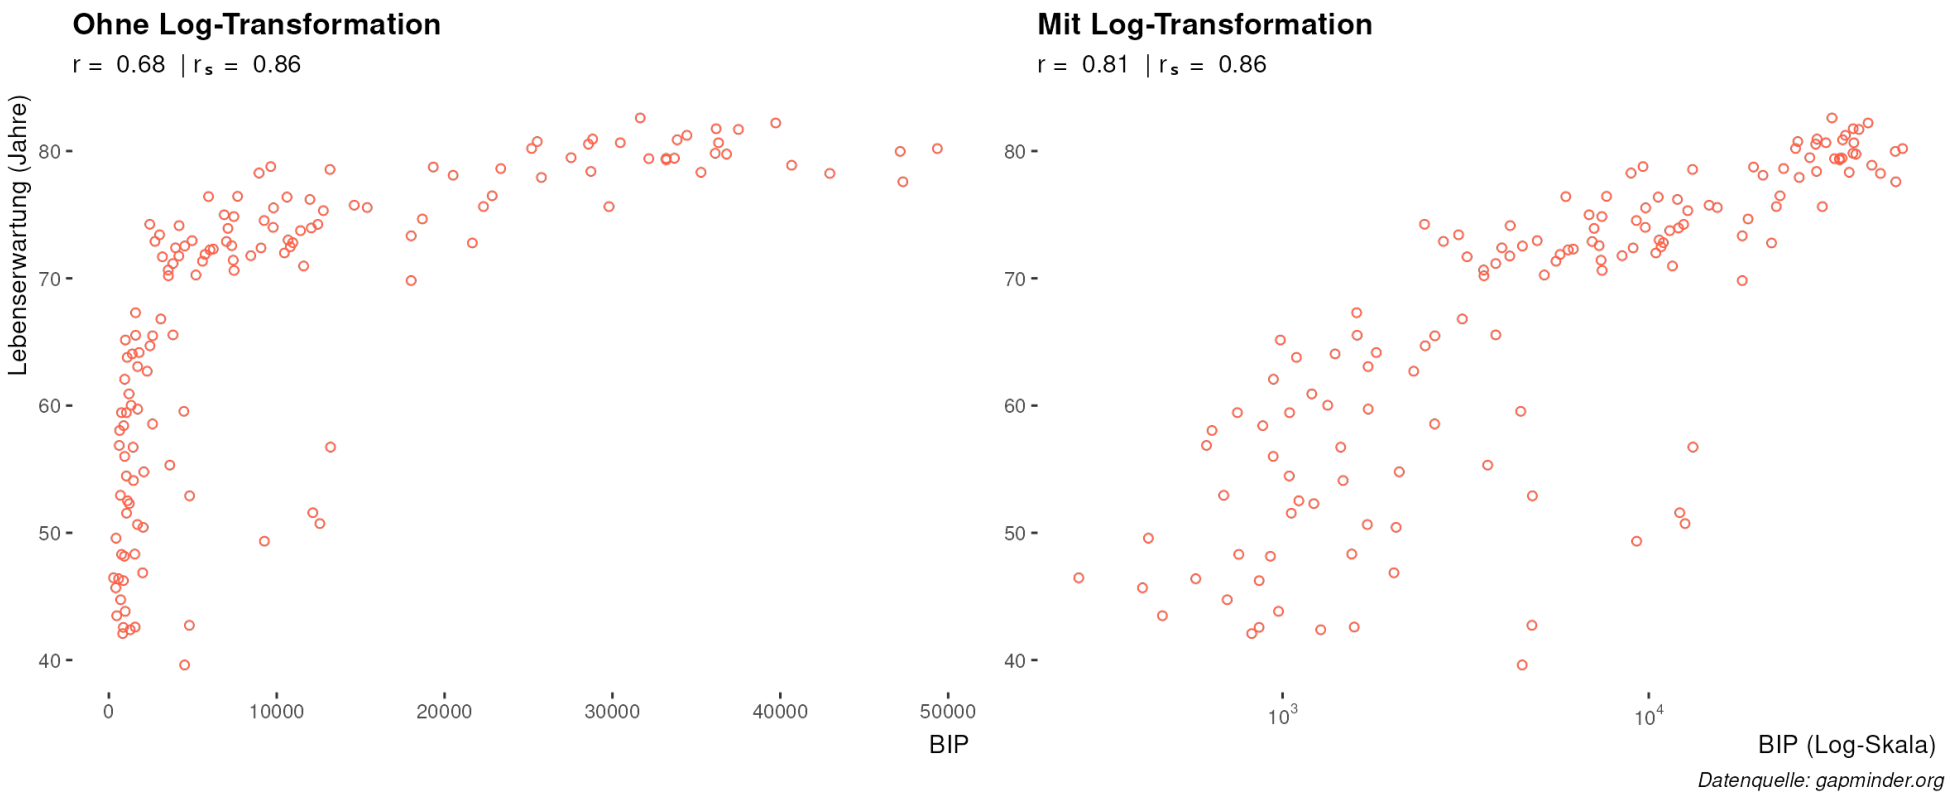
Nichtlineare Zusammenhänge



Nichtlineare Zusammenhänge



Transformationen



Rangkorrelationskoeffizient

Der **Rangkorrelationskoeffizient** ist der Korrelationskoeffizient der **Ränge** zweier Variablen. Für rangtransformierte Variablen x_r und y_r gilt also wie zuvor:

$$r_s = \frac{s_{x_r,y_r}}{s_{x_r} s_{y_r}}$$

Der Rangkorrelationskoeffizient erfasst nicht nur lineare sondern auch nichtlineare aber monotone Zusammenhänge und kann auch für ordinale Variablen eingesetzt werden.

Rangkorrelationskoeffizient

Die beiden Datenreihen

$$x = 1.4 \quad 2.3 \quad 1.1 \quad 2.7 \qquad y = 5.3 \quad 4.3 \quad 0.4 \quad 4.8$$

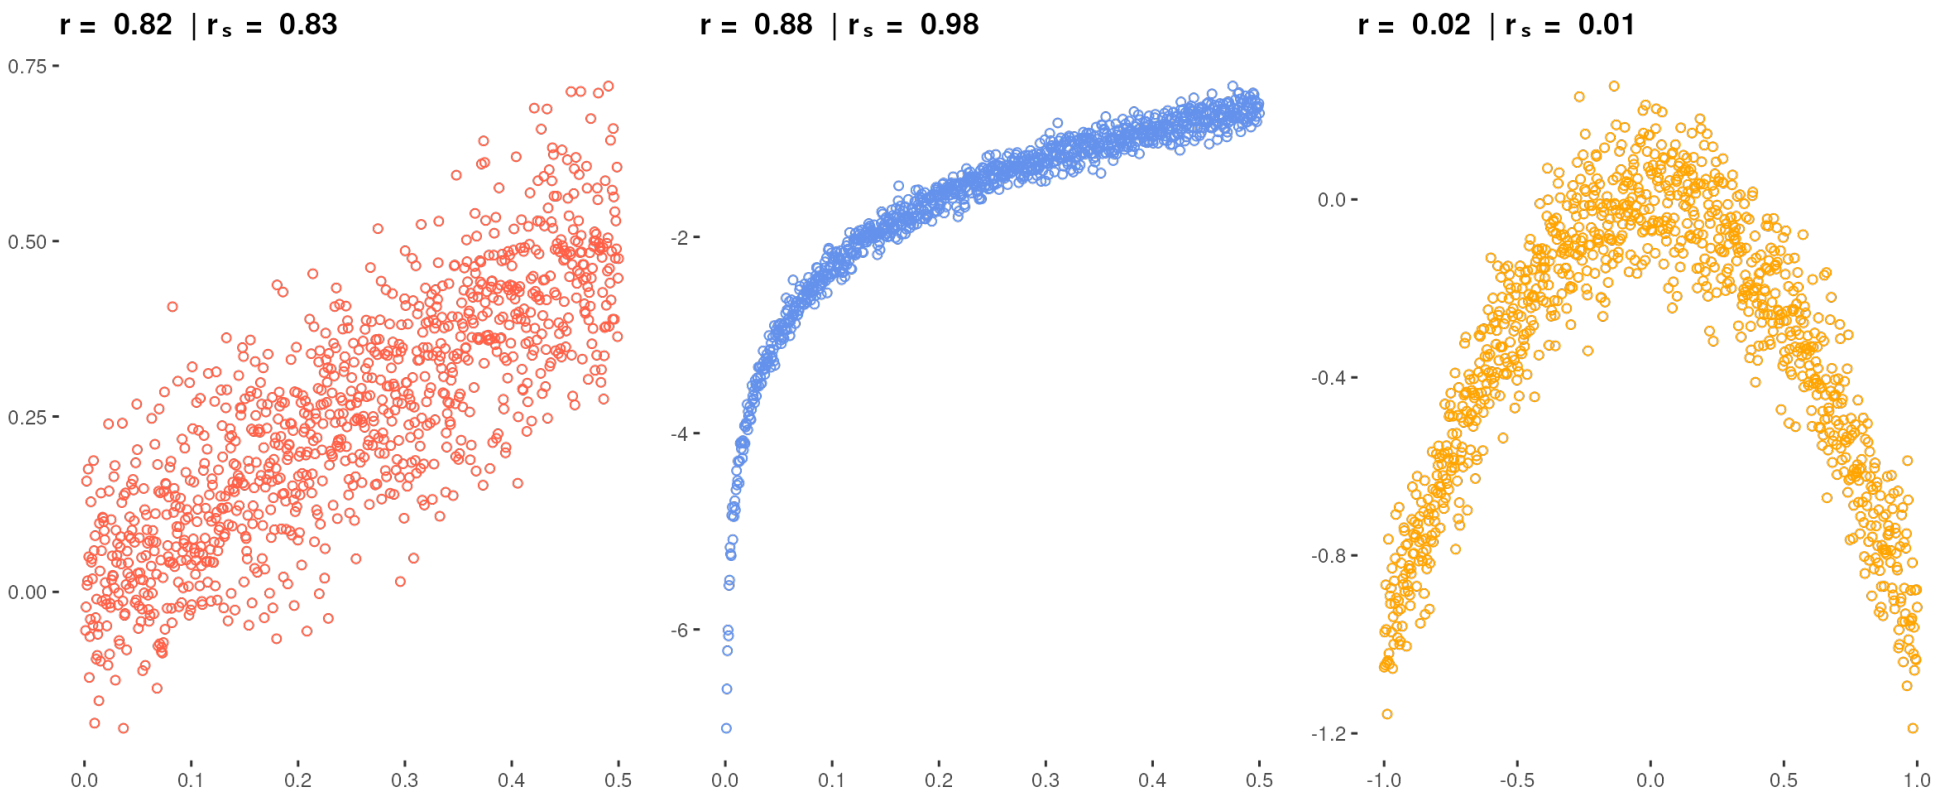
werden rangtransformiert zu:

$$x_r = 3 \quad 2 \quad 4 \quad 1 \qquad y_r = 1 \quad 3 \quad 4 \quad 2$$

Damit ergibt sich unter Anwendung der gleichen Schritte:

$$r_s = \frac{s_{x_r,y_r}}{s_{x_r} s_{y_r}} = \frac{0.5}{1.12 \times 1.12} = 0.4$$

Rangkorrelationskoeffizient



Prüfungsfragen

- Was bemisst der Gini-Koeffizient im Kontext der Lorenzkurve?
- Was impliziert eine negative Kovarianz zweier numerischer Variablen?
- Wovon hängt der Wertebereich der Kovarianz ab?
- Welchen Vorteil hat der Korrelationskoeffizient gegenüber der Kovarianz?
- Welches Zusammenhangsmaß können Sie im Falle eines nichtlinearen aber monotonen Zusammenhangs einsetzen?
- Wie können Sie einen statistschen Zusammenhang zweier ordinalskalierter Variablen messen?