Einführung in die Statistik

Lineare Regression I

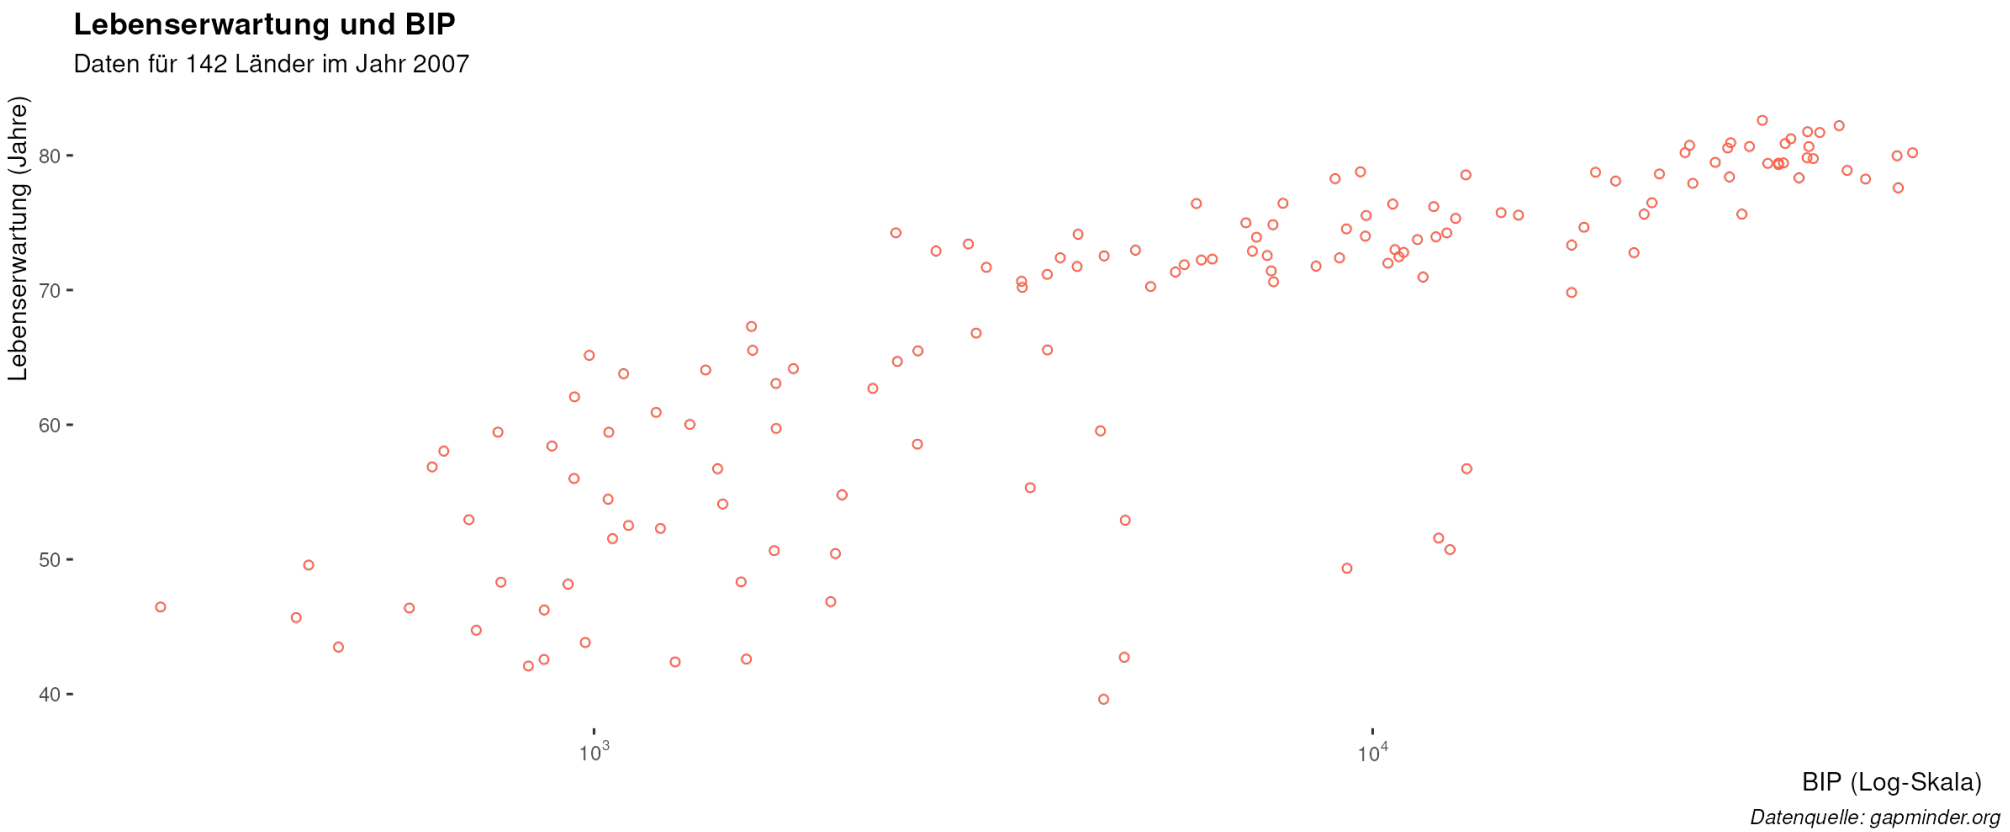
Dr. Jakob Hoffmann

Economic Geography Group, Department für Geographie

Ludwig-Maximilians-Universität, München

Forschungsdesign und statistische Modellierung

Welche Rollen haben die Variablen?

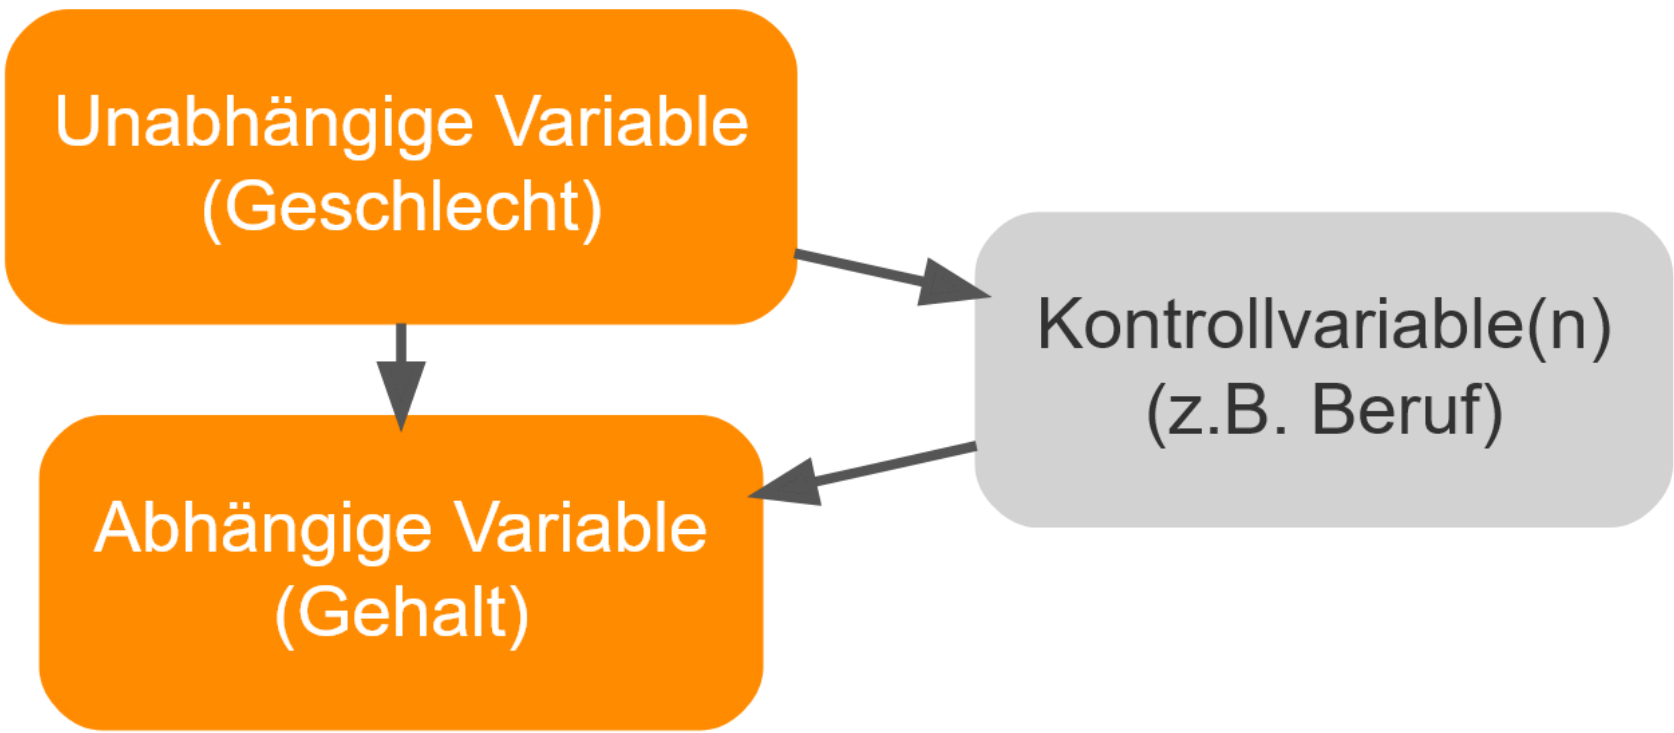


Asymmetrische Variablenrollen

Symmetrische Maße wie der Korrelationskoeffizient behandeln alle Variablen gleich, was häufig nicht der zugrundeliegenden Forschungslogik entspricht.

- Die **abhängige Variable** · *Eng: Outcome* und ihre systematische Variation zu verstehen ist das primäre Untersuchungsziel einer multivariaten Analyse.
- **Unabhängige Variablen** · *Eng: Predictor* dienen der Erklärung oder Vorhersage von Variation in der abhängigen Variable. Die Variation der unabhängigen Variable selbst wird i.d.R. als gegeben angesehen oder experimentell festgelegt.
- Manche unabhängige Variablen dienen als **Kontrollvariablen** der Vermeidung von verzerrten Schlussfolgerungen über den zentralen zu untersuchenden Zusammenhang.

Beispiel | Gender Pay Gap



Modelle statistischer Zusammenhänge

Wir modellieren eine abhängige Variable y als eine Funktion f einer unabhängigen Variable x. Der Fehlerterm ε bildet unmodellierte Variation in y ab:

$$y = f(x) + \varepsilon$$

- Für gegebenes x kann das Modell eine Vorhersage für y machen.
- Die Funktion f bildet die Form des Zusammenhangs zwischen x und y ab.
- Der Fehlerterm ε (Epsilon) ist eine Zufallsvariable, deren Streuung die Unsicherheit in der Vorhersage quantifiziert.
- Modellierungsentscheidung: Wie spezifizieren wir f (und die Verteilung von ε)?

Statistische Modelle als ‚Mittelwertsmaschinen'

Zentrale Frage: Was ist der Mittelwert des Outcomes y für eine spezifizierte Inputkombination x?

Fokus auf den Erwartungswert $\mathbb{E}[y] = f(x)$, der Fehlerterm ε is nicht direkt von Interesse (aber wichtig für Diagnostik und Bewertung eines Modells)

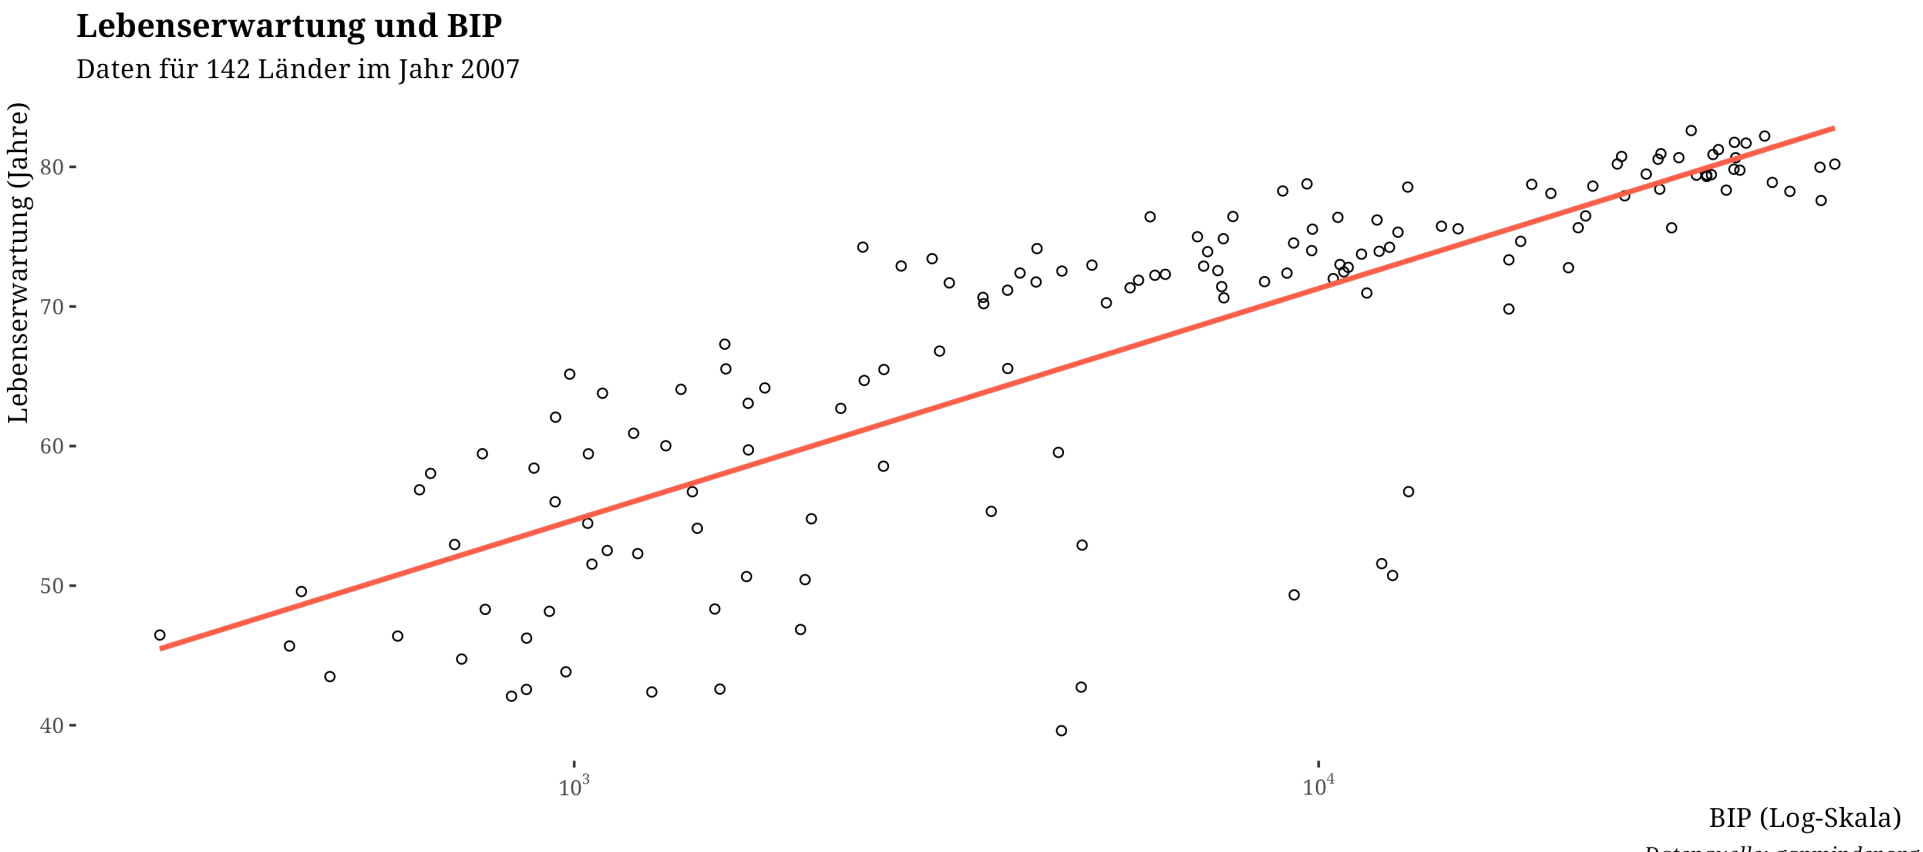
Beispiel:

Was ist das mittlere Einkommen von bayerischen Frauen über 40 mit 2 Kindern?

- **Outcomevariable** (y): Einkommen
- **Prädiktoren** (x): {Herkunft, Geschlecht, Alter, Kinder}

Lineare Regression

Lineare Regression



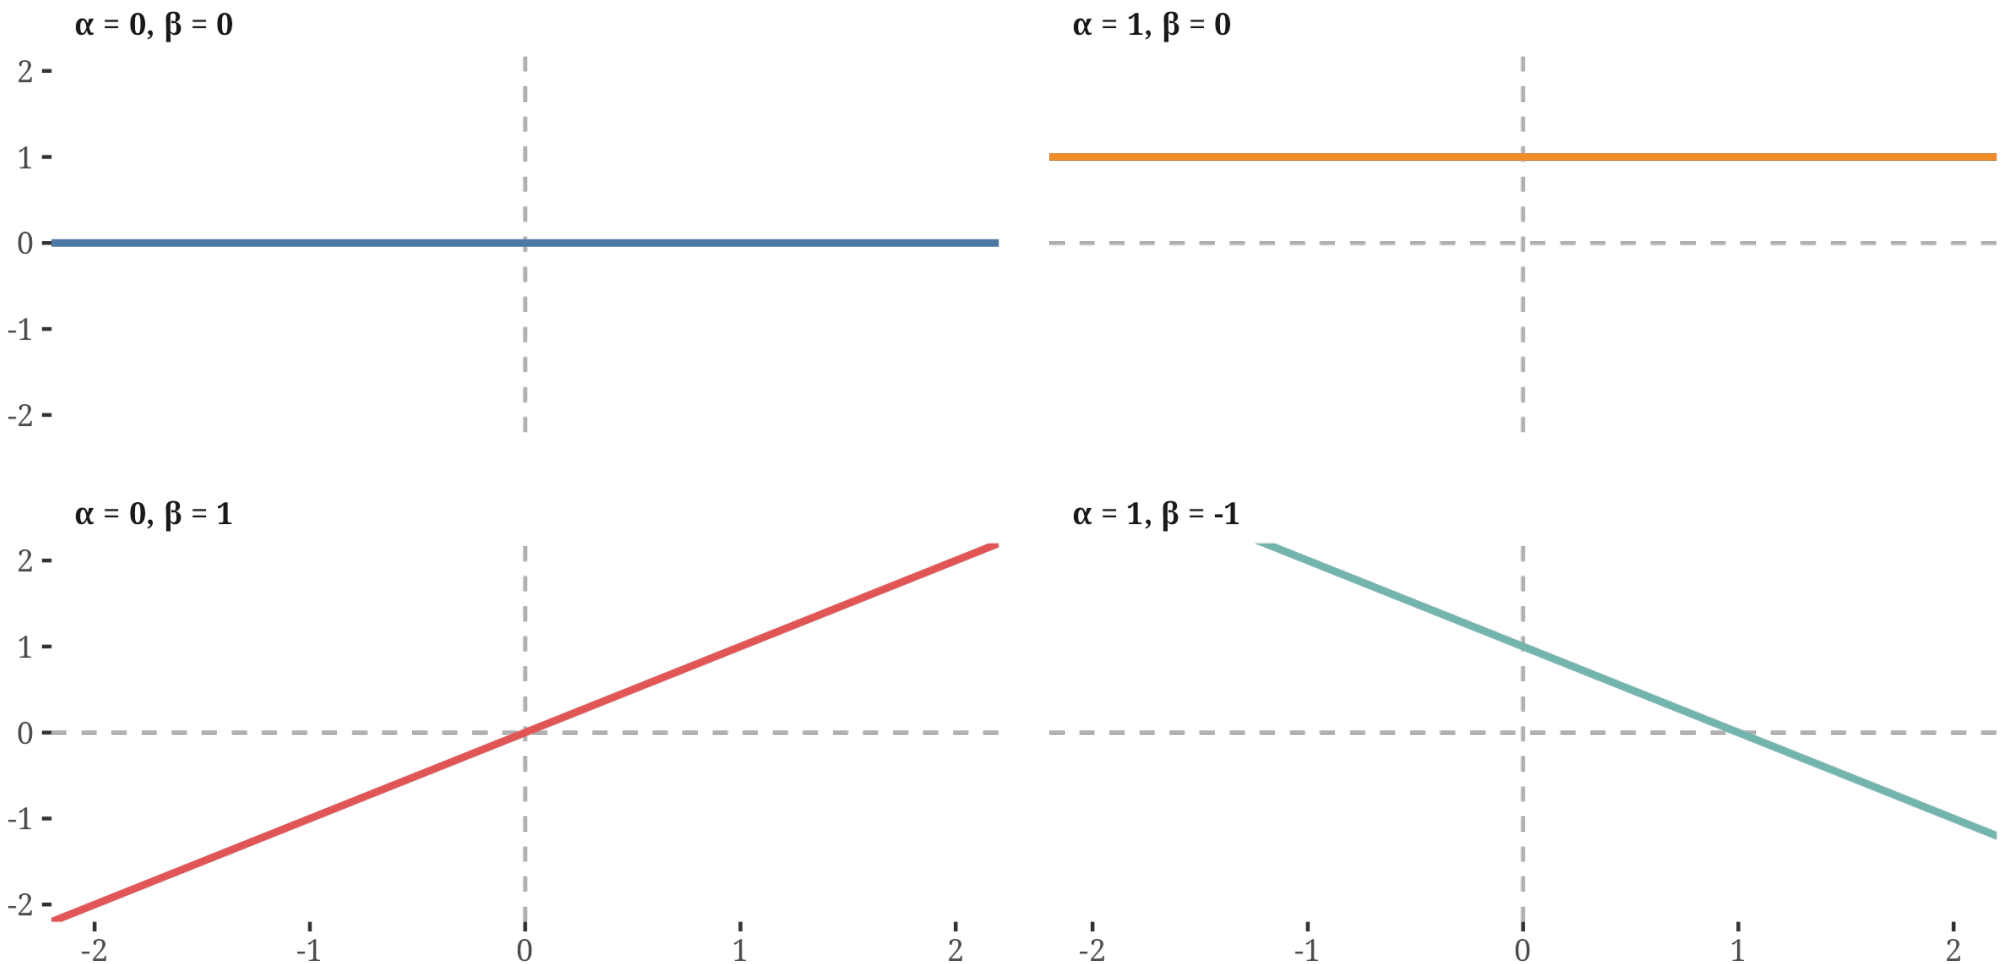
Lineare Regression

Eine simple aber nützliche Spezifikation für f ist die Geradengleichung:

$$f(x) = \alpha + x\beta$$

Die Modellparameter α und β bestimmen, wie x und y zusammenhängen:

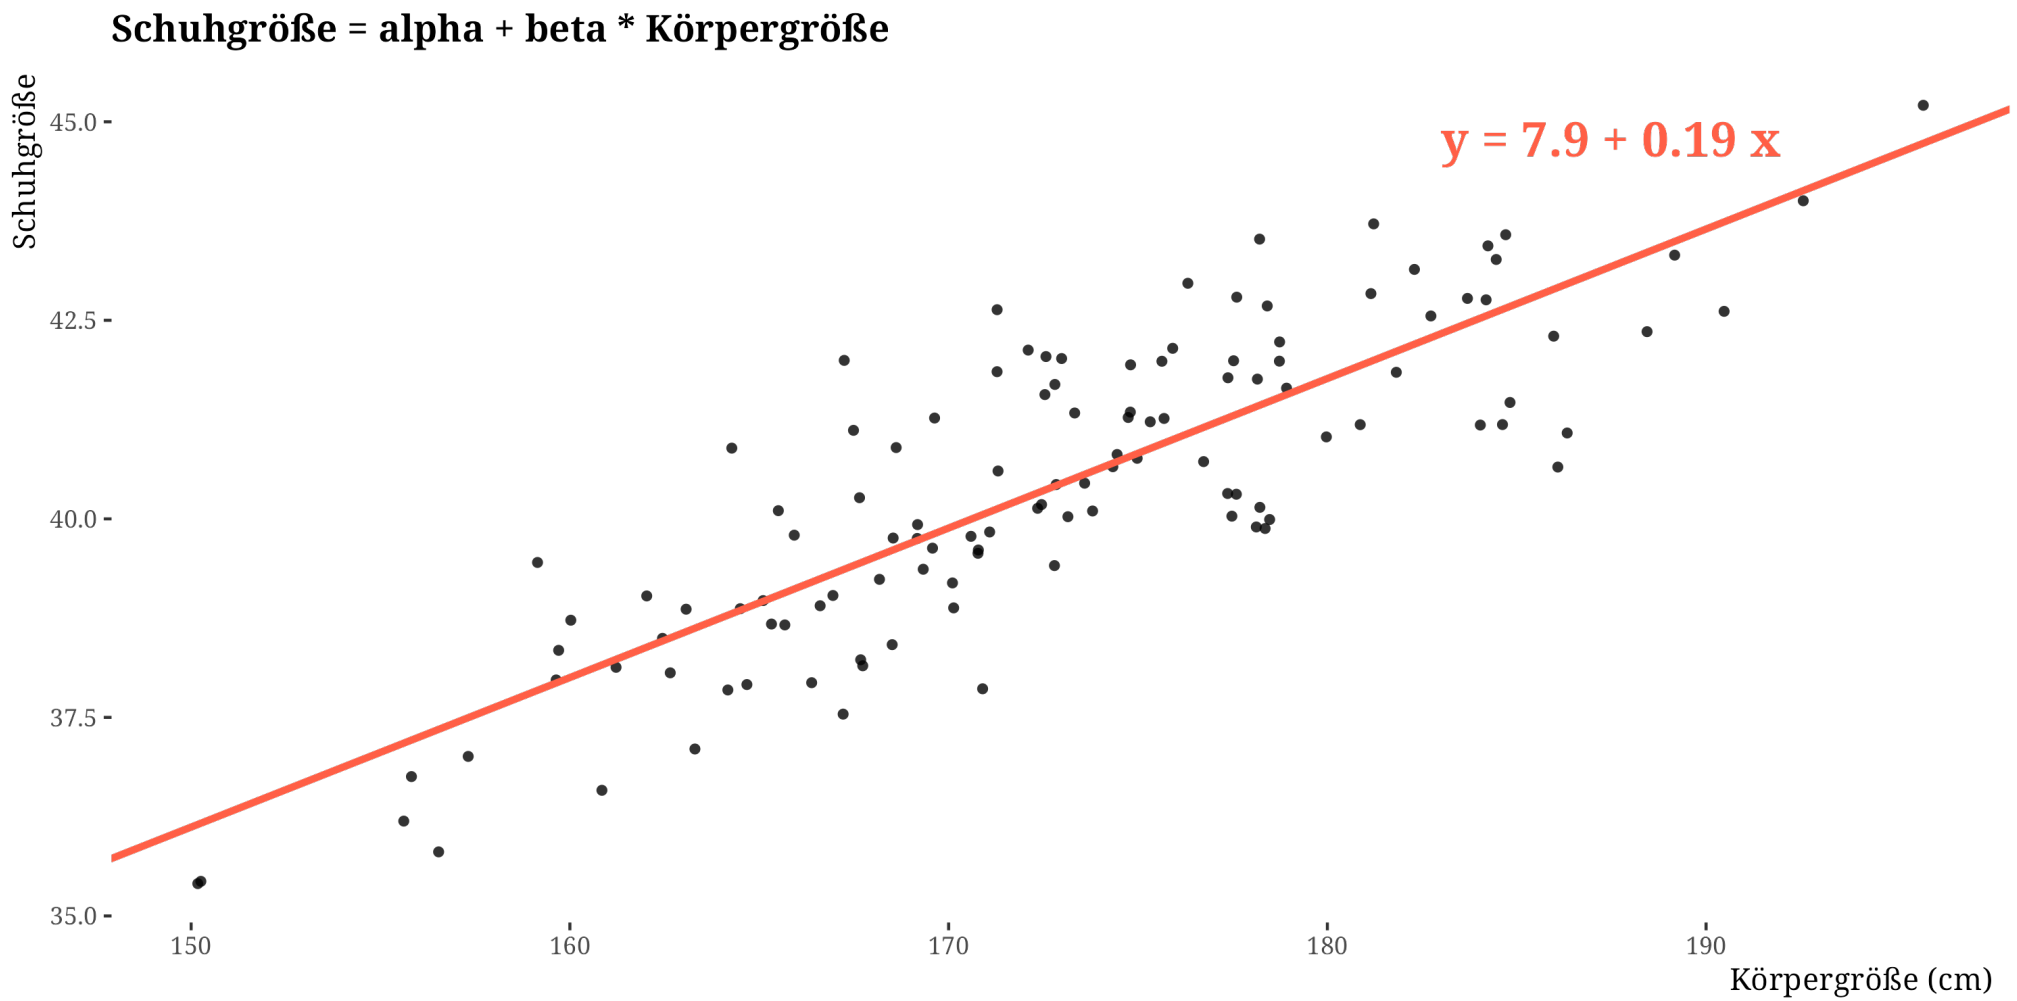
- Der Parameter α ist der *y-Achsenabschnitt* der Geradengleichung, d.h. der Wert von y wenn $x = 0$.
- Der Parameter β gibt die *Steigung* der Geraden an, d.h., um wie viel $f(x)$ steigt wenn x um 1 steigt. β bestimmt also *Richtung* und *Stärke* des Zusammenhangs.


α = 0, β = 0
α = 1, β = 0
α = 0, β = 1
α = 1, β = -1
2
1
0
-1
-2
-2
-1
0
1
2

Survey



$$\text{Schuhgröße} = f(\text{Körpergröße})$$


Schuhgröße = alpha + beta * Körpergröße
Schuhgröße
45.0
42.5
40.0
37.5
35.0
150
160
170
180
190
Körpergröße (cm)
y = 7.9 + 0.19 x

Modellvorhersage

Wenn wir die Paremeter α und β wissen, können wir das Modell nutzen, um eine Vorhersage $\hat{y}$ für y auf Basis eines Inputs x zu machen:

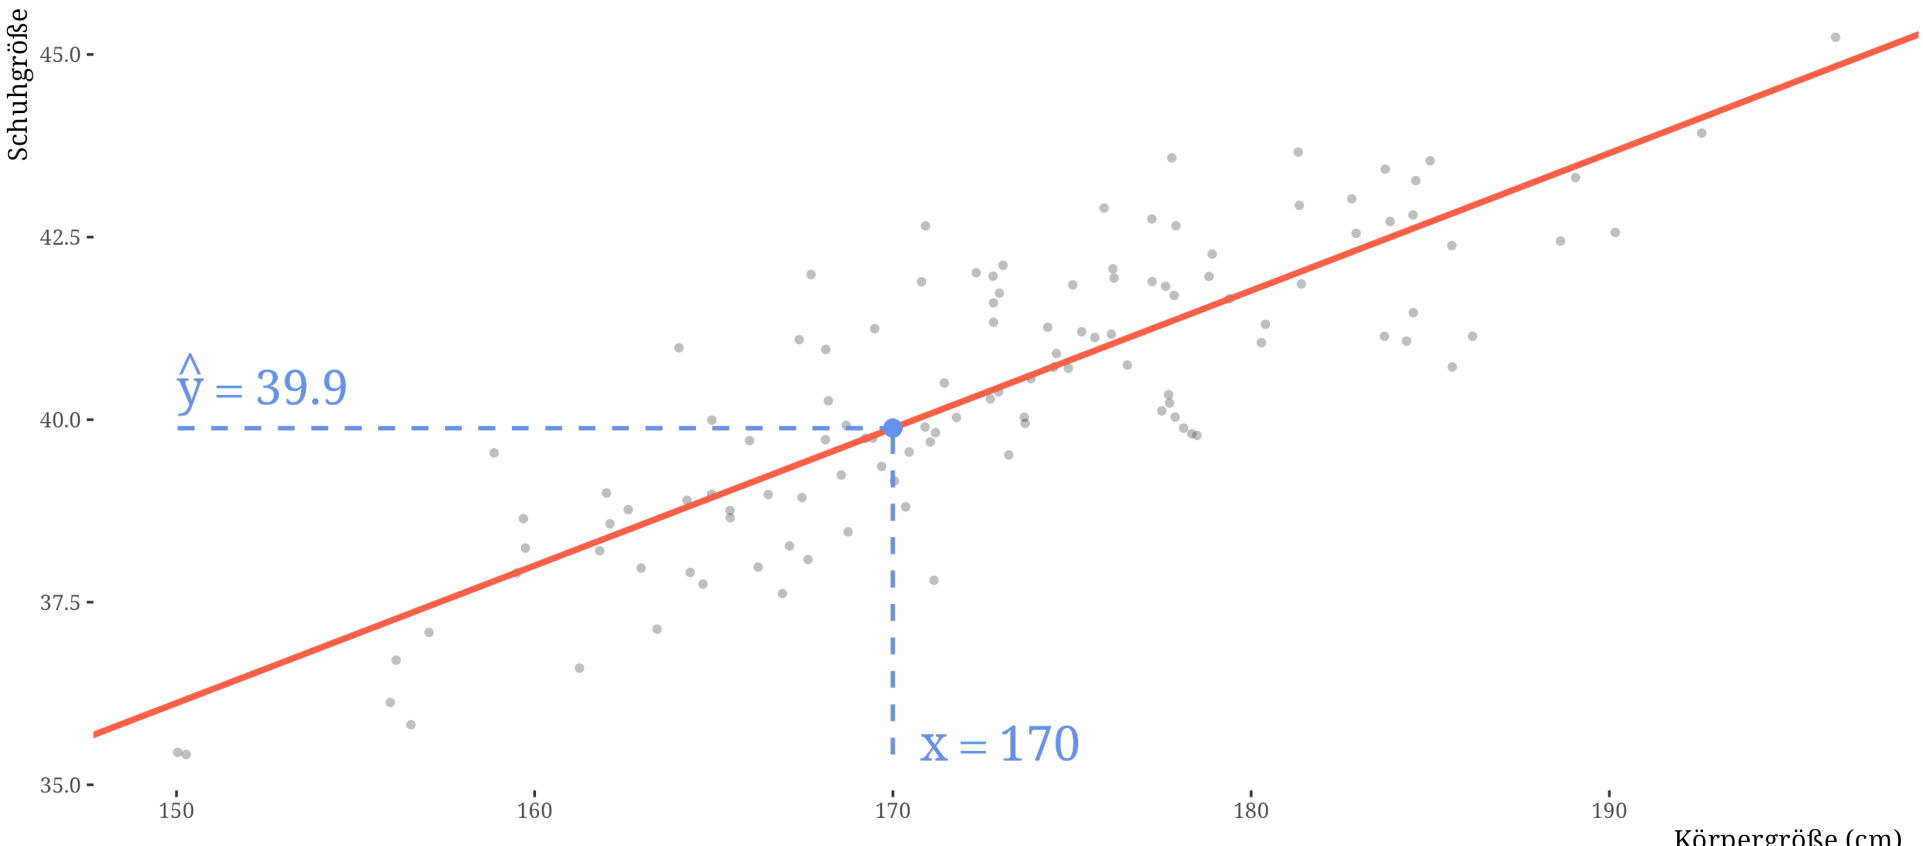
$$\hat{y} = \alpha + x\beta$$

Die Modellvorhersage $\hat{y}$ ist der geschätzte Mittelwert von y für Beobachtungen mit input x und entspricht der Regressionsgeraden am Punkt x.

Die Differenz zwischen der Vorhersage $\hat{y}_i$ für eine Beobachtung i und dem tastächlich beobachteten Wert y_i ist der Fehlerterm (das Residuum) ε_i:

$$\varepsilon_i = y_i - \hat{y}_i$$

Modellvorhersage

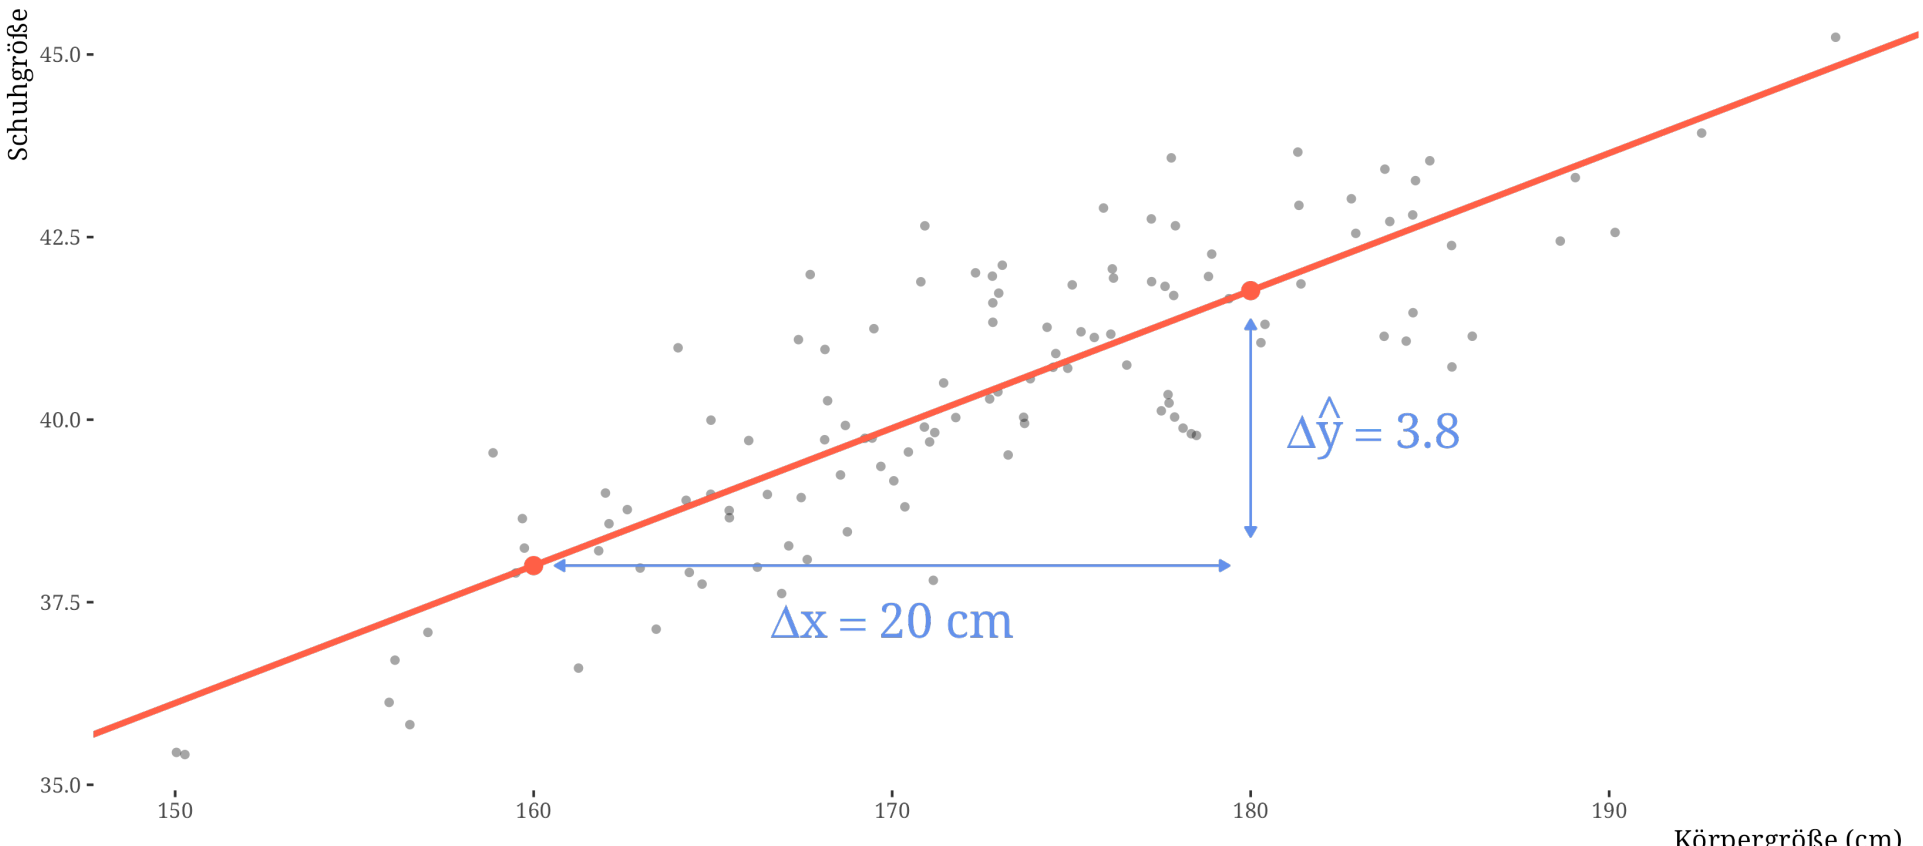


Vergleiche von Vorhersagen

Modellvorhersagen können genutzt werden, um Vergleiche auf Basis unterschiedlicher Inputs x_1 und x_2 zu tätigen:

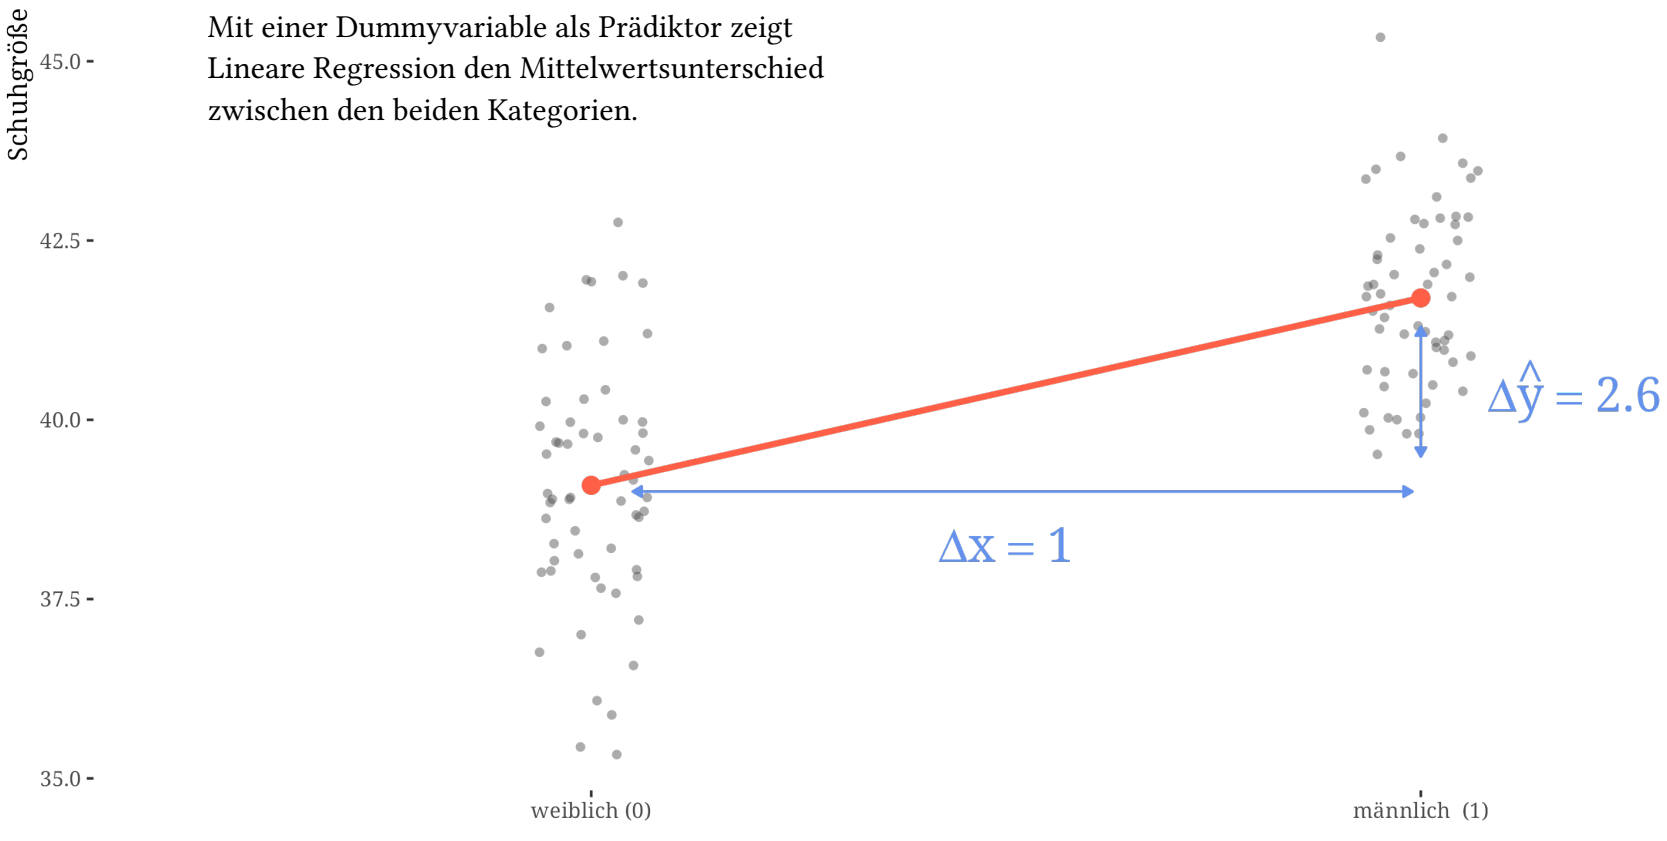
$$\begin{aligned}
\Delta y &= \hat{y}_2 - \hat{y}_1 \\
&= f(x_2) - f(x_1) \qquad \text{Allgemein (für beliebige } f\text{)} \\
&= (\alpha + x_2\beta) - (\alpha + x_1\beta) \\
&= (x_2 - x_1)\beta = \Delta x \cdot \beta \qquad \text{Lineare Regression}
\end{aligned}$$

Vergleiche von Vorhersagen



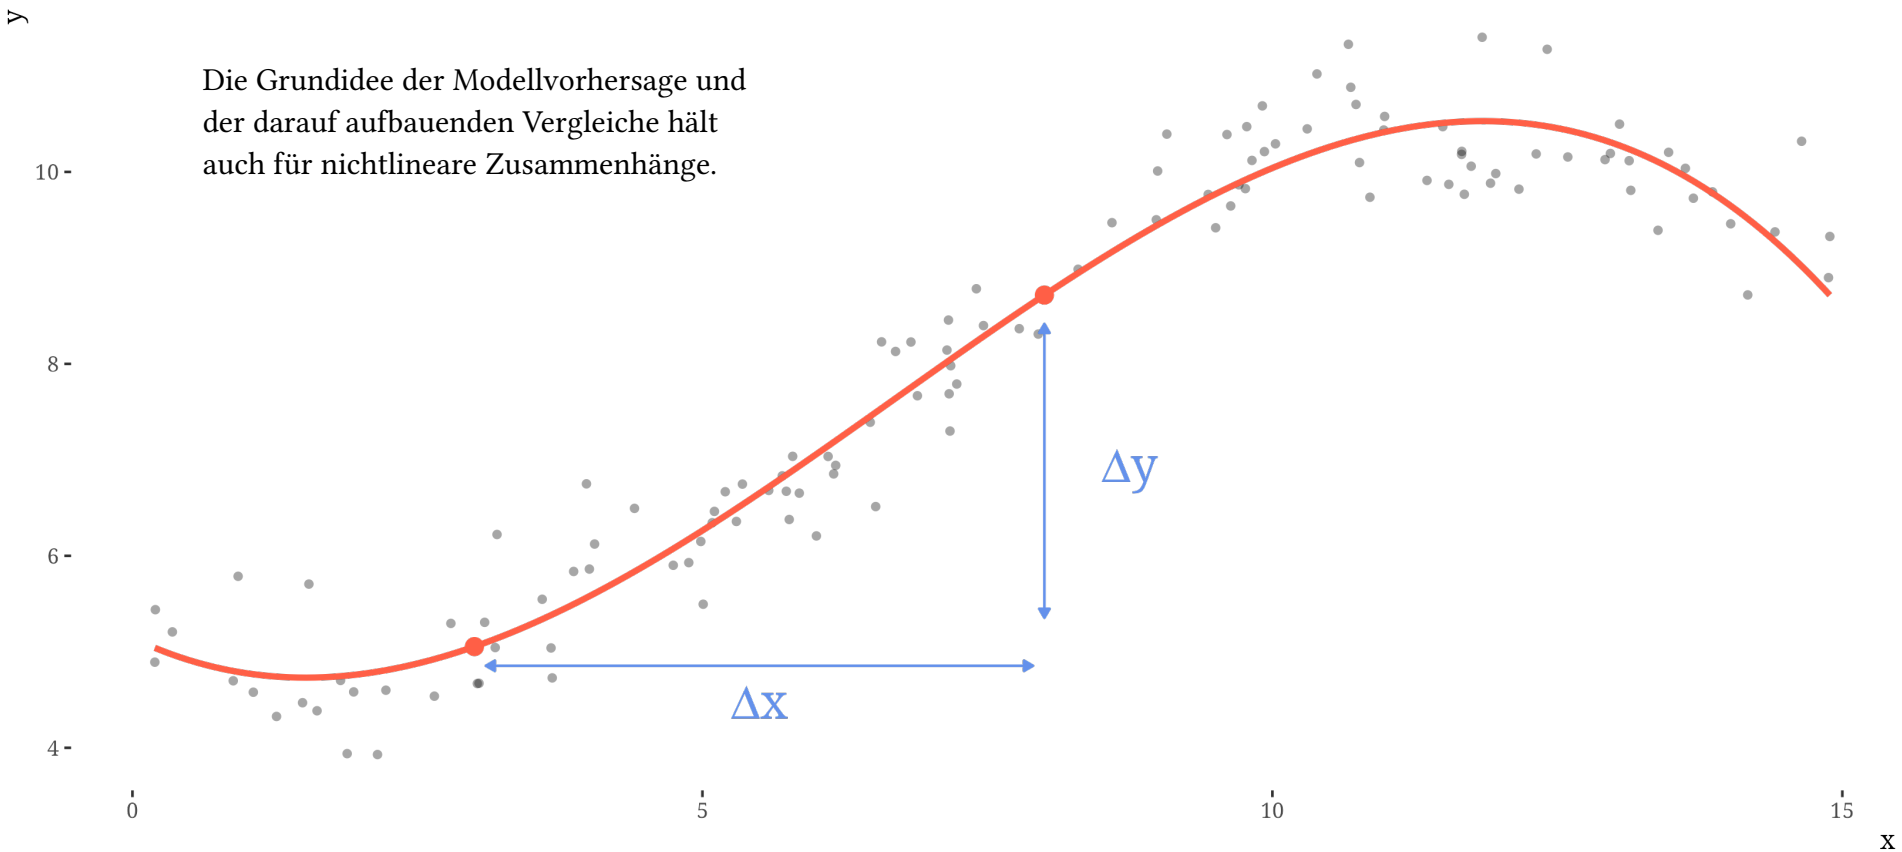
Dummyvariablen als Prädiktoren

Mit einer Dummyvariable als Prädiktor zeigt Lineare Regression den Mittelwertsunterschied zwischen den beiden Kategorien.

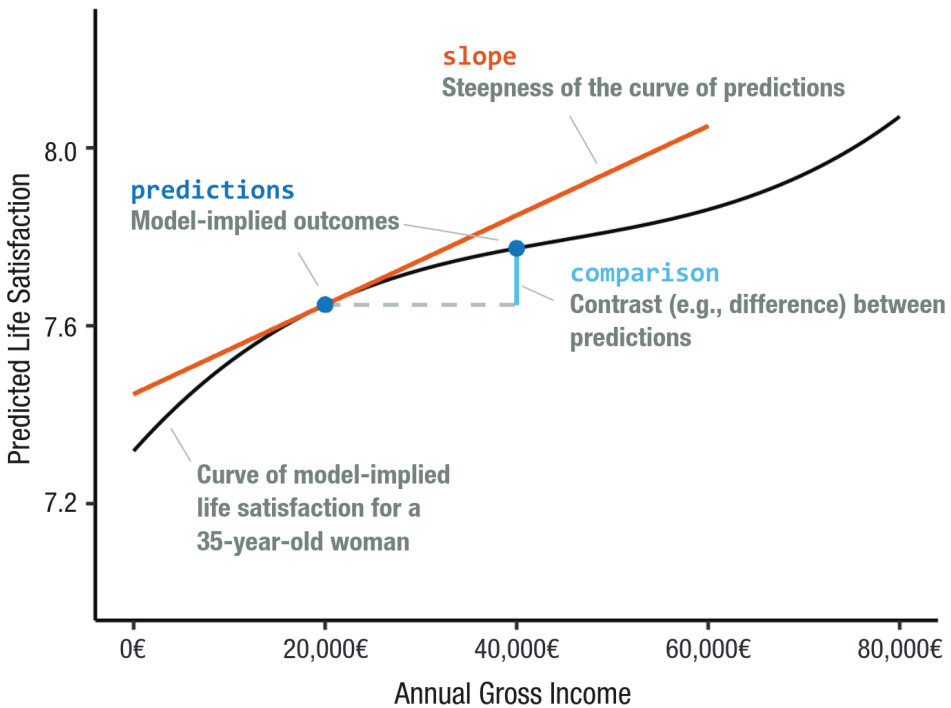


Nichtlineare Zusammenhänge

Die Grundidee der Modellvorhersage und der darauf aufbauenden Vergleiche hält auch für nichtlineare Zusammenhänge.



Relevante Modellgrößen



- Regressionsmodelle erlauben **Vorhersagen** der Outcomevariable für gegebene Werte der Inputvariable(n).
- **Vergleiche** von Vorhersagen lassen uns Mittelwertsunterschiede über Inputkombinationen prüfen.
- Die **Steigung** der Regressionsgerade quantifiziert die Stärke eines statistischen Zusammenhangs.

Quelle: Rohrer, J. M., & Arel-Bundock, V. (2026). Models as prediction machines: How to convert confusing coefficients into clear quantities. Advances in Methods and Practices in Psychological Science, 9(2).

Parameterschätzung

Parameterschätzung | OLS

Die Methode der **kleinsten Quadrate** (Ordinary Least Squares, OLS) wählt α und β so, dass die *Summe der quadrierten Residuen (RSS)* minimiert wird:

$$\hat{\alpha}, \hat{\beta} = \arg\min_{\alpha,\beta} \mathrm{RSS}(\alpha, \beta)$$

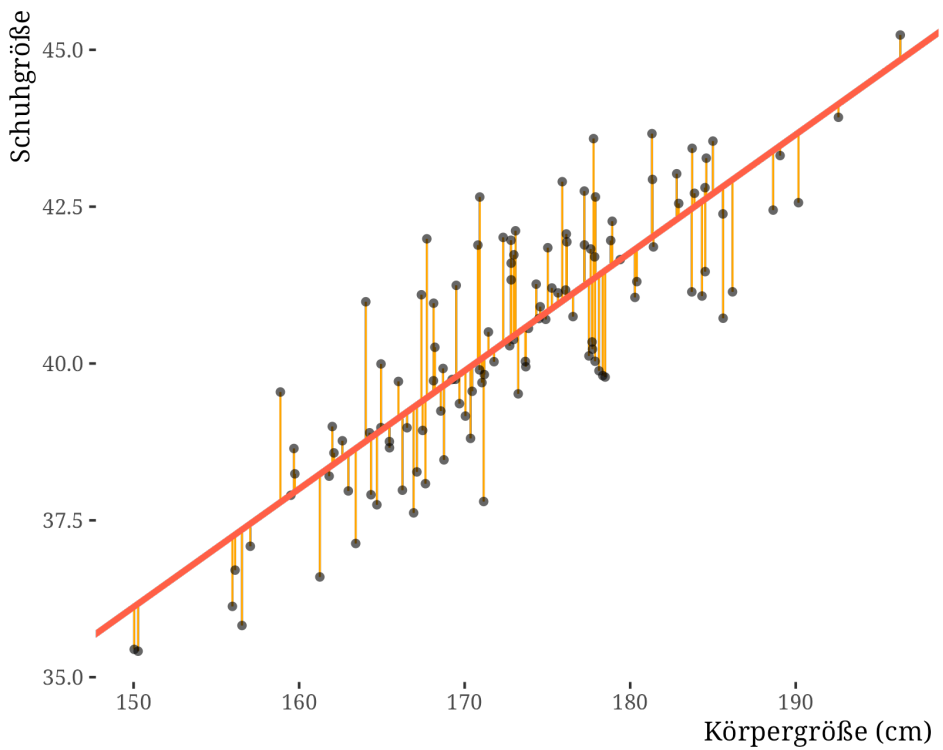
$$= \arg\min_{\alpha,\beta} \sum_{i=1}^{n} (y_i - \alpha - x_i\beta)^2$$

Die Statistiken $\hat{\alpha}$ und $\hat{\beta}$ werden auf Basis der Daten berechnet und werden die *OLS-Schätzer* der unbekannten Parameter α und β genannt.

Parameterschätzung | OLS

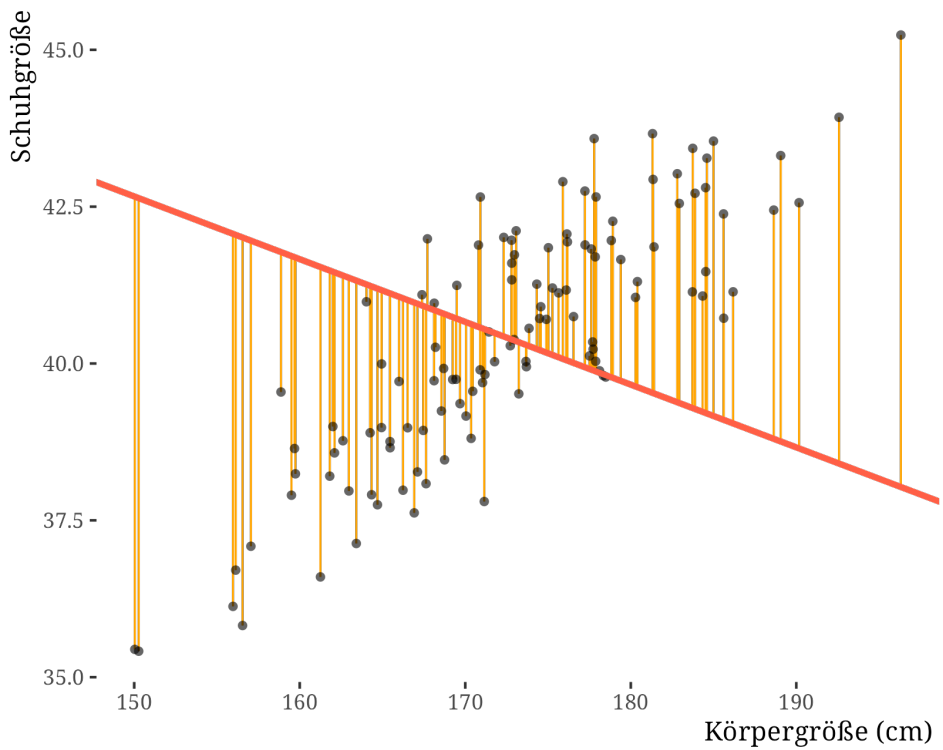
Guter Fit

beta = 0.19 | RSS = 132



Schlechter Fit

beta = -0.1 | RSS = 880



Parameterschätzung | Herleitung

Wir setzen die partiellen Ableitungen der Zielfunktion nach α und β gleich null:

$$\frac{\partial \text{ RSS}}{\partial \alpha} = -2 \sum_{i=1}^{n} (y_i - \alpha - x_i \beta) = 0$$

$$\frac{\partial \text{ RSS}}{\partial \beta} = -2 \sum_{i=1}^{n} x_i (y_i - \alpha - x_i \beta) = 0$$

Diese beiden Gleichungen lassen sich nach $\hat{\alpha}$ und $\hat{\beta}$ auflösen, den OLS-Schätzern der unbekannten Parameter α und β.

Parameterschätzung | Kovarianz und Korrelation

Der Zähler von $\hat{\beta}$ ist die Kovarianz von x und y, der Nenner die Varianz von x:

$$\hat{\beta} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2} = r\frac{s_y}{s_x}$$

Einfache Lineare Regression ist eng verwandt mit dem Korrelationskoeffizienten, hat aber einige Vorteile:

- Lineare Regression erlaubt komplexere Abfragen (Vorhersagen, Vergleiche).
- Lineare Regression lässt sich flexibel erweitern (mehrere Prädiktoren, andere Variablenverteilungen, andere funktionale Form).

Prüfungsfragen

- Was sind die Rollen der Parameter α und β im einfachen linearen Regressionsmodell?
- Was sind die ungefähren Werte der Parameter α und β für die nachfolgende Abbildung?
- Mit welchem Verfahren können Sie die optimalen Parameterwerte der Regressionsgerade für einen gegebenen Datensatz ermittlen? Wie funktioniert das Verfahren?
- Sie Schätzen ein Regressionsmodell für den Zusammenhang von Körper- und Schuhgröße und erhalten Werte von $\alpha = 6$ und $\beta = 0.2$. Was wäre die Modellvorhersage für eine Person, die 250cm groß ist?